SCHOOL OF **DATA**

INTRODUCTION AU TRAVAIL AVEC LES DONNEES

I. LES DIFFERENTES ETAPES

II. RECUPERER LES DONNEES

III. S’ORGANISER ET SE PROTEGER

IV. VERIFIER SES DONNEES

V. NETTOYER SES DONNEES

VI. EXERCICE GUIDE

SCHOOL OF DATA

LA PIPELINE DE DONNEES

LES DIFFERENTES ETAPES

7 GRANDES ETAPES
valable pour tout type de projet, de la brève sur le vote du budget municipal à l'enquête internationale sur l'évasion fiscale

TRAVAIL SOUVENT NON LINEAIRE
aller-retour entre étapes, répétition des étapes pour plusieurs jeux de données…)

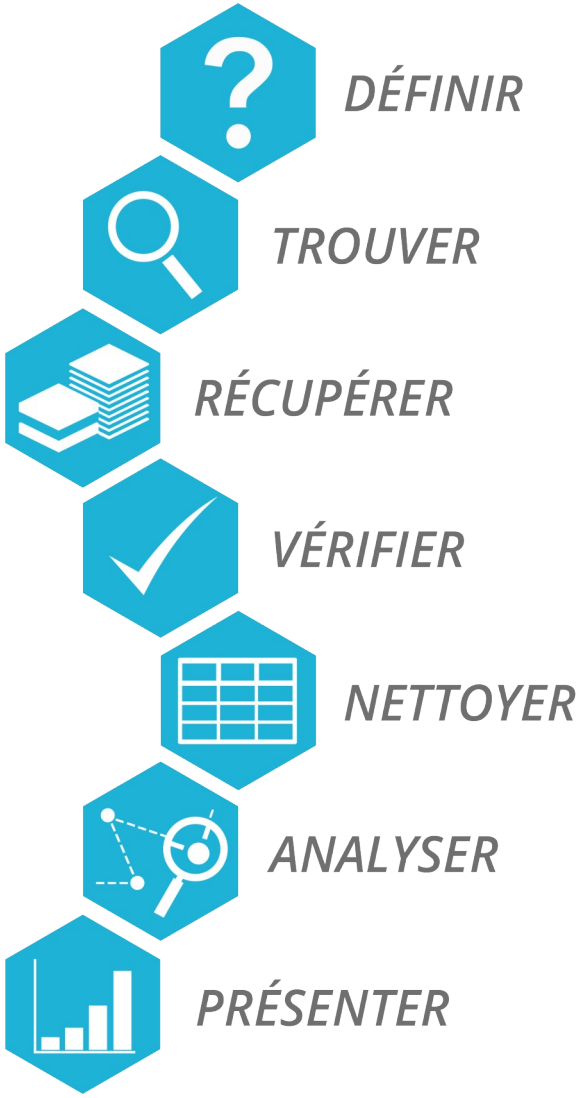

CE QUE VOUS CONNAISSEZ
Problématique & hypothèses, demande d'accès aux documents publics, portails open data, filetype:xls…

CE QUE L'ON VA VOIR
scraping, openrefine, validation de données, datavizcatalogue.com et plein d'autres choses sympa

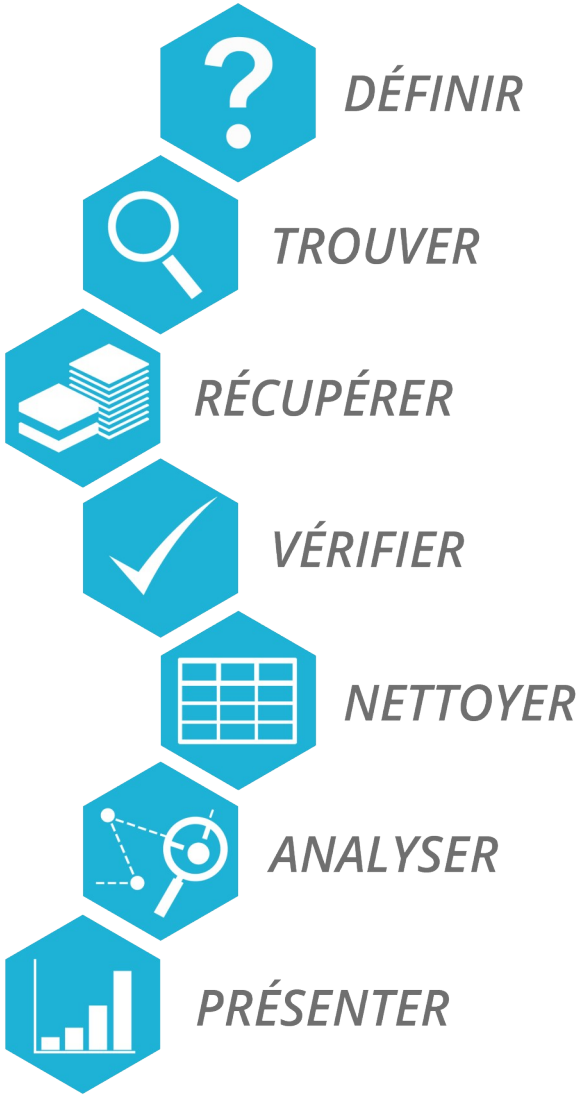

SCHOOL OF DATA

TROISIEME ETAPE

RECUPERER LES DONNEES

2 GRANDES QUESTIONS

Où sont mes données ?

Sous quel format sont-elles conservées ?

2 GRANDES QUESTIONS

→ Où sont mes données ?

Sous quel format sont-elles conservées ?

LOCALISATION	RECUPERATION	FORMATS
Portail open data	Téléchargement	xls, csv, shp, pdf, ods, json, xml, sqlite
Dans le système informatique d'une administration ou d'une entitée privée (non publiées en ligne)	Demande d'accès	xls, csv, shp, pdf, ods, json, xml, sqlite (et bien pire…)
Dans les archives physiques d'une administration ou d'une entitée privée	Demande d'accès	papier, photos (!), microfilm (!?!),
Derrière une interface de programmation applicative (API)	En bidouillant un peu de code informatique	csv, json, xml
En libre accès sur le web	en fonction du format	html, pdf (ou tout autre format en existence)
Nulle part	collecte de données	lié au mode de collecte

2 GRANDES QUESTIONS

Où sont mes données ?

→ Sous quel format sont-elles conservées ?

FORMAT	RECUPERATION
XLS, CSV, SHP, ODS, JSON, XML, SQLITE	Pas d'étapes supplémentaires
PDF créé numériquement	Extraction des données via Tabula, ou manuellement
PDF scanné	Reconnaissance optique de caractère (OCR) ou manuellement
Papier, Photographie, Microfilm	Scanner + OCR ou manuellemenet
HTML	collecte automatisée (scraping) ou manuellement

ZOOM SUR...

LE SCRAPING

RECUPERER DES DONNEES HTML SUR INTERNET = SCRAPER

Difficulté TRES variable

Liste et caractéristiques des régions actuelles [modifier | modifier le code]

Carte	Dénomination	Chef-lieu de région	Départements
	Auvergne-Rhône-Alpes[7]	Lyon[7]	12 (+ métropole de Lyon) (Ain, Allier, Ardèche, Cantal, Drôme, Isère, Loire, Haute-Loire, Puy-de-Dôme, Rhône + Métropole de Lyon, Savoie et Haute-Savoie)
	Bourgogne-Franche-Comté[8]	Dijon[8]	8 (Côte-d'Or, Doubs, Jura, Nièvre, Haute-Saône, Saône-et-Loire, Yonne et Territoire de Belfort)
	Bretagne	Rennes[9]	4 (Côtes-d'Armor, Finistère, Ille-et-Vilaine et Morbihan)

WIKIPEDIA? IMPORTHTML
http://bit.ly/ijba2018_scraping

IKEA? SCRAPERS GRATUITS
import.io / listly.io / webscraper.io

RECUPERER DES DONNEES HTML SUR INTERNET = SCRAPER

Difficulté TRES variable

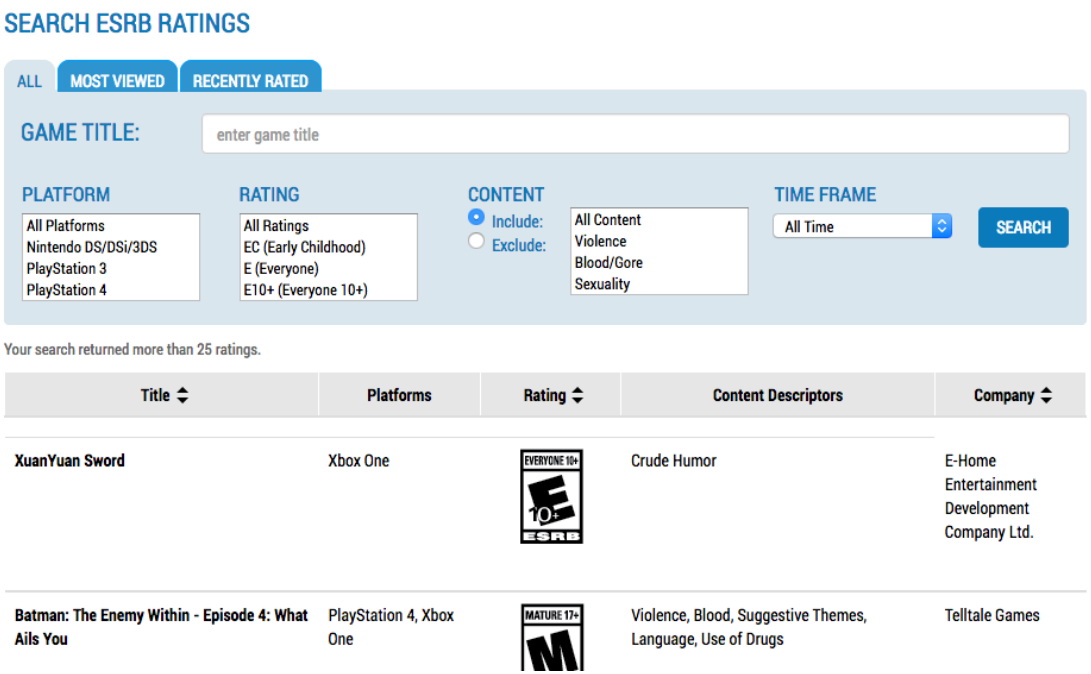

ESRB? PROGRAMMATION
scra.py, beautiful soup...

Pour comprendre comment un scraper fonctionne lit une page, il faut comprendre comment est structurée une page HTML: https://goggles.mozilla.org

ZOOM SUR...

L’EXTRACTION DE PDF

LES TABLEAUX DE DONNEES EN PDF

SI LE PDF EST NUMERIQUE
Tabula

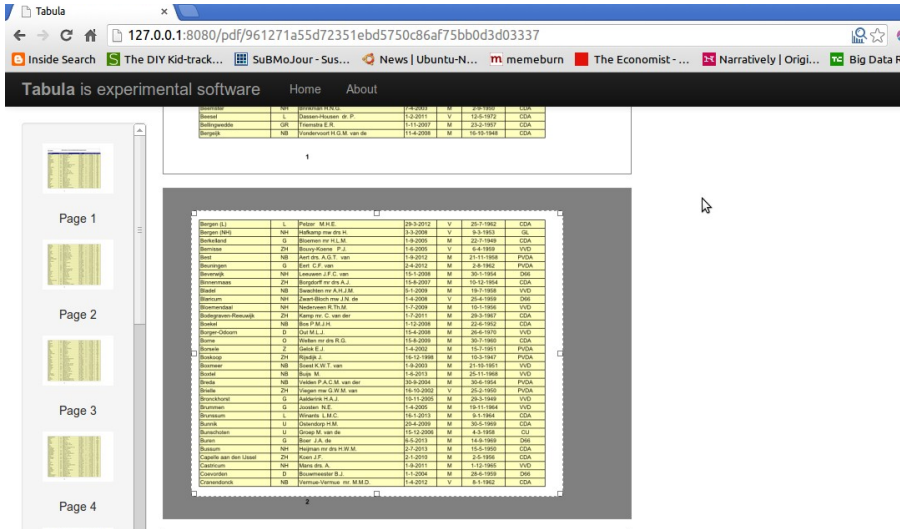

SI LE PDF EST SCANNE
OCR

ET SI...

LES DONNEES N’EXISTENT PAS

ALORS IL FAUT LES CREER!

CROWDSOURCING

8000 personnes libèrent en une semaine les données manuscrites des déclarations d'intérêts des parlementaires !

vendredi 1 août 2014

Télécharger les données brutes des déclarations d'intérêts des parlementaires numérisées par les citoyens

COLLECTE DE DONNEES SUR LE TERRAIN

OpenDataKit

magnifying human resources through technology

Collect | Scan | Sensors | Survey | Tables || Aggregate

COLLECTER SES PROPRES DONNEES N'EST PAS SIMPLE

→ Quelle méthodologie ?
→ Quelle structuration de mes données (colonnes) ?
→ Quel degré de précision ?
→ Quel niveau d'exhaustivité ?

Il vaut mieux prendre contact avec des spécialistes qui pourront vous aider à penser votre collecte (spécialistes de la statistique, de l'urbanisme…)

SCHOOL OF **DATA**

ETAPE BONUS

S’ORGANISER ET SE PROTEGER

QUELQUES REGLES SIMPLES POUR S'ORGANISER

→ Ne jamais travailler sur le fichier original, toujours sur une copie

→ Faire des copies à chaque grande étape de la transformation du fichier. Une erreur doit être facilement réparable.

→ s'assurer d'avoir des copies de sauvegarde pour tous les fichiers de travail. Hors ligne (disque dur externe) ou en ligne (Dropbox, Google Drive, Github...).

→ prendre en note les étapes de votre méthodologie, afin de pouvoir facilement revenir sur un projet ou de les partager avec des collègues.

→ si les données de votre article ne présentent pas de risques liés à la confidentialité ou la mise en danger d'autrui, pensez à les publier !

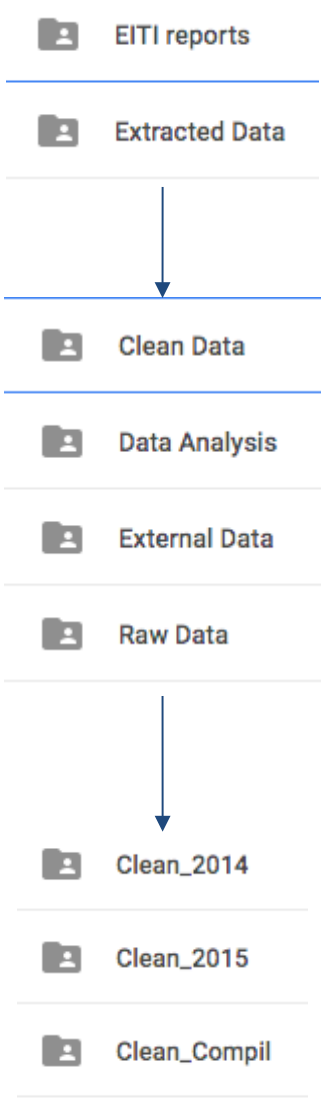

SE PROTEGER

Il est essentiel de prendre un certain nombre de précautions afin de ne pas être une proie facile pour des hackers. C'est une responsabilité de la/du journaliste envers elle/lui-même et envers ses sources.

Protéger ses outils de travail

Quoi	Comment l'utiliser
Outil de gestion de mot de passe: Dashlane, Lastpass, 1password... Vous ne devriez connaître que deux mots de passes: celui de votre ordinateur et celui de votre gestionnaire de mots de passe.	A utiliser pour générer des mots de passe aléatoires, qui peuvent aussi être utilisés pour répondre aux questions de récupération des comptes en ligne (voir pour ne jamais réutiliser le même pseudo pour les comptes en ligne).
Chiffrer son ordinateur et son téléphone. Cela permet d'empêcher quelqu'un qui a un accès physique à votre ordinateur de voler vos données	Sur Mac, il suffit d'activer FileVault. Sur Windows, il faut utiliser Bitlocker (requière une mise à niveau vers Windows 10 Pro). Pour iOS, chiffrement est par défaut. A vérifier pour les téléphones Android.

Protéger ses communications

Quoi	Comment l'utiliser
Application chiffrée de communication: Signal Messenger, Telegram, Whatsapp, Wire	A utiliser pour partager des données sensibles (idéalement chiffrées au préalable) et communiquer avec ses collègues et sources.
Email avec chiffrage intégré: ProtonMail, Mailvelope. Envoyer un email est l'équivalent d'envoyer une carte postale (particulièrement si votre destinataire utilise un fournisseur de messagerie non fiable), ou au mieux une lettre non scellée (si tous les interlocuteurs utilisent Gmail, par exemple).	Pour les occasions où il est important de communiquer par email de façon sécurisés, des outils pour envoyer des emails chiffrés sont plus sûrs, bien qu'ils demande un petit apprentissage.

Protéger ses données de travail

Quoi	Comment l'utiliser
Utiliser des archives protégées par mot de passe grâce à un utilitaire d'archive (7zip est gratuit et open source).	A utiliser pour protéger des données sensibles lorsque l'on ne travaille pas dessus ou pour les partager à un tiers de confiance.
Anonymisation des données. Permet de partager ou publier des données sans mettre en danger la vie privée des personnes mentionnées. Différentes techniques existent, du plus simple au plus complexe. C'est un équilibre entre le devoir de protection et la qualité des données (plus elles sont anonymisées, plus elles perdent en valeur pour l'analyse).	Très important de se renseigner en lisant des guides ici (cf. resources additionnelles). La façon la plus simple d'anonyiser est de retirer les informations personnelles, comme les noms. Il est aussi possible de remplacer les noms par les numéros aléatoire (cela permet de savoir combien de fois un individu apparaît dans le jeu de données, sans nécessairement savoir qui). D'autres éléments identifiants, comme l'adresse postale précise, peuvent être remplacés par des approximations (la ville ou la région).

SCHOOL OF **DATA**

QUATRIEME ETAPE

VERIFIER SES DONNEES

ETUDE DE CAS: FIVETHIRTYEIGHT

JAN. 9, 2018 AT 3:43 PM

We Used Broadband Data We Shouldn't Have — Here's What Went Wrong

By Clare Malone and Mai Nguyen

Filed under The Internet

Over the summer, FiveThirtyEight published two stories on broadband internet access in the U.S. that were based on a data set made public by academic researchers who had acquired data from Catalist, a well-known political data firm. After further reporting, we can no longer vouch for the academics' data set. The preponderance of evidence we've collected has led us to conclude that it is fundamentally flawed. That's because:

BON SENS

Another cause for concern is that the ASU/Iowa data fails some common-sense checks. **If the ASU/Iowa data were really capturing home broadband rates, we would expect the researchers' measure to be correlated with household income. But it isn't**. For example, San Francisco County's median household income is $87,701,9 but the ASU/Iowa data says only 46.6 percent of that county has home broadband. Now consider Apache County in Arizona — it has a median household income of $32,460 and a 57.4 percent home broadband rate according to the ASU/Iowa data.

DEMANDER A LA SOURCE

The ASU/Iowa researchers told us in their statement that they expected the Catalist-derived data to be consistently different from other sources of broadband data because of the difference in how it was collected. However, **the researchers said that they no longer have confidence in the data set's estimate for broadband use in Washington, D.C. "Upon further examination, Washington DC, which was highlighted by FiveThirtyEight, appeared to be an outlier in the data,"** Tolbert and Karen Mossberger, one of the researchers from ASU, said in the statement.

VERIFIER AUPRES D'EXPERTS

Steven Rosenberg, chief data officer for the FCC's wireline competition bureau, explained that the commission does collect more granular information on broadband speed and what kinds of technologies are used to deploy internet — fiber-optic cables or fixed wireless dishes, for example — but doesn't release it.

VERIFICATION STATISTIQUES BASIQUES

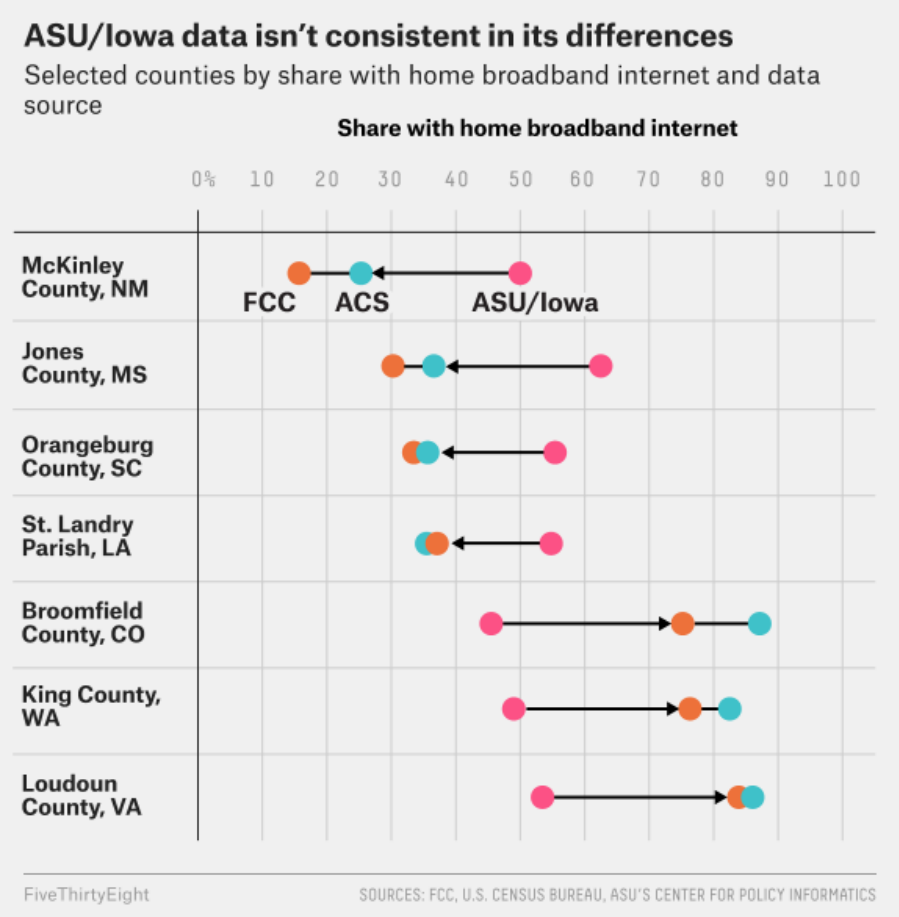

autres exemples:

- vérifier que la somme des éléments individuels correspond à la somme totale indiquée dans les données
- vérifier que les chiffres évoluent de façon prévisible (e.g. chiffres de population en croissance ou stagnation)

ET MAINTENANT, UN...

EXERCICE

TROUVER LES ERREURS DANS LES JEUX DE DONNEES FOURNIS

→ http://bit.ly/ijba2018_verif1

→ http://bit.ly/ijba2018_verif2

SCHOOL OF **DATA**

CINQUIEME ETAPE

NETTOYER SES DONNEES

TROIS GRANDES ETAPES

→ **Le toilettage**: à cheval entre la vérification et le nettoyage, permet de faire des analyse simples (tri, visualisations…). Seule la forme des données est touchée.

→ **L'édition**: ne garder que les données pertinentes pour l'analyse, et corriger les éventuels problèmes de contenu.

→ **Le rapprochement**: associer plusieurs jeux de données si nécessaire afin d'avoir un jeu de données plus complet. Peut nécessiter de refaire toute la pipeline de données.

DEUX GRANDS OUTILS

VOTRE TABLEUR FAVORI
Excel (fonctionne bien hors ligne), Google Spreadsheets (facilite la collaboration), LibreOffice (open source).

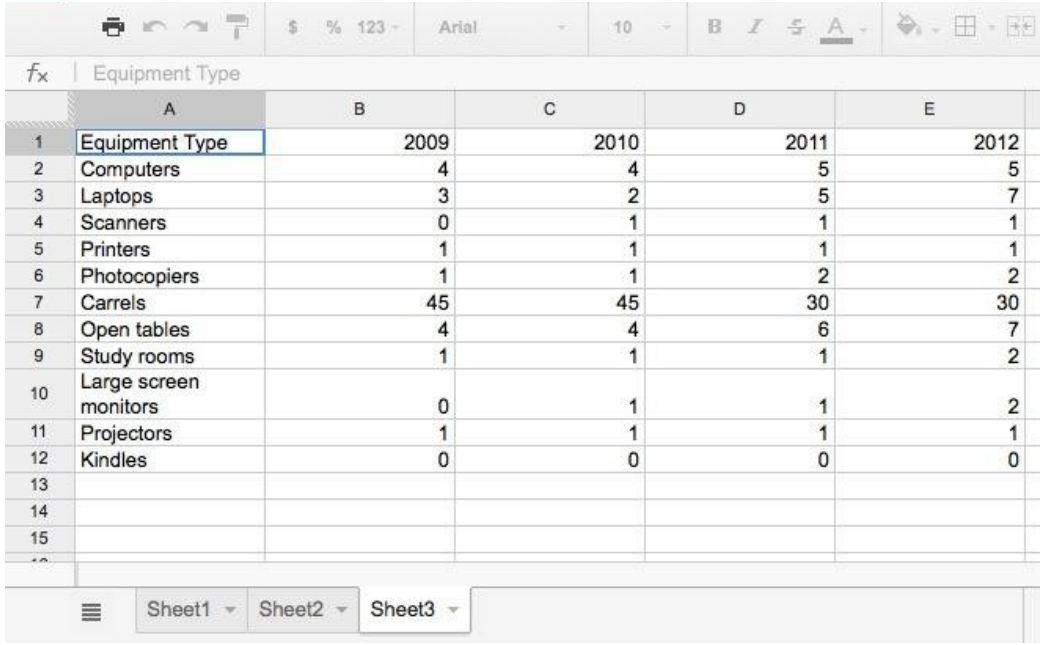

	A	B	C	D	E
1	Equipment Type	2009	2010	2011	2012
2	Computers	4	4	5	5
3	Laptops	3	2	5	7
4	Scanners	0	1	1	1
5	Printers	1	1	1	1
6	Photocopiers	1	1	2	2
7	Carrels	45	45	30	30
8	Open tables	4	4	6	7
9	Study rooms	1	1	1	2
10	Large screen monitors	0	1	1	2
11	Projectors	1	1	1	1
12	Kindles	0	0	0	0
13					
14					
15					

DEUX GRANDS OUTILS

OPENREFINE
Un outil très puissant, idéal pour des jeux de données entre 1K+ et 2-3 millions de lignes.

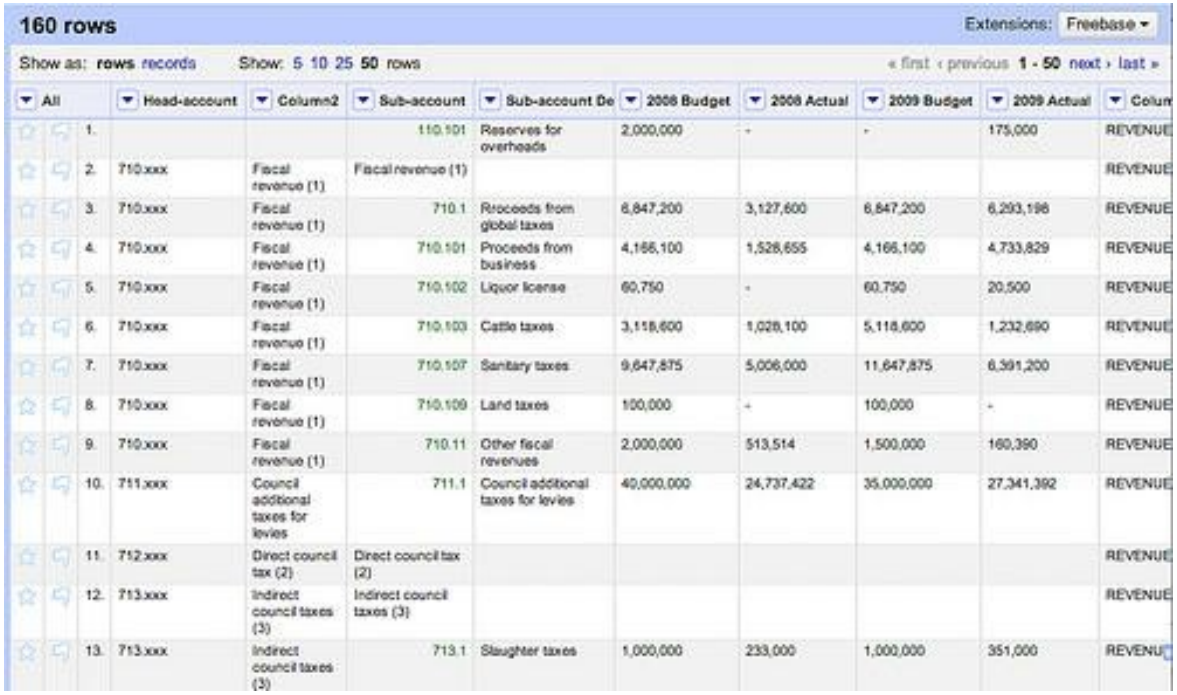

160 rows — Extensions: Freebase

Show as: rows records — Show: 5 10 25 50 rows — « first ‹ previous 1 - 50 next › last »

All		Head-account	Column2	Sub-account	Sub-account De	2008 Budget	2008 Actual	2009 Budget	2009 Actual	Colum
1.				110.101	Reserves for overheads	2,000,000	-	-	175,000	REVENUE
2.		710.xxx	Fiscal revenue (1)	Fiscal revenue (1)						REVENUE
3.		710.xxx	Fiscal revenue (1)	710.1	Proceeds from global taxes	6,847,200	3,127,600	6,847,200	6,293,198	REVENUE
4.		710.xxx	Fiscal revenue (1)	710.101	Proceeds from business	4,166,100	1,528,655	4,166,100	4,733,829	REVENUE
5.		710.xxx	Fiscal revenue (1)	710.102	Liquor license	60,750	-	60,750	20,500	REVENUE
6.		710.xxx	Fiscal revenue (1)	710.103	Cattle taxes	3,118,600	1,028,100	5,118,600	1,232,690	REVENUE
7.		710.xxx	Fiscal revenue (1)	710.107	Sanitary taxes	9,647,875	5,006,000	11,647,875	6,391,200	REVENUE
8.		710.xxx	Fiscal revenue (1)	710.109	Land taxes	100,000	-	100,000	-	REVENUE
9.		710.xxx	Fiscal revenue (1)	710.11	Other fiscal revenues	2,000,000	513,514	1,500,000	160,390	REVENUE
10.		711.xxx	Council additional taxes for levies	711.1	Council additional taxes for levies	40,000,000	24,737,422	35,000,000	27,341,392	REVENUE
11.		712.xxx	Direct council tax (2)	Direct council tax (2)						REVENUE
12.		713.xxx	Indirect council taxes (3)	Indirect council taxes (3)						REVENUE
13.		713.xxx	Indirect council taxes (3)	713.1	Slaughter taxes	1,000,000	233,000	1,000,000	351,000	REVENU

OPENREFINE VS EXCEL

	Microsoft Excel	Open Refine
Trier	X	X
Enlever les espaces en trop	X	X
Scindre les colonnes	X	X
Conversion en JSON		X
Facts		X
Requetes HTTP		X
Geocodage		X
API de réconciliation		X
Support Regex		X
Historique		X

ET MAINTENANT, UN...

TUTORIEL

TUTORIEL DE NETTOYAGE DES DONNEES

Les aides aux associations distribuées par la ville de Bordeaux en 2016

Ville de Bordeaux - Budget principal - CA 2016

ANNEXE	A

VALORISATION DES AIDES EN NATURE ACCORDEES AUX ASSOCIATIONS EN 2016	
NOM DES BENEFICIAIRES	PRESTATIONS EN NATURE CHIFFREES
"BAMBINO BERTHELOT" ASSOCIATION DE PARENTS D'ELEVES DE L'ECOLE MATERNELLE BERTHELOT A BORDEAUX	56,00
1001 JEUNES BORDELAIS	4 359,52
2AA	34,00
2SI2LA	675,00
4 CATS	400,00
9-33	20 632,00
A TRAVERS CHANT	2 791,00
A2RUNNING	631,00
ABALONE CHASSE BORDEAUX	14 561,67
ABEILLES BORDELAISES	15 042,00

→ http://bit.ly/ijba2018_cleaning1

SCHOOL OF DATA

EXERCICE GUIDE

RECUPERER, VERIFIER, NETTOYER

COMMENT FAIRE POUR...

Extraire les données de ce PDF?

Tableau G8. Cœur - Pourcentage de données manquantes du bilan médical à l'inscription pour les malades inscrits en 2013 et du bilan médical à la greffe pour les malades greffés en 2013

Equipe de greffe	Inscription		
	N	%	N
Bordeaux (A+P)	21	0,2%	15
Caen (A)	15	5,2%	10
Clermont-Ferrand (A)	22	1,2%	16
Créteil Henri Mondor (AP-HP) (A)	14	0,6%	12
Dijon (A)	17	0,0%	10
Grenoble (A)	13	2,2%	8
Le Plessis-Robinson Marie-Lannelongue (A+P)	13	2,6%	9
Lille (A+P)	19	7,4%	18
Limoges (A)	7	3,3%	5
Lyon I (HCL) (A+P)	13	0,0%	12
Lyon II (HCL) (A)	15	0,0%	13
Marseille Timone adultes (APM) (A)	35	0,7%	18
Marseille Timone enfants (APM) (A+P)	1	0,0%	2
Montpellier (A)	15	1,7%	11
Nancy (A)	14	14,0%	8
Nantes (A+P)	29	0,0%	24
Paris Bichat (AP-HP) (A)	43	31,0%	26
Paris Georges Pompidou (AP-HP) (A)	20	1,1%	11
Paris Necker Enfants Malades (AP-HP) (P)	8	7,7%	7
Paris Pitié-Salpêtrière (AP-HP) (A)	109	3,5%	90

COMMENT FAIRE POUR...

Extraire les données de cette page web?

23 et 30 mars 2014

Accueil Municipales 2014 > Résultats France entière

Résultats du 2d tour

	Scrutin Majoritaire	Scrutin de Listes	Tous Scrutins	% Inscrits	% Votants
Inscrits	1 409 419	16 927 388	18 336 807		
Abstentions	379 026	6 564 291	6 943 317	37,87	
Votants	1 030 393	10 363 097	11 393 490	62,13	
Blancs ou nuls	48 153	358 908	407 061	2,22	3,57
Exprimés	982 240	10 004 189	10 986 429	59,91	96,43

COMMENT FAIRE POUR...

Utiliser cette API pour comparer les “Andrea” de France et d’Italie ?

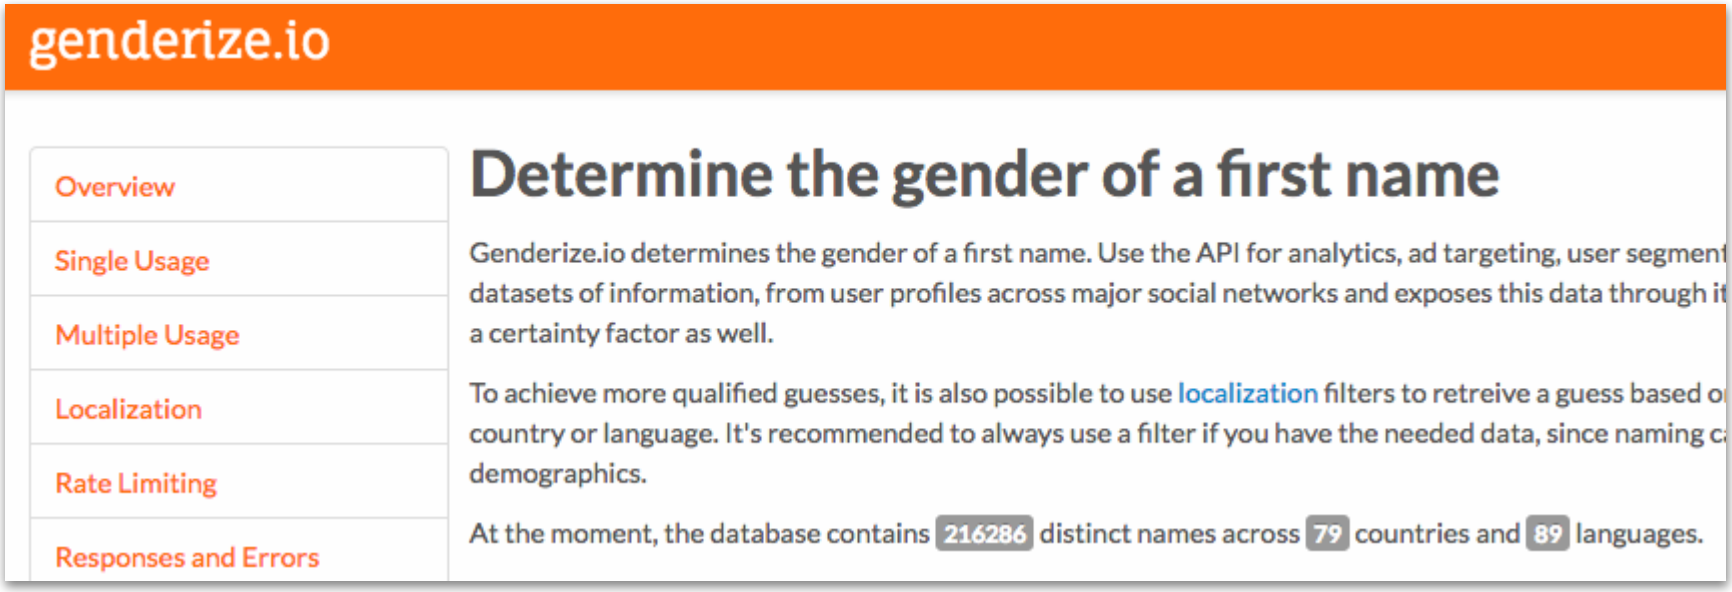

COMMENT FAIRE POUR...

Créer une carte des terrains de sports de Bordeaux ?

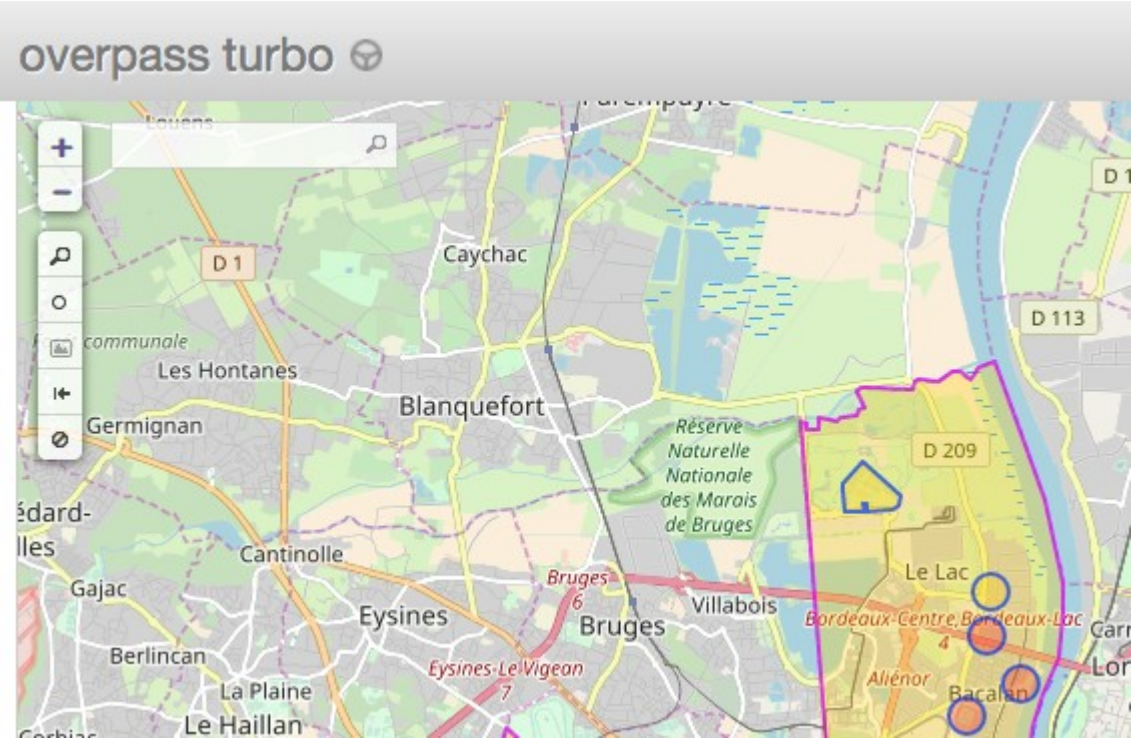

ET MAINTENANT, UN...

EXERCICE

DEUX GROUPES

L’activité des représentants des français de l’étranger

Epidémie de rougeole: La France et l’Aquitaine sont-elles à risque ?

RESSOURCES ADDITIONNELLES

Formats de fichiers

http://opendatahandbook.org/guide/fr/appendices/file-formats/
https://www.europeandataportal.eu/elearning/fr/module9/#/id/co-01

Collecter des données

bit.ly/mobiledatacollection

Vérifier ses données

https://github.com/Quartz/bad-data-guide

Chiffrer son disque dur

https://progresser-en-informatique.com/chiffrer-ordinateur-avec-bitlocker/
https://support.apple.com/fr-ch/HT204837

RESSOURCES ADDITIONNELLES

Anonymiser ses données

- https://theodi.org/guides/save-the-titanic-handson-anonymisation-and-risk-control-of-publishing-open-data
- http://theodi.github.io/ukan-course/assets/odi-data-anonymization.pdf

Tutoriels Excel pour journalistes

http://www.joelmatriche.com/?p=295

Solutions exerices de vérification

- http://bit.ly/ijba2018_verif3
  https://github.com/Quartz/bad-data-guide

Article source de Fivethirtyeight

- https://fivethirtyeight.com/features/we-used-broadband-data-we-shouldnt-have-heres-what-went-wrong/

RESSOURCES ADDITIONNELLES

Explorer des APIs

- Open Street Map: http://overpass-turbo.eu/
- data.gouv.fr https://www.data.gouv.fr/fr/apidoc/
- Banque Mondiale: https://datahelpdesk.worldbank.org/knowledgebase/articles/898581-api-basic-call-structure
- Genderize: https://genderize.io
- Base de données SIRENE: https://data.opendatasoft.com/explore/dataset/sirene%40public/api/

A SUIVRE...

(N’hésitez pas à poser des questions!)