SCHOOL OF **DATA**

INTRODUCTION AU NETTOYAGE DE DONNEES

I. RAPPEL : LA DATA PIPELINE

II. QU’EST-CE QU’UNE DONNEE

III. LA VERIFICATION

IV. LE NETTOYAGE

V. LES OUTILS

SCHOOL OF **DATA**

LA DATA PIPELINE

QUELQUES RAPPELS

7 GRANDES ETAPES
valable pour tout type de projet, de la brève sur le vote du budget municipal à l'enquête internationale sur l'évasion fiscale

TRAVAIL SOUVENT NON LINEAIRE
aller-retour entre étapes, répétition des étapes pour plusieurs jeux de données…)

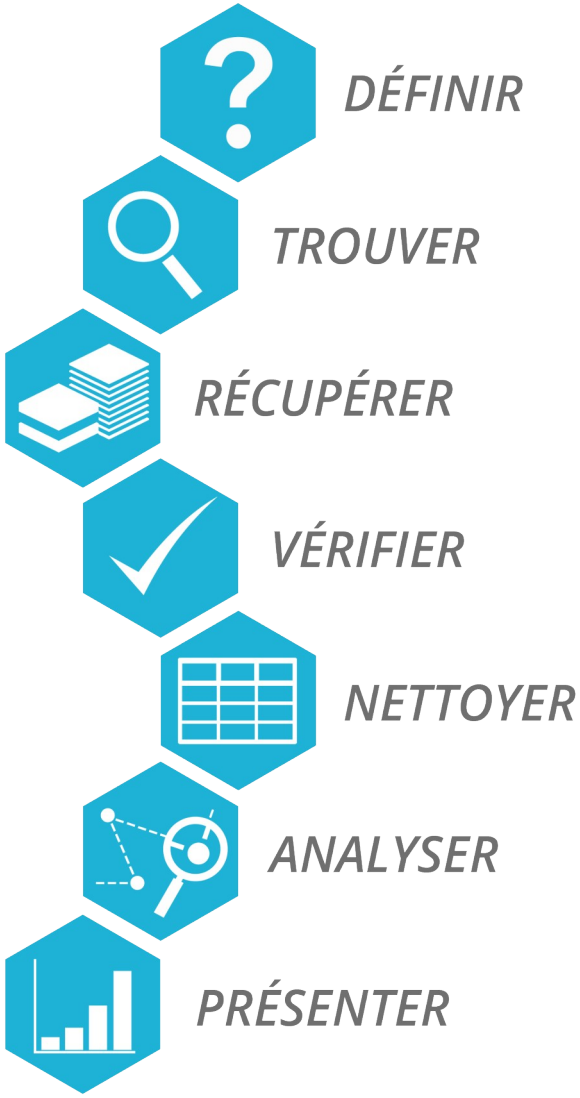

CE QUE VOUS AVEZ DEJA VU

Qu’est-ce que l’open data ?
Définir son projet d’enquête
Trouver les sources de données
Récupérer les données

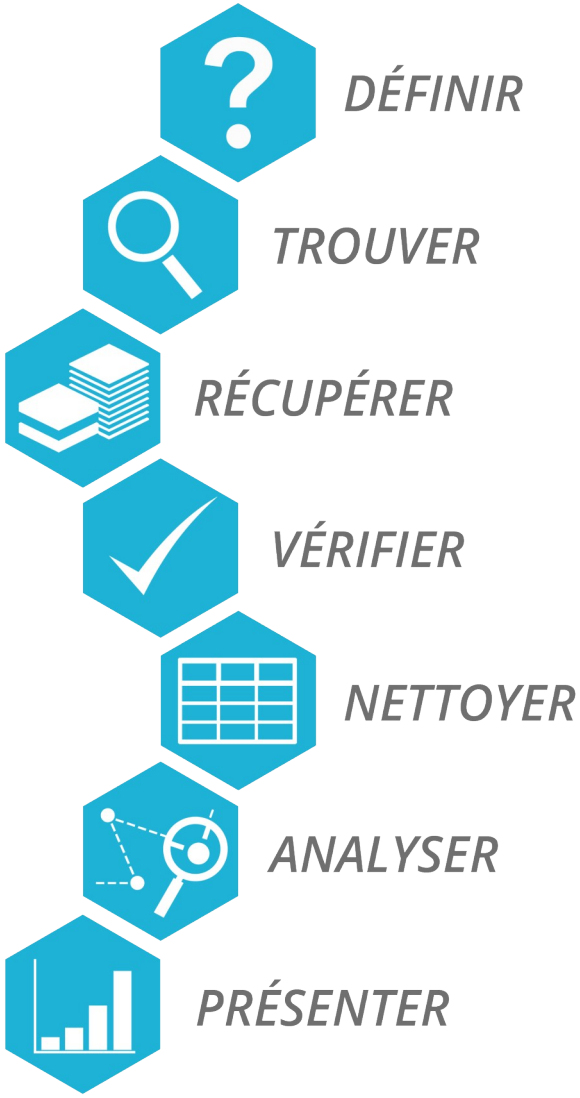

CE QUE VOUS AVEZ DEJA VU

Qu’est-ce que l’open data ?
loi d’accès aux documents publics (1978)
Loi pour une république numérique (2016)
open data par défaut (octobre 2018)

Définir son projet d’enquête
Choisir une problématique
Définit des hypothèses

Trouver les sources de données
portails open data
recherches google
experts / producteurs

Récupérer les données
où sont-elles
sous quel format
dois-je les transformer?

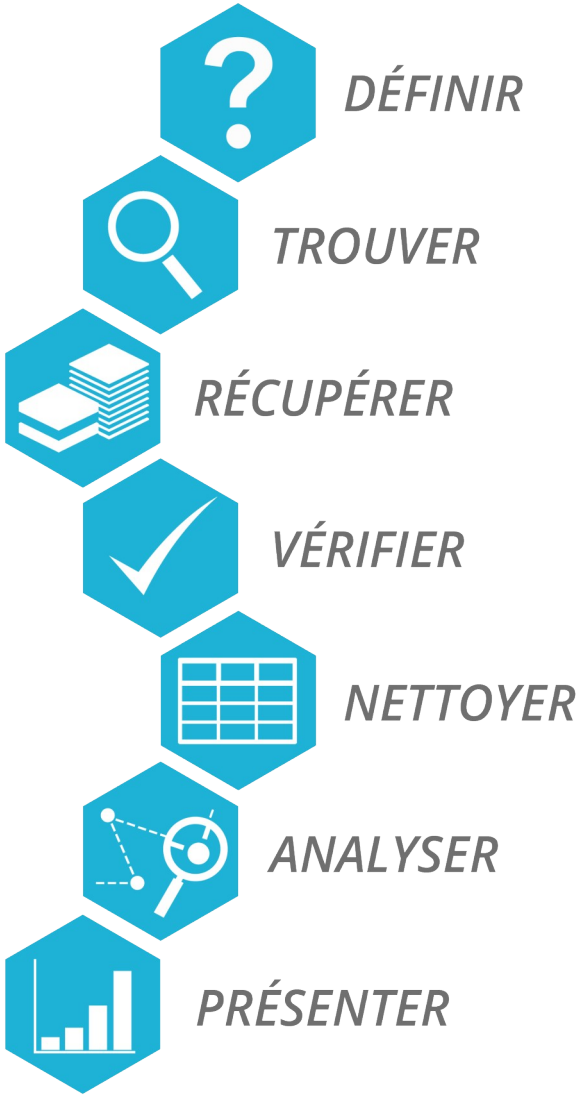

LOCALISATION	RECUPERATION	FORMATS
Portail open data	Téléchargement	xls, csv, shp, pdf, ods, json, xml, sqlite
Dans le système informatique d'une administration ou d'une entitée privée (non publiées en ligne)	Demande d'accès	xls, csv, shp, pdf, ods, json, xml, sqlite (et bien pire…)
Dans les archives physiques d'une administration ou d'une entitée privée	Demande d'accès	papier, photos (!), microfilm (!?!),
Derrière une interface de programmation applicative (API)	En bidouillant un peu de code informatique	csv, json, xml
En libre accès sur le web	en fonction du format	html, pdf (ou tout autre format en existence)
Nulle part	collecte de données	lié au mode de collecte

FORMAT	RECUPERATION
XLS, CSV, SHP, ODS, JSON, XML, SQLITE	Pas d’étapes supplémentaires
PDF créé numériquement	Extraction des données via Tabula, ou manuellement
PDF scanné	Reconnaissance optique de caractère (OCR) ou manuellement
Papier, Photographie, Microfilm	Scanner + OCR ou manuellemenet
HTML	collecte automatisée (scraping) ou manuellement

EXEMPLE: DOSSIER MATERNITÉS DU MONDE

Problématique: Sur quel critère choisir une maternité lorsque l'on est enceinte ? Y a-t-il des profils type d'établissements ?

Hypothèse supposée : certains établissements se distinguent par un taux de médicalisation de l'acte plus fort (césarienne…)

Recherche de données : enquête nationale périnatale, base statistique annuelle des établissements de santé (SAE), l'Agence technique de l'information hospitalière (ATIH) et la Fédération française de recherche en santé périnatale (FFRSP)

Problèmes avec les données :
fiabilité: données aberrantes, encodage non standardisé
exhaustivité: actes non encodés

LES DÉCODEURS

Césarienne, épisiotomie… enquête sur la médicalisation de l'accouchement en France

Les statistiques des maternités en 2016 montrent que les interventions dites « techniques » sont loin d'être limitées.

CE QUE L'ON VA VOIR AUJOURD'HUI

- ➔ Méthodes de vérification
- ➔ Nettoyage de données tabulaires

SCHOOL OF **DATA**

MAIS AU FAIT

QU’EST-CE QU’UNE DONNEE ?

Qu’est-ce qu’une donnée ?

Qu’est-ce qu’une donnée ?

Une représentation structurée du monde

Une représentation structurée du monde

Une représentation structurée du monde

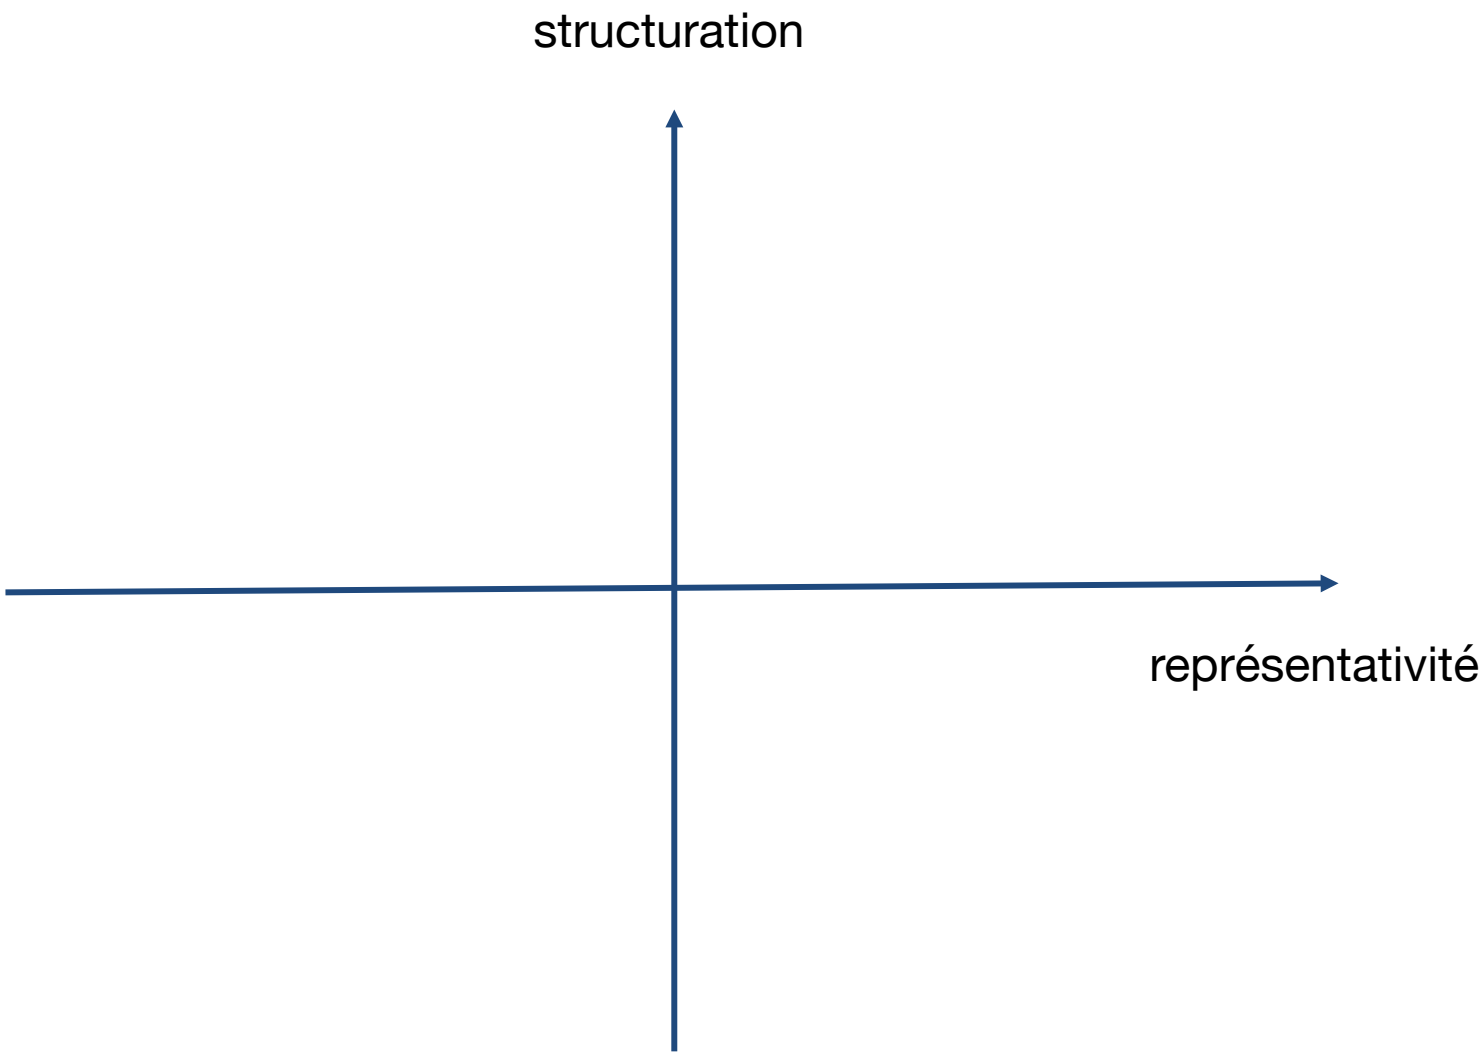
structuration
représentativité

représentativité

données mal encodées (qualité)

bonnes données

structuration

hallucinations

données falsifiées ou erronées (fiabilité / exhaustivité)

données mal encodées

Tableau 1 : Importations de véhicules en Côte d'Ivoire sur la période 2017-2018

Mois	Type	Nombre	
		2017	2018
Juillet	Neufs	793	993
	Usagés	4482	4682
Août	Neufs	609	809
	Usagés	1477	1677
Septembre	Neufs	583	783
	Usagés	738	938
Octobre	Neufs	739	939
	Usagés	515	715
Novembre	Neufs	664	864
	Usagés	539	739

Source : Rapport 2018

bonnes données

Mois	Type	Nombre	Année
Juillet	Neufs	793	2017
Juillet	Neufs	993	2018
Juillet	Usagés	4482	2018
Juillet	Usagés	4682	2018
Août	Neufs	609	2017
Août	Neufs	809	2018
Août	Usagés	1477	2017
Août	Usagés	1677	2018
Septembre	Neufs	583	2017
Septembre	Neufs	783	2018
Septembre	Usagés	738	2017
Septembre	Usagés	938	2018
Octobre	Neufs	739	2017
Octobre	Neufs	939	2018
Octobre	Usagés	515	2017
Octobre	Usagés	715	2018

données falsifiées ou erronées

Que signifie “Neufs” ?

Mois	Type	Nombre	Année
Juillet	Neufs	793	2017
Juillet	Neufs	993	2018
Juillet	Usagés	4482	2018
Juillet	Usagés	4682	2018
Août	Neufs	609	2017
Août	Neufs	809	2018
Août	Usagés	1477	2017
Août	Usagés	1677	2018
Septembre	Neufs	583	2017
Septembre	Neufs	783	2018
Septembre	Usagés	738	2017
Septembre	Usagés	938	2018
Octobre	Neufs	739	2017
Octobre	Neufs	939	2018
Octobre	Usagés	515	2017
Octobre	Usagés	715	2018

hallucinations

Tableau 1 : Importations de véhicules en Côte d'Ivoire sur la période 2017-2018

Mois	Type	Nombre	
		2017	2018
Juillet	Neufs	0	110,5
	Usagés	1	2
Août	Neufs	-5	4
	Usagés	2	7
Septembre	Neufs	0	9
	Usagés	1	6
Octobre	Neufs	-5	2
	Usagés	2	2
Novembre	Neufs	5	210,7
	Usagés	4	-20

Source : Rapport 2018

SCHOOL OF **DATA**

ON REVIENT DONC VERS

LA VERIFICATION

VERIFICATION: 3 ENJEUX

Fiabilité

Exhaustivité

Qualité

Vérification: 3 enjeux

FIABILITE: les données représentent-elles la réalité ?

Exhaustivité

Qualité

« par exemple, un taux d'épisiotomie plus élevé chez les multipares que chez les primipares, des taux d'épisiotomie à moins de 1 % ou à plus de 60 % (source: Le Monde) »

Vérification: 3 enjeux

Fiabilité

EXHAUSTIVITE: les données sont-elles complètes ?

Qualité

« **tous les actes ne disposent pas d'un code spécifique**, et même parmi ceux qui en ont, certains, non « tarifés », **ne sont pas systématiquement saisis** par les soignants, à l'image de l'épisiotomie. (source: Le Monde) »

Vérification: 3 enjeux

Fiabilité

Exhaustivité

QUALITE: Les données sont-elles structurées et documentées correctement ?

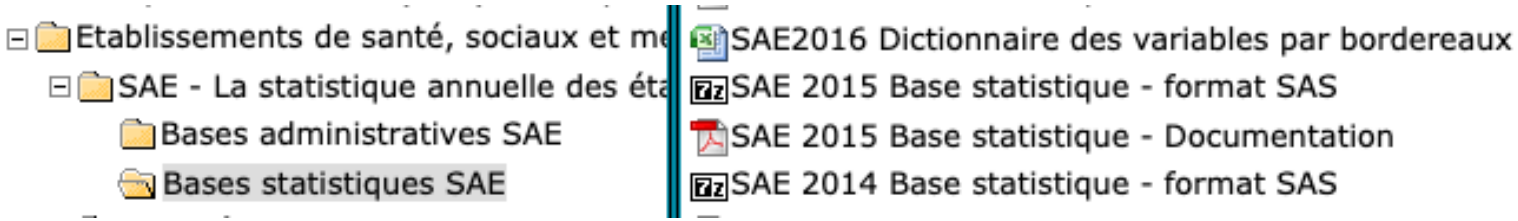

BOR	AN	FI	FI_EJ	BIO_A1	BIO_A2	BIO_A3	BIO_A4	BIO_A5	BIO_A6	BIO_A7	BIO_A8	BIO_A9	BIO_A10	BIO_A11	BIO_A12	BIO_A13	BIO_A14	BIO_A15	BIO_A16	BIO_A17	BIO_A18	BIO_B1	BIO_B2	BIO_B3
BIO	2017	010000024	010780054	1	1	0	1	1	0	0	1	0	0	1	1	1	1	0	0	0	0	0	842413	46807
BIO	2017	010005239	010008407	1	0	0	1	1	1	0	0	0	0	1	1	0	0	0	0	0	0	1	287872	33034
BIO	2017	020000162	020000063	1	1	0	1	1	0	0	1	0	0	1	1	1	0	0	0	0	0	1	941991	34002
BIO	2017	020000394	020000253	1	1	0	1	1	1	1	1	0	0	1	1	1	0	0	0	0	0	1	966398	139529
BIO	2017	020000519	020000261	1	1	0	1	1	1	1	1	0	0	1	1	1	1	0	0	1	1	1	738092	64676
BIO	2017	020000535	020000287	1	1	0	1	1	1	0	0	0	0	0	0	1	1	0	0	0	0	1	467262	2516
BIO	2017	020001061	020004404	1	1	0	1	1	1	0	0	0	0	1	1	1	0	0	0	0	0	0	613385	209591

VERIFICATION: 4 méthodes

Demander à la source

Demander aux experts

Vérifications statistiques

Bon sens

SCHOOL OF **DATA**

NOUS VOILA ENFIN AU

NETTOYAGE

3 TYPES DE NETTOYAGE

Toilettage

Edition

Rapprochement

3 types de nettoyage

TOILETTAGE

Edition

Rapprochement

Préparer les données à la vérification ou l'analyse, sans toucher au contenu : **nettoyage de la structure des données**.

3 types de nettoyage

Toilettage

EDITION

Rapprochement

Préparer les données à l'analyse, en corrigeant les problèmes et/ou en enlevant le superflu: **nettoyage du contenu des données**

3 types de nettoyage

Toilettage

Edition

RAPPROCHEMENT

Préparer les données à l'analyse, en les **fusionnant avec des données additionnelles** qui rajoutent du contexte ou de la précision

SCHOOL OF **DATA**

REGARDONS MAINTENANT

LES OUTILS

DEUX GRANDS OUTILS

VOTRE TABLEUR FAVORI
Excel (fonctionne bien hors ligne), Google Spreadsheets (facilite la collaboration), LibreOffice (open source).

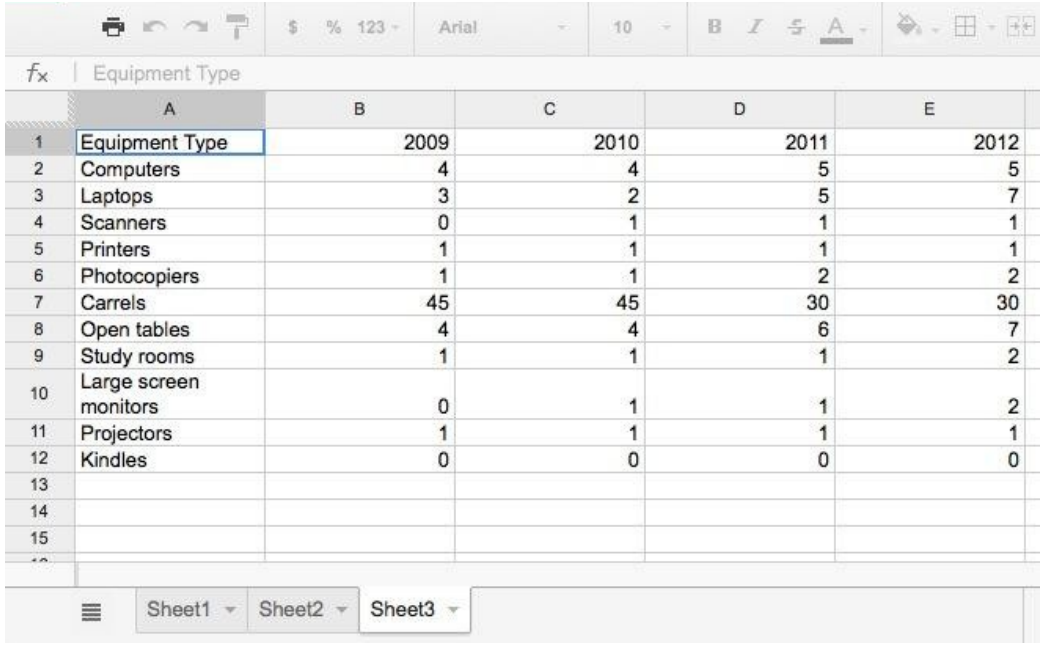

	A	B	C	D	E
1	Equipment Type	2009	2010	2011	2012
2	Computers	4	4	5	5
3	Laptops	3	2	5	7
4	Scanners	0	1	1	1
5	Printers	1	1	1	1
6	Photocopiers	1	1	2	2
7	Carrels	45	45	30	30
8	Open tables	4	4	6	7
9	Study rooms	1	1	1	2
10	Large screen monitors	0	1	1	2
11	Projectors	1	1	1	1
12	Kindles	0	0	0	0
13					
14					
15					

DEUX GRANDS OUTILS

OPENREFINE
Un outil très puissant, idéal pour des jeux de données entre 1K+ et 2-3 millions de lignes.

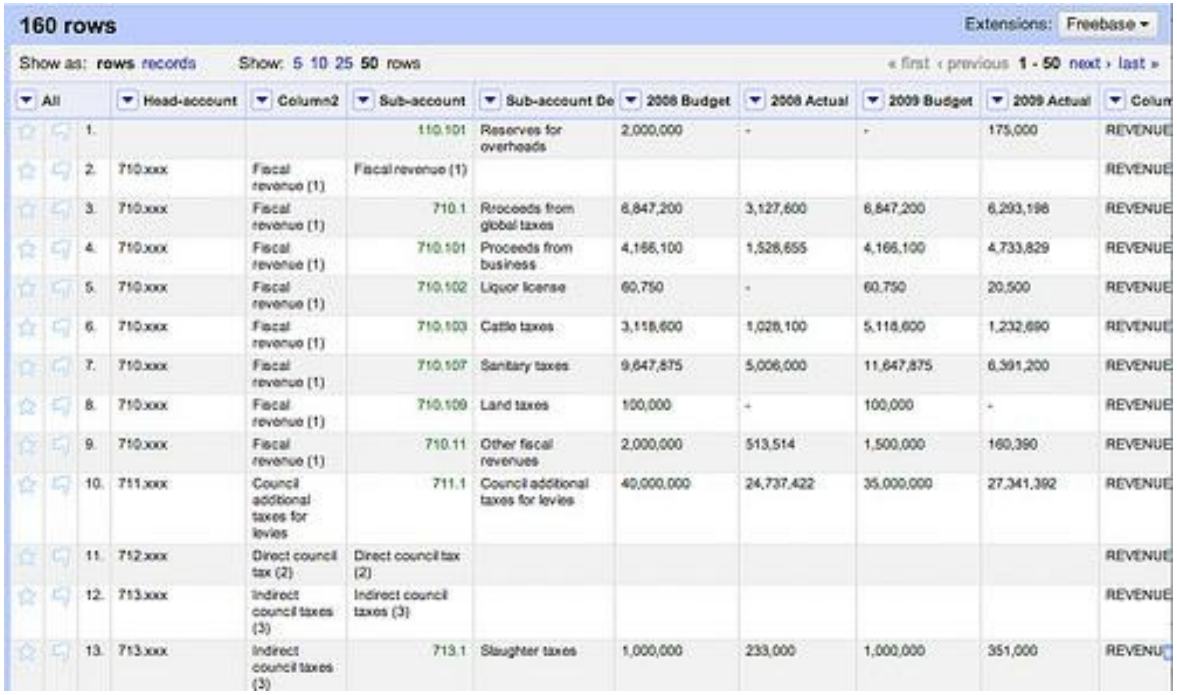

160 rows — Extensions: Freebase

Show as: rows records — Show: 5 10 25 50 rows — « first ‹ previous 1 - 50 next › last »

All		Head-account	Column2	Sub-account	Sub-account De	2008 Budget	2008 Actual	2009 Budget	2009 Actual	Colum
1.				110.101	Reserves for overheads	2,000,000	-	-	175,000	REVENUE
2.		710.xxx	Fiscal revenue (1)	Fiscal revenue (1)						REVENUE
3.		710.xxx	Fiscal revenue (1)	710.1	Proceeds from global taxes	6,847,200	3,127,600	6,847,200	6,293,198	REVENUE
4.		710.xxx	Fiscal revenue (1)	710.101	Proceeds from business	4,166,100	1,528,655	4,166,100	4,733,829	REVENUE
5.		710.xxx	Fiscal revenue (1)	710.102	Liquor license	60,750	-	60,750	20,500	REVENUE
6.		710.xxx	Fiscal revenue (1)	710.103	Cattle taxes	3,118,600	1,028,100	5,118,600	1,232,690	REVENUE
7.		710.xxx	Fiscal revenue (1)	710.107	Sanitary taxes	9,647,875	5,006,000	11,647,875	6,391,200	REVENUE
8.		710.xxx	Fiscal revenue (1)	710.109	Land taxes	100,000	-	100,000	-	REVENUE
9.		710.xxx	Fiscal revenue (1)	710.11	Other fiscal revenues	2,000,000	513,514	1,500,000	160,390	REVENUE
10.		711.xxx	Council additional taxes for levies	711.1	Council additional taxes for levies	40,000,000	24,737,422	35,000,000	27,341,392	REVENUE
11.		712.xxx	Direct council tax (2)	Direct council tax (2)						REVENUE
12.		713.xxx	Indirect council taxes (3)	Indirect council taxes (3)						REVENUE
13.		713.xxx	Indirect council taxes (3)	713.1	Slaughter taxes	1,000,000	233,000	1,000,000	351,000	REVENU

OPENREFINE VS EXCEL

	Microsoft Excel	Open Refine
Trier	X	X
Enlever les espaces en trop	X	X
Scindre les colonnes	X	X
Conversion en JSON		X
Facts		X
Requetes HTTP		X
Geocodage		X
API de réconciliation		X
Support Regex		X
Historique		X

SCHOOL OF **DATA**

ALLEZ, UN PETIT

EXERCICE

EXERCICE 1: IMPORTATION DE VOITURES

Les importations de voiture en Côte d'Ivoire en 2017 et 2018

EXERCICE 2: LES AIDES AUX ASSOCIATIONS

Les aides aux associations distribuées par la ville de Bordeaux en 2016

Ville de Bordeaux - Budget principal - CA 2016

ANNEXE	A

VALORISATION DES AIDES EN NATURE ACCORDEES AUX ASSOCIATIONS EN 2016	
NOM DES BENEFICIAIRES	PRESTATIONS EN NATURE CHIFFREES
"BAMBINO BERTHELOT" ASSOCIATION DE PARENTS D'ELEVES DE L'ECOLE MATERNELLE BERTHELOT A BORDEAUX	56,00
1001 JEUNES BORDELAIS	4 359,52
2AA	34,00
2SI2LA	675,00
4 CATS	400,00
9-33	20 632,00
A TRAVERS CHANT	2 791,00
A2RUNNING	631,00
ABALONE CHASSE BORDEAUX	14 561,67
ABEILLES BORDELAISES	15 042,00

→ http://bit.ly/ijba2018_cleaning1

EXERCICE 3: LES AIDES AUX ASSOCIATIONS (OPEN REFINE)

Les aides aux associations distribuées par la ville de Bordeaux en 2017

→ http://bit.ly/ijba2018_cleaning1

A SUIVRE...

(N’hésitez pas à poser des questions!)