SCHOOL OF **DATA**

INTRODUCTION AU NETTOYAGE DE DONNÉES

I. RAPPEL : LA DATA PIPELINE

II. QU’EST-CE QU’UNE DONNEE

III. LA VERIFICATION

IV. LE NETTOYAGE

V. LES OUTILS

SCHOOL OF **DATA**

LA DATA PIPELINE

QUELQUES RAPPELS

7 GRANDES ETAPES
valable pour tout type de projet, de la brève sur le vote du budget municipal à l'enquête internationale sur l'évasion fiscale

TRAVAIL SOUVENT NON LINEAIRE
aller-retour entre étapes, répétition des étapes pour plusieurs jeux de données…)

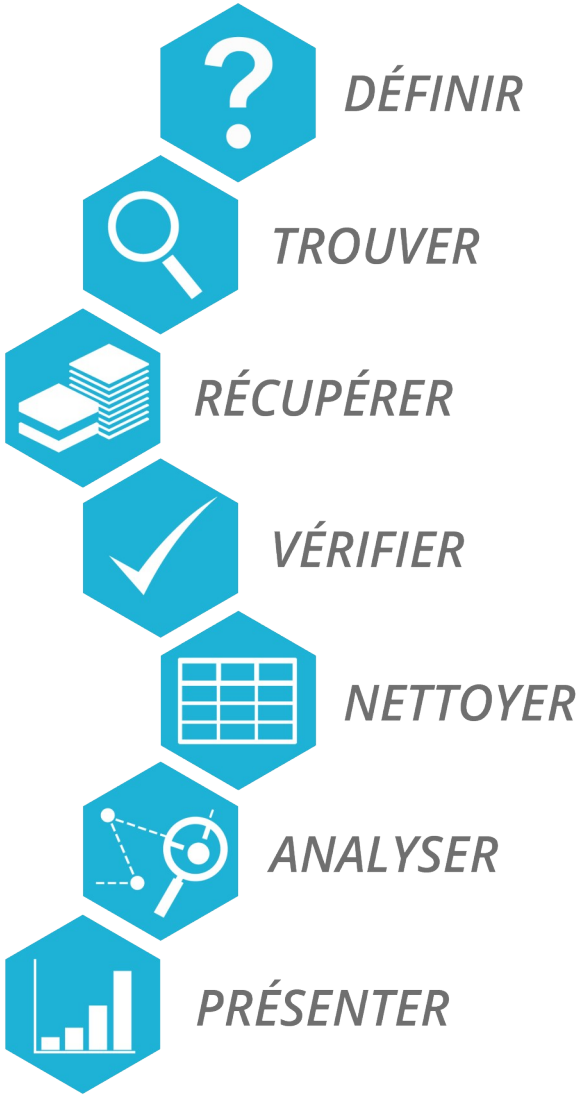

CE QUE VOUS AVEZ DÉJÀ VU

Qu’est-ce que l’open data ?
Définir son projet d’enquête
Trouver les sources de données
Récupérer les données

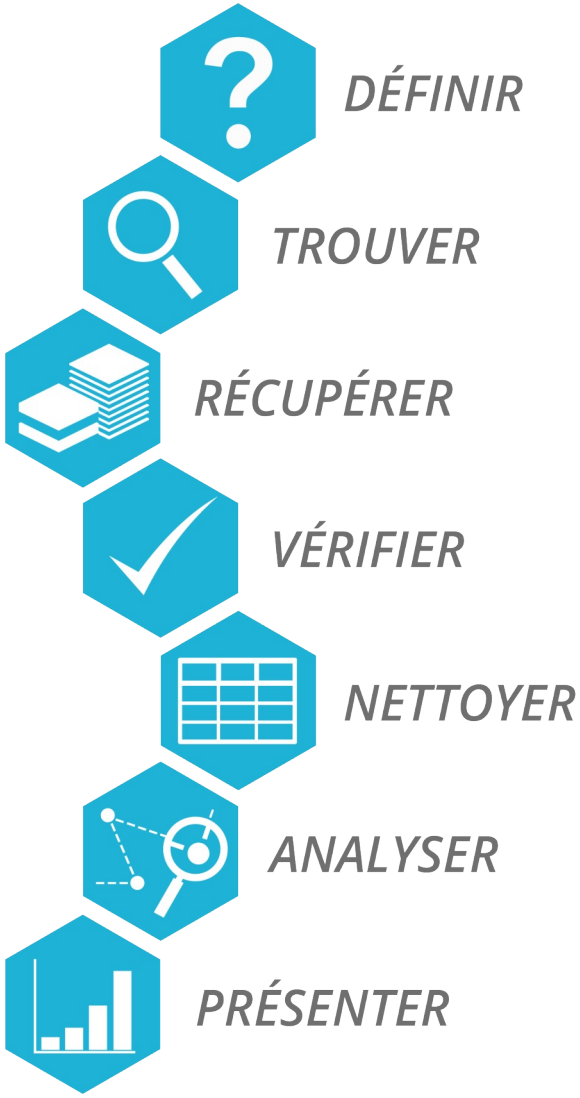

EXEMPLE: DOSSIER MATERNITÉS DU MONDE

Problématique: Sur quel critère choisir une maternité lorsque l'on est enceinte ? Y a-t-il des profils type d'établissements ?

Hypothèse supposée : certains établissements se distinguent par un taux de médicalisation de l'acte plus fort (césarienne…)

Recherche de données : enquête nationale périnatale, base statistique annuelle des établissements de santé (SAE), l'Agence technique de l'information hospitalière (ATIH) et la Fédération française de recherche en santé périnatale (FFRSP)

Problèmes avec les données :
fiabilité: données aberrantes, encodage non standardisé
exhaustivité: actes non encodés

LES DÉCODEURS

Césarienne, épisiotomie… enquête sur la médicalisation de l'accouchement en France

Les statistiques des maternités en 2016 montrent que les interventions dites « techniques » sont loin d'être limitées.

CE QUE L'ON VA VOIR AUJOURD'HUI

- ➔ Méthodes de vérification
- ➔ Nettoyage de données tabulaires

SCHOOL OF **DATA**

MAIS AU FAIT

QU’EST-CE QU’UNE DONNEE ?

Qu’est-ce qu’une donnée ?

Qu’est-ce qu’une donnée ?

Une représentation structurée du monde

Une représentation structurée du monde

Une représentation structurée du monde

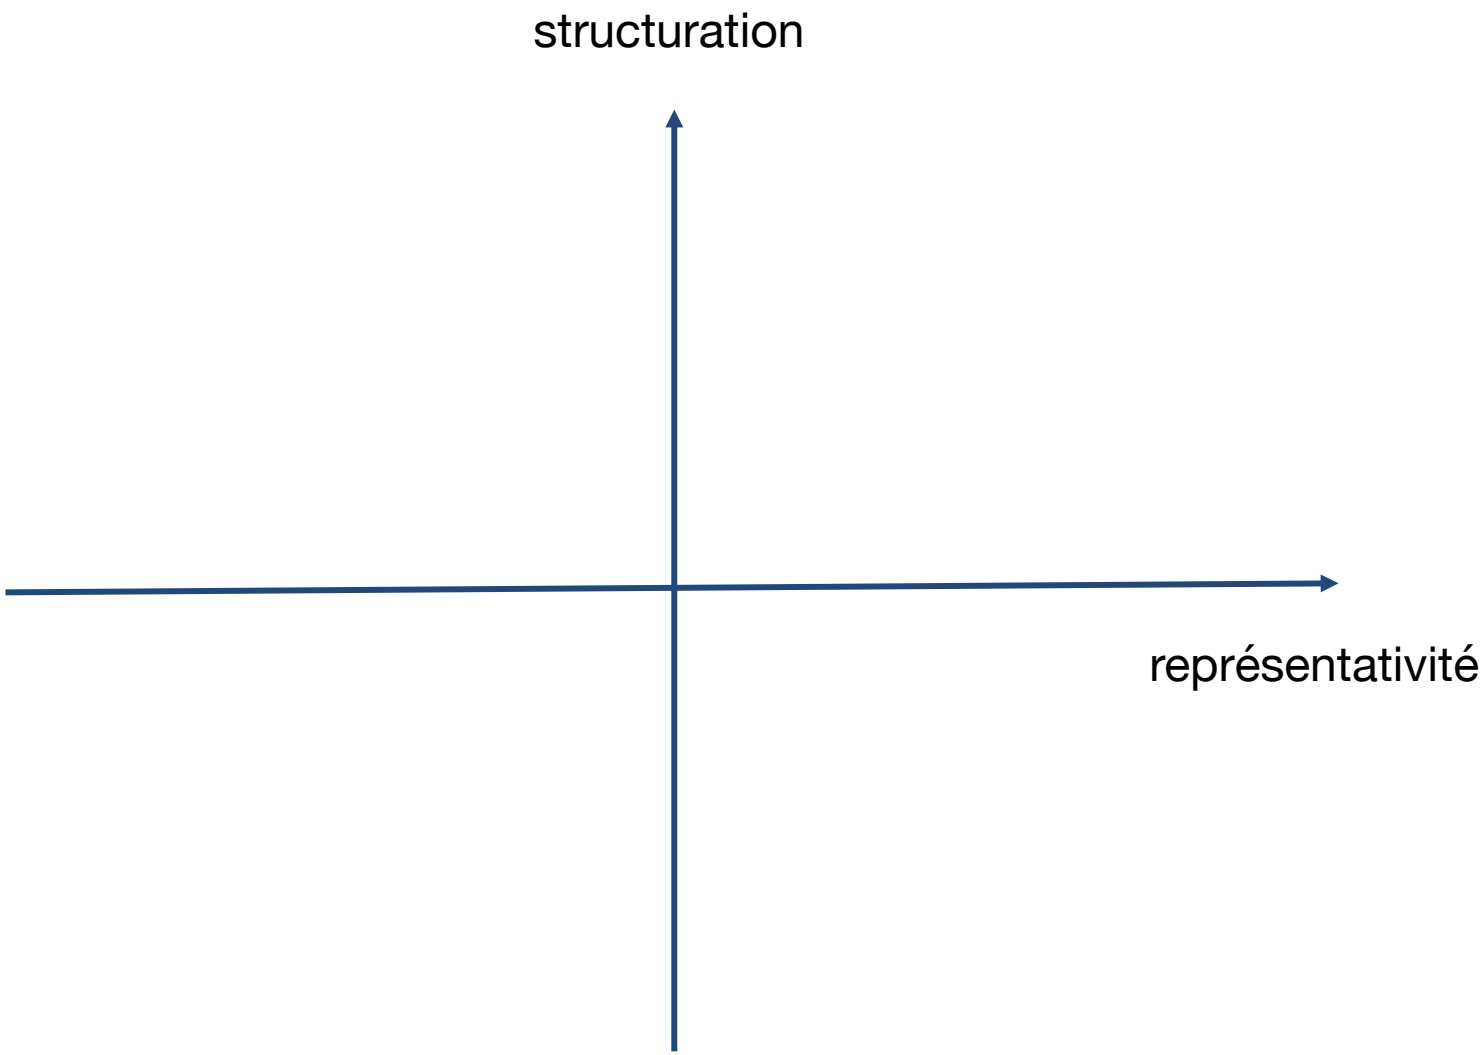
structuration
représentativité

représentativité

données mal encodées (qualité)

bonnes données

structuration

hallucinations

données falsifiées ou erronées (fiabilité / exhaustivité)

données mal encodées

Tableau 1 : Importations de véhicules en Côte d'Ivoire sur la période 2017-2018

Mois	Type	Nombre	
		2017	2018
Juillet	Neufs	793	993
	Usagés	4482	4682
Août	Neufs	609	809
	Usagés	1477	1677
Septembre	Neufs	583	783
	Usagés	738	938
Octobre	Neufs	739	939
	Usagés	515	715
Novembre	Neufs	664	864
	Usagés	539	739

Source : Rapport 2018

bonnes données

Mois	Type	Nombre	Année
Juillet	Neufs	793	2017
Juillet	Neufs	993	2018
Juillet	Usagés	4482	2018
Juillet	Usagés	4682	2018
Août	Neufs	609	2017
Août	Neufs	809	2018
Août	Usagés	1477	2017
Août	Usagés	1677	2018
Septembre	Neufs	583	2017
Septembre	Neufs	783	2018
Septembre	Usagés	738	2017
Septembre	Usagés	938	2018
Octobre	Neufs	739	2017
Octobre	Neufs	939	2018
Octobre	Usagés	515	2017
Octobre	Usagés	715	2018

données falsifiées ou erronées

Que signifie “Neufs” ?

Mois	Type	Nombre	Année
Juillet	Neufs	793	2017
Juillet	Neufs	993	2018
Juillet	Usagés	4482	2018
Juillet	Usagés	4682	2018
Août	Neufs	609	2017
Août	Neufs	809	2018
Août	Usagés	1477	2017
Août	Usagés	1677	2018
Septembre	Neufs	583	2017
Septembre	Neufs	783	2018
Septembre	Usagés	738	2017
Septembre	Usagés	938	2018
Octobre	Neufs	739	2017
Octobre	Neufs	939	2018
Octobre	Usagés	515	2017
Octobre	Usagés	715	2018

hallucinations

Tableau 1 : Importations de véhicules en Côte d'Ivoire sur la période 2017-2018

Mois	Type	Nombre	
		2017	2018
Juillet	Neufs	0	110,5
	Usagés	1	2
Août	Neufs	-5	4
	Usagés	2	7
Septembre	Neufs	0	9
	Usagés	1	6
Octobre	Neufs	-5	2
	Usagés	2	2
Novembre	Neufs	5	210,7
	Usagés	4	-20

Source : Rapport 2018

SCHOOL OF **DATA**

ON REVIENT DONC VERS

LA VERIFICATION

VERIFICATION: 3 ENJEUX

Fiabilité

Exhaustivité

Qualité

Vérification: 3 enjeux

FIABILITE: les données représentent-elles la réalité ?

Exhaustivité

Qualité

« par exemple, un taux d'épisiotomie plus élevé chez les multipares que chez les primipares, des taux d'épisiotomie à moins de 1 % ou à plus de 60 % (source: Le Monde) »

Vérification: 3 enjeux

Fiabilité

EXHAUSTIVITE: les données sont-elles complètes ?

Qualité

« **tous les actes ne disposent pas d'un code spécifique**, et même parmi ceux qui en ont, certains, non « tarifés », **ne sont pas systématiquement saisis** par les soignants, à l'image de l'épisiotomie. (source: Le Monde) »

Vérification: 3 enjeux

Fiabilité

Exhaustivité

QUALITE: Les données sont-elles structurées et documentées correctement ?

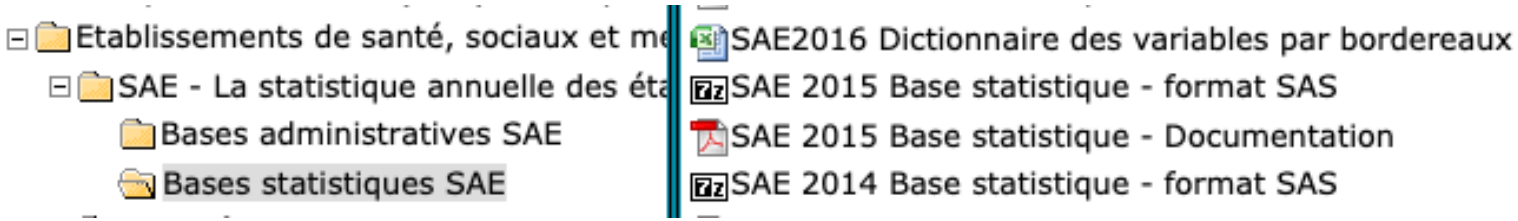

BOR	AN	FI	FI_EJ	BIO_A1	BIO_A2	BIO_A3	BIO_A4	BIO_A5	BIO_A6	BIO_A7	BIO_A8	BIO_A9	BIO_A10	BIO_A11	BIO_A12	BIO_A13	BIO_A14	BIO_A15	BIO_A16	BIO_A17	BIO_A18	BIO_B1	BIO_B2	BIO_B3
BIO	2017	010000024	010780054	1	1	0	1	1	0	0	1	0	0	1	1	1	1	0	0	0	0	0	842413	46807
BIO	2017	010005239	010008407	1	0	0	1	1	1	0	0	0	0	1	1	0	0	0	0	0	0	1	287872	33034
BIO	2017	020000162	020000063	1	1	0	1	1	0	0	1	0	0	1	1	1	0	0	0	0	0	1	941991	34002
BIO	2017	020000394	020000253	1	1	0	1	1	1	1	1	0	0	1	1	1	0	0	0	0	0	1	966398	139529
BIO	2017	020000519	020000261	1	1	0	1	1	1	1	1	0	0	1	1	1	1	0	0	1	1	1	738092	64676
BIO	2017	020000535	020000287	1	1	0	1	1	1	0	0	0	0	0	0	1	1	0	0	0	0	1	467262	2516
BIO	2017	020001061	020004404	1	1	0	1	1	1	0	0	0	0	1	1	1	0	0	0	0	0	0	613385	209591

VERIFICATION: 4 méthodes

Demander à la source: ce sont les meilleurs experts sur les données qu'ils produisent

Demander aux experts: de bons interlocuteurs quand la source ne coopère pas où quand il faut choisir entre plusieurs sources

Vérifications statistiques: moyenne, médiane, maximum, minimum, écart-type

Bon sens: est-ce que les hypothèses de bases sont vraies?

SCHOOL OF **DATA**

ALLEZ, UN PETIT

EXERCICE

spreadsheet: http://bit.ly/IJBA2021_regio1

jamboard: http://bit.ly/IJBA2021_jam2

Quelles questions de vérification poser à ce jeu de données ?

Ecrire les questions sur le jamboard, slide 'VERIFICATION 1'

Problèmes courants rencontrés lors de la vérification

- Valeurs manquantes
- Valeurs manquantes remplacées par des valeurs ambigues comme 0 ou des dates par défaut (1900,1904, 1969, 1970 sont des défauts courant)
- Lignes ou valeurs en double
- Formats de dates qui varient au sein du même jeu de données
- Unités de mesure non spécifiées
- Noms de colonnes ambigus
- Pas de documentation de la provenance ou méthodologie du jeu de donnée
- Des valeurs suspectes sont présentes
- Les données ne sont pas assez fines
- Les totaux diffèrent des agrégats inclus
- La feuille de calcul a exactement 65536 lignes (valeur max dans les anciennes versions d'Excel) ou 255 colonnes (valeur max dans les anciennes versions de Numbers)

SCHOOL OF **DATA**

NOUS VOILA ENFIN AU

NETTOYAGE

3 TYPES DE NETTOYAGE

Toilettage

Edition

Rapprochement

3 types de nettoyage

TOILETTAGE

Edition

Rapprochement

Préparer les données à la vérification ou l'analyse, sans toucher au contenu : **nettoyage de la structure des données**.

3 types de nettoyage

Toilettage

EDITION

Rapprochement

Préparer les données à l'analyse, en corrigeant les problèmes et/ou en enlevant le superflu: **nettoyage du contenu des données**

3 types de nettoyage

Toilettage

Edition

RAPPROCHEMENT

Préparer les données à l'analyse, en les **fusionnant avec des données additionnelles** qui rajoutent du contexte ou de la précision

SCHOOL OF **DATA**

ALLEZ, UN PETIT

EXERCICE

spreadsheet: http://bit.ly/IJBA2021_regio2

jamboard: http://bit.ly/IJBA2021_jam2

Quelles questions de vérification poser à ce jeu de données ?

Ecrire les questions sur le jamboard, slide 'VERIFICATION 2'

spreadsheet: http://bit.ly/IJBA2021_regio2

jamboard: http://bit.ly/IJBA2021_jam2

Je souhaite comparer les résultats des listes ayant une tête de liste homme avec ceux des listes ayant une tête de liste femme.

Quels sont les problèmes à régler avant de pouvoir faire mon analyse?

➔ Ecrire les questions sur le jamboard, slide NETTOYAGE 2’

Astuces à retenir pour l'étape de Nettoyage

Lors du **toilettage** vous serez souvent amené à:

- Enlever les artefacts de mise en force (e.g. * NOM*)
  - en utilisant SUBSTITUTE()
- Séparer les données en deux colonnes, par exemple pour séoarer une valeur et son unité (e.g. 5 milliards)
  - en utilisant SPLIT()
- Aligner les colonnes qui étaient décalées (par exemple après un export Tabula)
- Scindre les donnée sur plusieurs lignes quand elles sont dans une seule cellule
  - par exemple avec SPLIT() et char(10)
- Corriger les problèmes basiques d'orthographe qui affectent les filtres comme les formats de dates et les variations dans l'écriture des noms propres (New York, N.Y.)
  - en utilisant: IF() or IFS()

Astuces à retenir pour l'étape de Nettoyage

Lors de **l'Édition** vous serez amené à faire:

- Valeurs manquantes ou incorrectes: corriger ou supprimer ?
  - La seule solution peut être d'abandonner le jeu de donnée et aller en chercher un autre
- Identifier et enlever les éléments en double
  - formule utile: UNIQUE()
  - fonctionnalité unique: Filters
- Ajouter de colonnes de clarification (e.g. unités de valeur)
- Ajouter des colonnes calculées (e.g. âge des individus quand vous n'avez que leurs date de naissance
  - formule utile: DATEDIF()
- Ajouter des colonnes de catégorisation (e.g. tranches d'âges)
  - formules utiles: IF() or IFS()
- Enlever des portions de données qui ne sont pas pertinentes pour votre analyse

Astuces à retenir pour l'étape de Nettoyage

Lors de **l'Édition** vous serez amené à faire:

- Valeurs manquantes ou incorrectes: corriger ou supprimer ?
  - La seule solution peut être d'abandonner le jeu de donnée et aller en chercher un autre
- Identifier et enlever les éléments en double
  - formule utile: UNIQUE()
  - fonctionnalité unique: Filters
- Ajouter de colonnes de clarification (e.g. unités de valeur)
- Ajouter des colonnes calculées (e.g. âge des individus quand vous n'avez que leurs date de naissance
  - formule utile: DATEDIF()
- Ajouter des colonnes de catégorisation (e.g. tranches d'âges)
  - formules utiles: IF() or IFS()
- Enlever des portions de données qui ne sont pas pertinentes pour votre analyse

Astuces à retenir pour l'étape de Nettoyage

Lors du **Rapprochement** vous serez amenés à faire:

- Fusion de deux jeux de données (ou plus) en utilisant une colonne commune
  - formule utile: FILTER() et INDEX(MATCH())

SCHOOL OF **DATA**

REGARDONS MAINTENANT

LES OUTILS

DEUX GRANDS OUTILS

VOTRE TABLEUR FAVORI
Excel (fonctionne bien hors ligne), Google Spreadsheets (facilite la collaboration), LibreOffice (gratuit, open source, éthique).

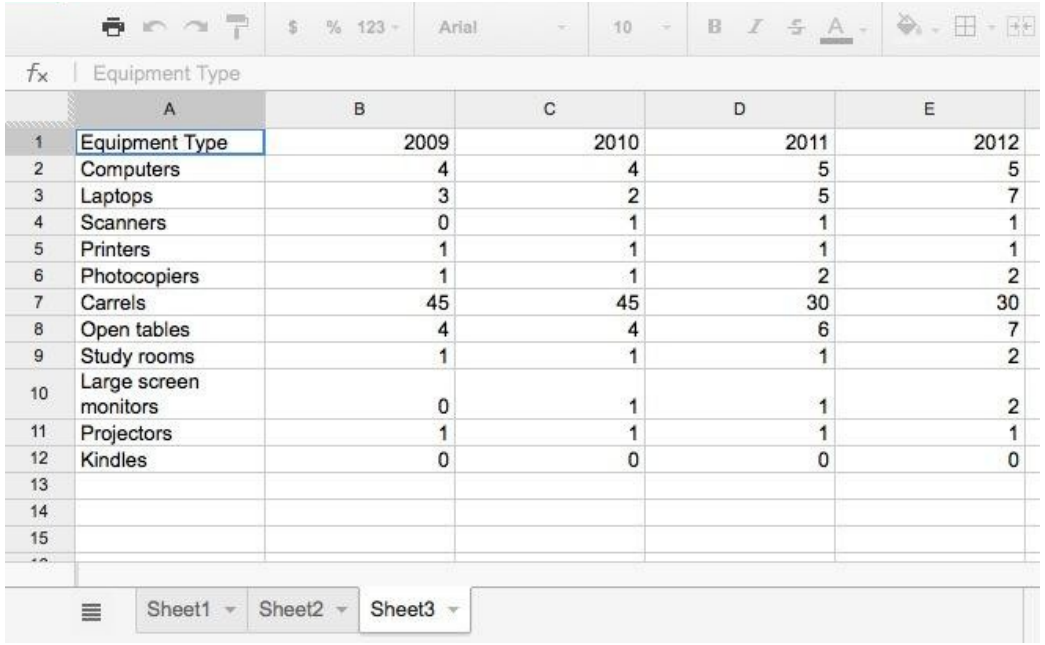

Equipment Type

	A	B	C	D	E
1	Equipment Type	2009	2010	2011	2012
2	Computers	4	4	5	5
3	Laptops	3	2	5	7
4	Scanners	0	1	1	1
5	Printers	1	1	1	1
6	Photocopiers	1	1	2	2
7	Carrels	45	45	30	30
8	Open tables	4	4	6	7
9	Study rooms	1	1	1	2
10	Large screen monitors	0	1	1	2
11	Projectors	1	1	1	1
12	Kindles	0	0	0	0
13					
14					
15					

Sheet1 Sheet2 Sheet3

DEUX GRANDS OUTILS

OPENREFINE
Un outil très puissant, idéal pour des jeux de données entre 1K+ et 2-3 millions de lignes.

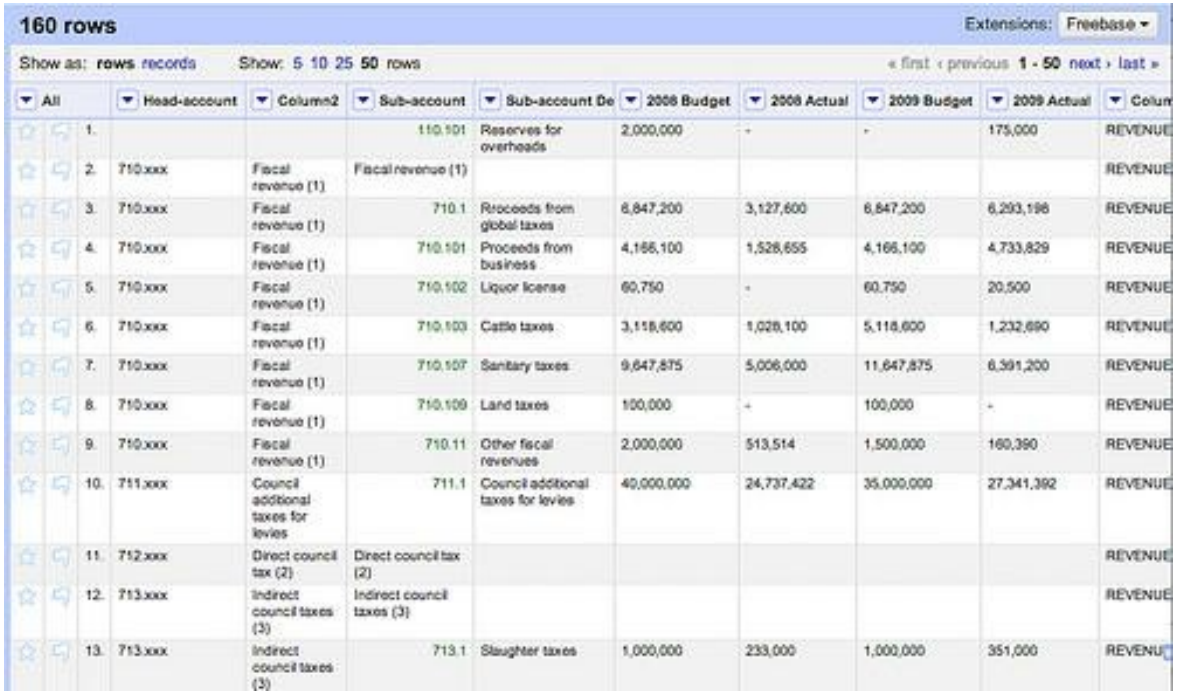

160 rows — Extensions: Freebase

Show as: rows records — Show: 5 10 25 50 rows — « first ‹ previous 1 - 50 next › last »

All		Head-account	Column2	Sub-account	Sub-account De	2008 Budget	2008 Actual	2009 Budget	2009 Actual	Colum
1.				110.101	Reserves for overheads	2,000,000	-	-	175,000	REVENUE
2.		710.xxx	Fiscal revenue (1)	Fiscal revenue (1)						REVENUE
3.		710.xxx	Fiscal revenue (1)	710.1	Proceeds from global taxes	6,847,200	3,127,600	6,847,200	6,293,198	REVENUE
4.		710.xxx	Fiscal revenue (1)	710.101	Proceeds from business	4,166,100	1,528,655	4,166,100	4,733,829	REVENUE
5.		710.xxx	Fiscal revenue (1)	710.102	Liquor license	60,750	-	60,750	20,500	REVENUE
6.		710.xxx	Fiscal revenue (1)	710.103	Cattle taxes	3,118,600	1,028,100	5,118,600	1,232,690	REVENUE
7.		710.xxx	Fiscal revenue (1)	710.107	Sanitary taxes	9,647,875	5,006,000	11,647,875	6,391,200	REVENUE
8.		710.xxx	Fiscal revenue (1)	710.109	Land taxes	100,000	-	100,000	-	REVENUE
9.		710.xxx	Fiscal revenue (1)	710.11	Other fiscal revenues	2,000,000	513,514	1,500,000	160,390	REVENUE
10.		711.xxx	Council additional taxes for levies	711.1	Council additional taxes for levies	40,000,000	24,737,422	35,000,000	27,341,392	REVENUE
11.		712.xxx	Direct council tax (2)	Direct council tax (2)						REVENUE
12.		713.xxx	Indirect council taxes (3)	Indirect council taxes (3)						REVENUE
13.		713.xxx	Indirect council taxes (3)	713.1	Slaughter taxes	1,000,000	233,000	1,000,000	351,000	REVENU

OPENREFINE VS EXCEL

	Microsoft Excel	Open Refine
Trier	X	X
Enlever les espaces en trop	X	X
Scindre les colonnes	X	X
Conversion en JSON		X
Facets		X
Requetes HTTP		X
Geocodage		X
API de réconciliation		X
Support Regex		X
Historique		X

SCHOOL OF **DATA**

ALLEZ, UN VRAI

EXERCICE

spreadsheets: http://bit.ly/IJBA2021_regio1 & http://bit.ly/IJBA2021_regio2

jamboard: http://bit.ly/IJBA2021_jam2

Je souhaite comparer les résultats des listes ayant une tête de liste homme avec ceux des listes ayant une tête de liste femme. Mais je dois avant ça vérifier et nettoyer les jeux de données. Quelles étapes pour y arriver ?

Ecrire les étapes, slide EXERCICE - ETAPES’

spreadsheets: http://bit.ly/IJBA2021_regio1 & http://bit.ly/IJBA2021_regio2

jamboard: http://bit.ly/IJBA2021_jam2

Tutoriel guidé: la vérification et le nettoyage des données du premier tour des élections régionales de 2015

A SUIVRE...