SCHOOL OF **DATA**

INTRODUCTION A LA RECUPERATION DE DONNEES

I. LE TRAVAIL AVEC LES DONNEES

II. EXERCICE SUPER DIFFICILE

III. RECUPERER LES DONNEES

IV. ZOOM SUR LE SCRAPING

V. L’EXTRACTION DE DONNEES

VI. LA COLLECTE MANUELLE

SCHOOL OF **DATA**

LA DATA PIPELINE

LE TRAVAIL AVEC LES DONNÉES

7 GRANDES ETAPES
valable pour tout type de projet, de la brève sur le vote du budget municipal à l'enquête internationale sur l'évasion fiscale

TRAVAIL SOUVENT NON LINEAIRE
aller-retour entre étapes, répétition des étapes pour plusieurs jeux de données…)

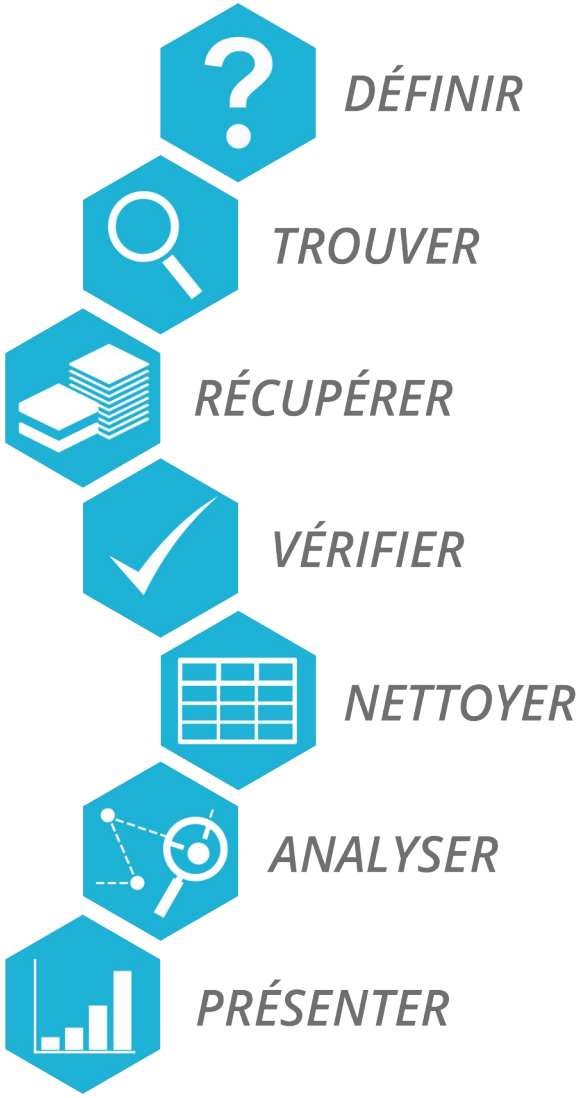

CE QUE VOUS CONNAISSEZ
Problématique & hypothèses, demande d'accès aux documents publics, portails open data, filetype:xls…

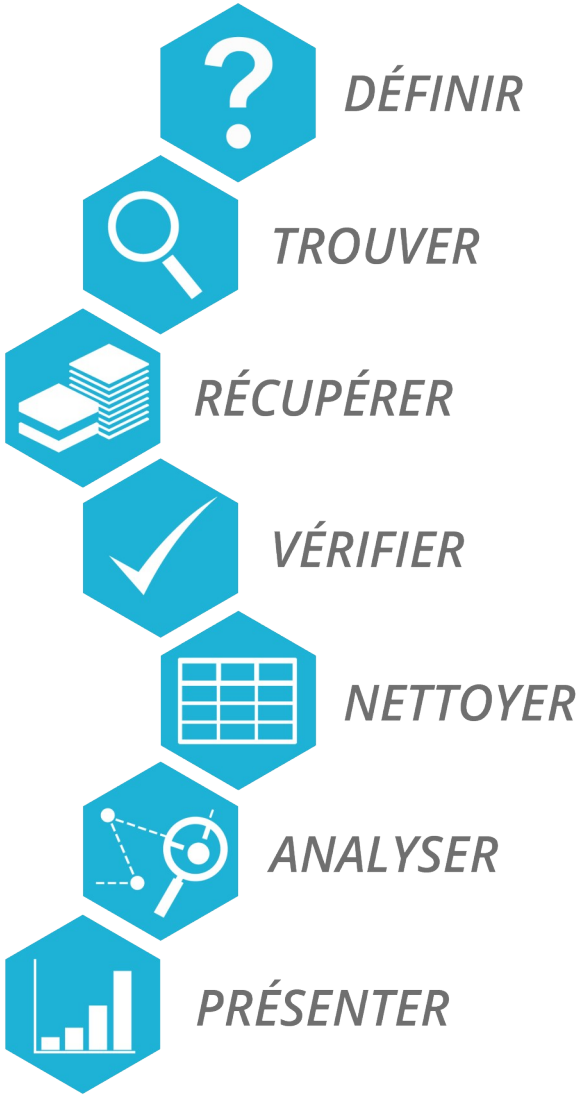

CE QUE L'ON VA VOIR AUJOURD'HUI
scraping, collecte manuelle, extraction...

SCHOOL OF **DATA**

MAIS AVANT...

UN PETIT EXERCICE

→ **https://bit.ly/ijbaJAM2022**

SCHOOL OF DATA

TROISIEME ETAPE

RECUPERER LES DONNEES

3 GRANDES QUESTIONS

Où sont mes données ?

Sous quel format sont-elles conservées ?

Dois-je les transformer ?

3 grandes questions

OÙ SONT MES DONNÉES ?

Sous quel format sont-elles conservées ?

Dois-je les transformer ?

OÙ SONT MES DONNÉES ?

LOCALISATION
Portail open data
Dans le système informatique d'une administration ou d'une entitée privée (non publiées en ligne)
Dans les archives physiques d'une administration ou d'une entitée privée
Derrière une interface de programmation applicative (API)
En libre accès sur le web
Nulle part

SOUS QUEL FORMAT SONT-ELLES CONSERVÉES ?

LOCALISATION	RECUPERATION	FORMATS
Portail open data	Téléchargement	xls, csv, shp, pdf, ods, json, xml, sqlite
Dans le système informatique d'une administration ou d'une entitée privée (non publiées en ligne)	Demande d'accès	xls, csv, shp, pdf, ods, json, xml, sqlite (et bien pire…)
Dans les archives physiques d'une administration ou d'une entitée privée	Demande d'accès	papier, photos (!), microfilm (!?!),
Derrière une interface de programmation applicative (API)	En bidouillant un peu de code informatique	csv, json, xml
En libre accès sur le web	en fonction du format	html, pdf (ou tout autre format en existence)
Nulle part	collecte de données	lié au mode de collecte

DOIS-JE LES TRANSFORMER ?

FORMAT	RECUPERATION
XLS, CSV, SHP, ODS, JSON, XML, SQLITE	Pas d’étapes supplémentaires
PDF créé numériquement	Extraction des données via Tabula, ou manuellement
PDF scanné	Reconnaissance optique de caractère (OCR) ou manuellement
Papier, Photographie, Microfilm	Scanner + OCR ou manuellemenet
HTML	collecte automatisée (scraping) ou manuellement

SCHOOL OF **DATA**

ET MAINTENANT...

UN PETIT EXERCICE

Comment un site web est-il structuré ?

→ **https://x-ray-goggles.mouse.org/**

SCHOOL OF **DATA**

ZOOM SUR

LE SCRAPING

RECUPERER DES DONNEES HTML SUR INTERNET = SCRAPER

Difficulté TRES variable

Liste et caractéristiques des régions actuelles [modifier | modifier le code]

Carte	Dénomination	Chef-lieu de région	Départements
	Auvergne-Rhône-Alpes[7]	Lyon[7]	12 (+ métropole de Lyon) (Ain, Allier, Ardèche, Cantal, Drôme, Isère, Loire, Haute-Loire, Puy-de-Dôme, Rhône + Métropole de Lyon, Savoie et Haute-Savoie)
	Bourgogne-Franche-Comté[8]	Dijon[8]	8 (Côte-d'Or, Doubs, Jura, Nièvre, Haute-Saône, Saône-et-Loire, Yonne et Territoire de Belfort)
	Bretagne	Rennes[9]	4 (Côtes-d'Armor, Finistère, Ille-et-Vilaine et Morbihan)

WIKIPEDIA? IMPORTHTML
http://bit.ly/ijba2021_scraping

IKEA? SCRAPERS GRATUITS
listly.io / webscraper.io

RECUPERER DES DONNEES HTML SUR INTERNET = SCRAPER

Difficulté TRES variable

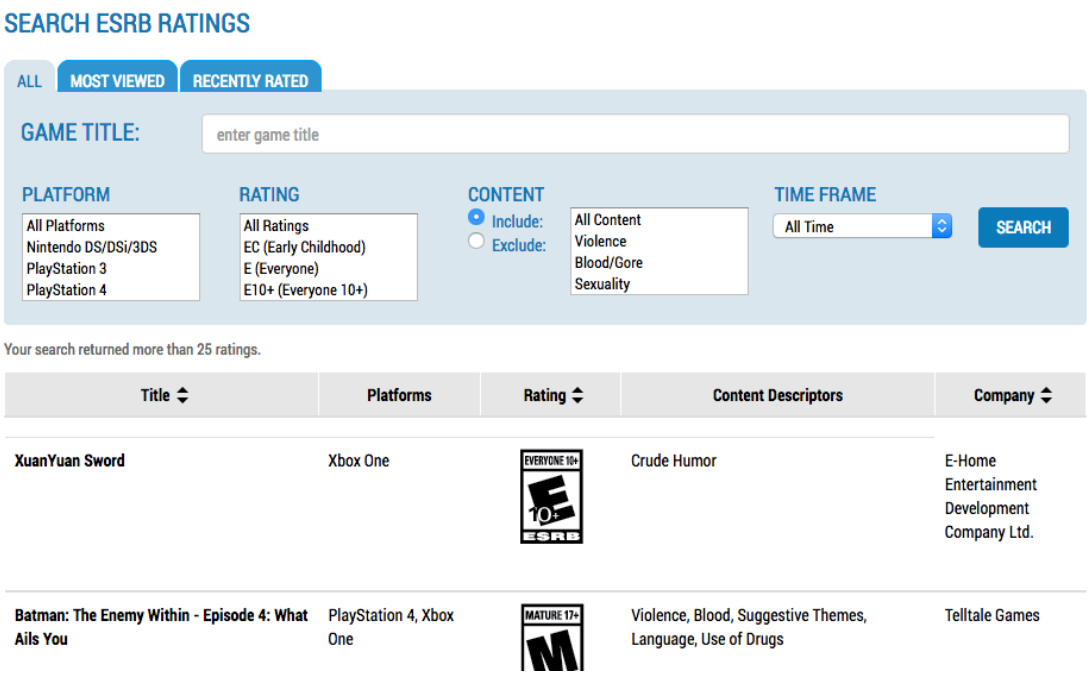

ESRB? PROGRAMMATION
scra.py, beautiful soup...

→ https://bit.ly/IJBAscraping2022

1. Créer un onglet à son nom
2. Choisir un site web à scraper
3. Utiliser importHTML

Un autre scraper: webscraper.io
On le teste sur les délibérations du conseil municipal de Bordeaux

→ **webscraper.io**

Récupérer des données via une API: genderize.io

→ **genderize.io/**

SCHOOL OF **DATA**

ZOOM SUR

L’EXTRACTION DE PDF

LES TABLEAUX DE DONNEES EN PDF

SI LE PDF EST NUMERIQUE
Tabula

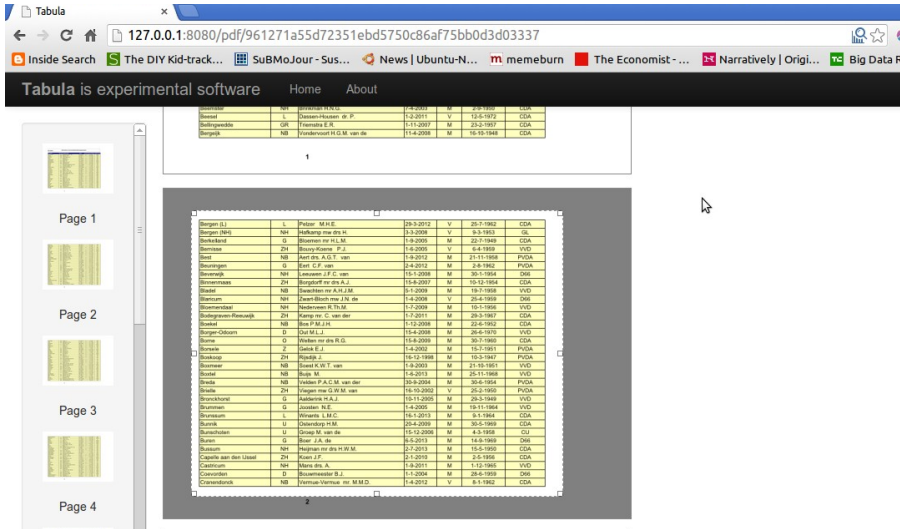

SI LE PDF EST SCANNE
OCR

SCHOOL OF DATA

ZOOM SUR

LA COLLECTE MANUELLE

ET SI...

LES DONNEES N’EXISTENT PAS?

ALORS IL FAUT LES CREER!

CROWDSOURCING

8000 personnes libèrent en une semaine les données manuscrites des déclarations d'intérêts des parlementaires !

vendredi 1 août 2014

Télécharger les données brutes des déclarations d'intérêts des parlementaires numérisées par les citoyens

COLLECTE DE DONNEES SUR LE TERRAIN

OpenDataKit

magnifying human resources through technology

Collect | Scan | Sensors | Survey | Tables || Aggregate

COLLECTER SES PROPRES DONNEES N'EST PAS SIMPLE

→ Quelle méthodologie ?
→ Quelle structuration de mes données (colonnes) ?
→ Quel degré de précision ?
→ Quel niveau d'exhaustivité ?

Il vaut mieux prendre contact avec des spécialistes qui pourront vous aider à penser votre collecte (spécialistes de la statistique, de l'urbanisme…)

SCHOOL OF **DATA**

ET MAINTENANT

EXERCICE PRATIQUE

Exercice Pratique: refaire la démarche de la data pipeline avec un jeu de données

→ point de départ: subventions aux associations de Bordeaux Métropole

→ **http://bit.ly/ijbaJAM2021 pour documenter les phases**

→ **http://bit.ly/asso2016PDF pour travailler avec Tabula**

A SUIVRE...

(N’hésitez pas à poser des questions!)