SCHOOL OF **DATA**

INTRODUCTION A L'ANALYSE DE DONNÉES

I. RAPPEL : LA DATA PIPELINE

II. LES 3 CATEGORIES D'ANALYSE

III. LA METHODOLOGIE D'ANALYSE

IV. EXERCICE GUIDE

V. EXERCICE EN GROUPE

SCHOOL OF **DATA**

LA DATA PIPELINE

OÙ ON EST-ON

CE QUE VOUS AVEZ DEJA VU

Qu’est-ce que l’open data ?
Définir son projet d’enquête
Trouver les sources de données
Récupérer les données
Vérifier les données
Nettoyer les données

Présenter les données

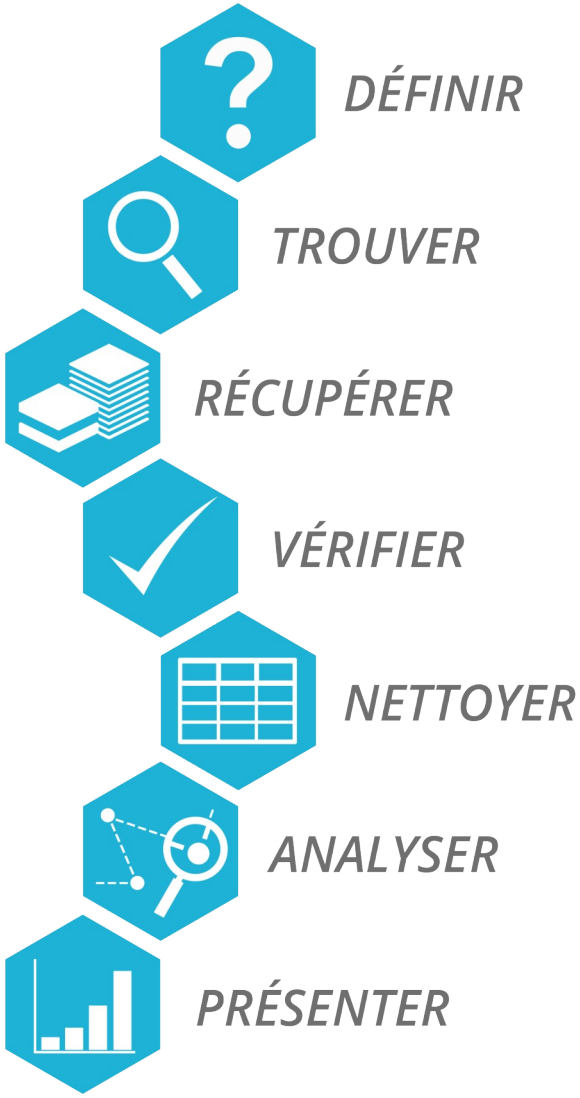

CE QUE VOUS AVEZ DÉJÀ VU

Qu’est-ce que l’open data ?
Définir son projet d’enquête
Trouver les sources de données
Récupérer les données
Vérifier les données
Nettoyer les données
Analyser les données
Présenter les données

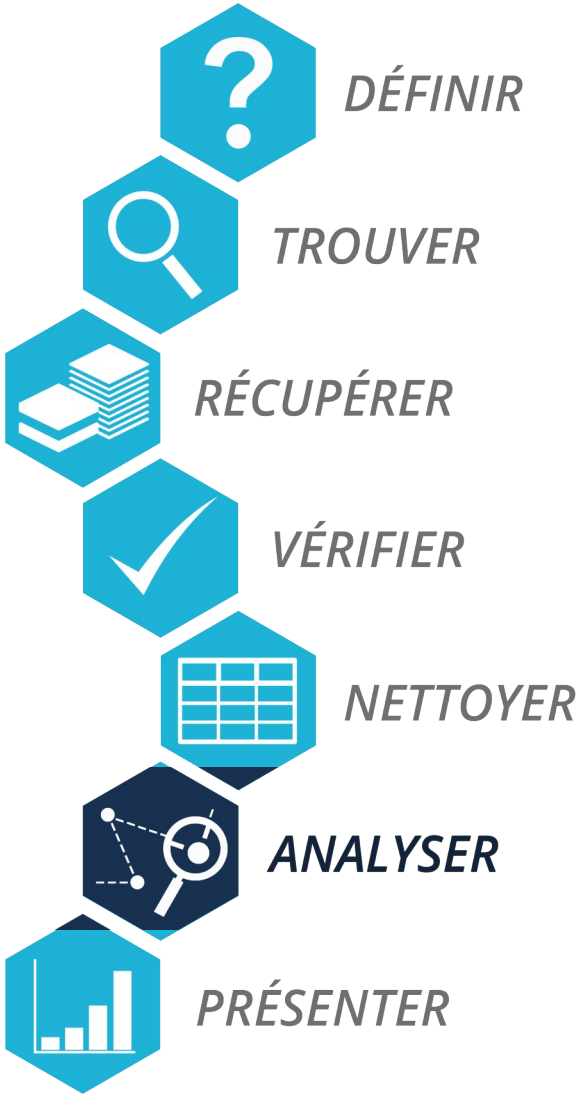

SCHOOL OF **DATA**

ALORS FAISONS DE

L’ANALYSE DE DONNÉES

UN PEU DE CONTEXTE : 3 CATEGORIES D'ANALYSE

Analyse descriptive

Analyse inferentielle

Analyse predictive

UN PEU DE CONTEXTE : 3 CATEGORIES D'ANALYSE

ANALYSE DESCRIPTIVE

Analyse inferentielle

Analyse predictive

- MOYENNE
- MEDIANE
- ECART TYPE
- MAXIMUM...

UN PEU DE CONTEXTE : 3 CATEGORIES D'ANALYSE

analyse descriptive

ANALYSE INFERENTIELLE

Analyse predictive

- CORRELATION
- SONDAGE

UN PEU DE CONTEXTE : 3 CATEGORIES D'ANALYSE

analyse descriptive

analyse inferentielle

ANALYSE PREDICTIVE

- MODELISATION
- MACHINE LEARNING

LA METHODOLOGIE D'ANALYSE

un thème...

décomposé en plusieurs hypothèses...

DÉFINIR

qui deviennent des question(s)/étape(s)

d'analyse…

reformulées selon les données.

ANALYSER

SCHOOL OF DATA

PARLONS CONCRET PARLONS

EXERCICE DE GROUPES

A DADA SUR NOS DONNEES

Concentrons nous sur l'analyse descriptive

Analyse des résultats du 1er tour des régionales 2015

→ http://bit.ly/IJBA2022_2015clean

Pour chaque question, il nous faudra formuler nos hypothèse(s) et étape(s) d'analyse

Problème: Quelles nuances politiques sont les plus paritaires ?

Hypothèse: les nuances politiques écologiques et de gauche sont plus proche la parité au niveau des têtes de liste

Etape(s) d'analyse:

LVEG, LSOC, LUG ont 40-60% de sexe F

les nuances non-LVEG/LSOC/LUG ont-elles moins de 40% de sexe F

Problème: Les listes menées par des femmes font-elles de bons scores ?

Hypothèse: ces listes ont rassemblé le plus de voix dans deux régions tout au plus

Etape(s) d'analyse:

Le max de voix dans libellé_région correspond sexe F max deux fois

Problème: Quelles couleurs politiques sont arrivées en tête dans chaque région ?

Hypothèse:

Etape(s) d'analyse:

SCHOOL OF **DATA**

C’EST DEJA FINI

MERCI