SCHOOL OF **DATA**

INTRODUCTION A LA RECUPERATION DE DONNEES

I. LE TRAVAIL AVEC LES DONNÉES

II. EXERCICE SUPER DIFFICILE

III. RECUPERER LES DONNEES

IV. ZOOM SUR LE SCRAPING ET LES API

V. L’EXTRACTION DE PDF

VI. LA COLLECTE MANUELLE

VII. CHATGPT?

Pour accéder aux slides et aux ressource de cours, c’est par ici:

→https://bit.ly/IJBA2024ressources

SCHOOL OF **DATA**

LA DATA PIPELINE

LE TRAVAIL AVEC LES DONNÉES

7 GRANDES ETAPES
valable pour tout type de projet, de la brève sur le vote du budget municipal à l'enquête internationale sur l'évasion fiscale

TRAVAIL SOUVENT NON LINEAIRE
aller-retour entre étapes, répétition des étapes pour plusieurs jeux de données…)

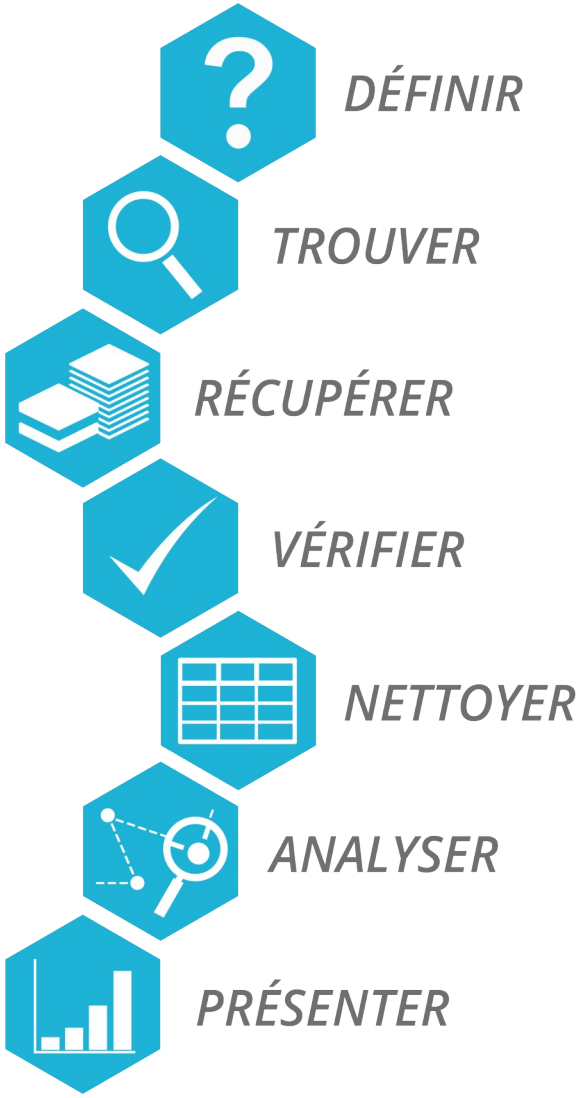

CE QUE VOUS CONNAISSEZ
Problématique & hypothèses, demande d'accès aux documents publics, portails open data, filetype:xls…

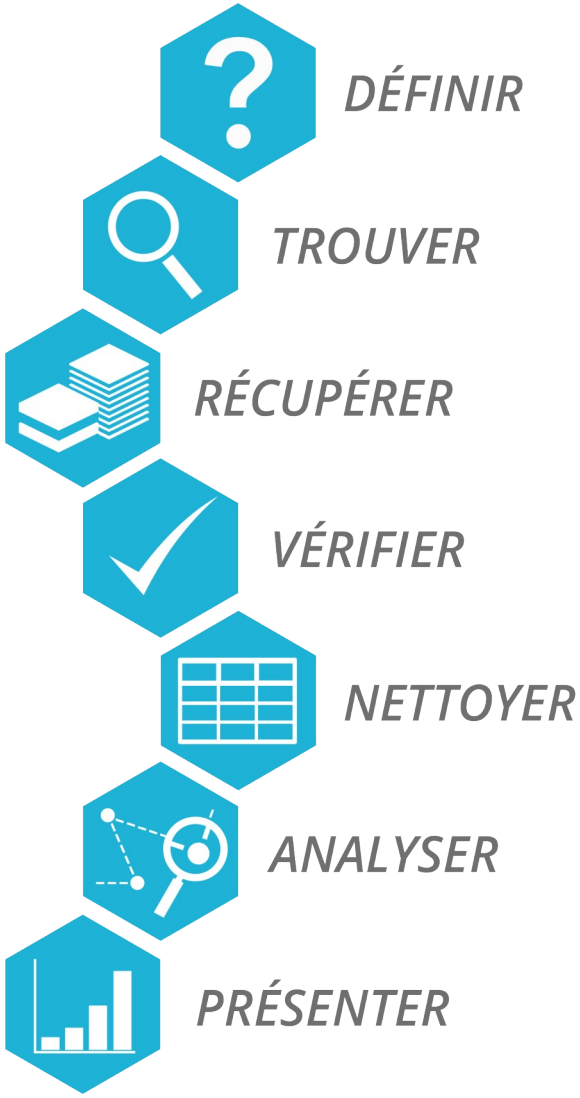

CE QUE L'ON VA VOIR AUJOURD'HUI
scraping, collecte manuelle, extraction...

SCHOOL OF **DATA**

MAIS AVANT...

UN PETIT EXERCICE

→ **https://bit.ly/ijbaJAM2024**

SCHOOL OF DATA

TROISIEME ETAPE

RECUPERER LES DONNEES

3 GRANDES QUESTIONS

Où sont mes données ?

Sous quel format sont-elles conservées ?

Dois-je les transformer ?

3 grandes questions

OÙ SONT MES DONNÉES ?

Sous quel format sont-elles conservées ?

Dois-je les transformer ?

OÙ SONT MES DONNÉES ?

LOCALISATION
Portail open data
Dans le système informatique d'une administration ou d'une entitée privée (non publiées en ligne)
Dans les archives physiques d'une administration ou d'une entitée privée
Derrière une interface de programmation applicative (API)
En libre accès sur le web
Nulle part

SOUS QUEL FORMAT SONT-ELLES CONSERVÉES ?

LOCALISATION	RECUPERATION	FORMATS
Portail open data	Téléchargement	xls, csv, shp, pdf, ods, json, xml, sqlite
Dans le système informatique d'une administration ou d'une entitée privée (non publiées en ligne)	Demande d'accès	xls, csv, shp, pdf, ods, json, xml, sqlite (et bien pire…)
Dans les archives physiques d'une administration ou d'une entitée privée	Demande d'accès	papier, photos (!), microfilm (!?!),
Derrière une interface de programmation applicative (API)	En bidouillant un peu de code informatique	csv, json, xml
En libre accès sur le web	en fonction du format	html, pdf (ou tout autre format en existence)
Nulle part	collecte de données	lié au mode de collecte

DOIS-JE LES TRANSFORMER ?

FORMAT	RECUPERATION
XLS, CSV, SHP, ODS, JSON, XML, SQLITE	Pas d’étapes supplémentaires
PDF créé numériquement	Extraction des données via Tabula, ou manuellement
PDF scanné	Reconnaissance optique de caractère (OCR) ou manuellement
Papier, Photographie, Microfilm	Scanner + OCR ou manuellemenet
HTML	collecte automatisée (scraping) ou manuellement

SCHOOL OF **DATA**

ZOOM SUR

LE SCRAPING

SCHOOL OF **DATA**

MAIS AVANT...

UN PETIT EXERCICE

Comment un site web est-il structuré ?

→ **https://x-ray-goggles.mouse.org/**

RECUPERER DES DONNEES HTML SUR INTERNET = SCRAPER

C’est parce que c’est structuré qu’on peut facilement automatiser l’extraction.

Démonstration par la preuve: scrapons Wikipedia avec Google Sheets

→ **https://bit.ly/IJBAscraping2024**

1. Créer un onglet à son nom
2. Choisir un site web à scraper
3. Utiliser importHTML

RECUPERER DES DONNEES HTML SUR INTERNET = SCRAPER

On utilise la formule **IMPORTHTML**

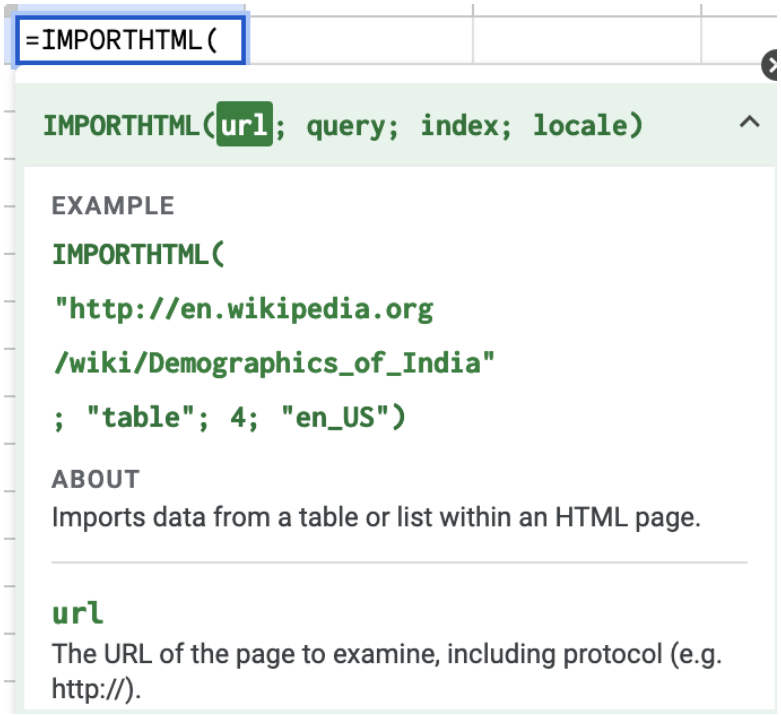

RECUPERER DES DONNEES HTML SUR INTERNET = SCRAPER

Le niveau de difficulté est très variable, mais les outils sont nombreux

Liste et caractéristiques des régions actuelles [modifier | modifier le code]

Carte	Dénomination	Chef-lieu de région	Départements
	Auvergne-Rhône-Alpes[7]	Lyon[7]	12 (+ métropole de Lyon) (Ain, Allier, Ardèche, Cantal, Drôme, Isère, Loire, Haute-Loire, Puy-de-Dôme, Rhône + Métropole de Lyon, Savoie et Haute-Savoie)
	Bourgogne-Franche-Comté[8]	Dijon[8]	8 (Côte-d'Or, Doubs, Jura, Nièvre, Haute-Saône, Saône-et-Loire, Yonne et Territoire de Belfort)
	Bretagne	Rennes[9]	4 (Côtes-d'Armor, Finistère, Ille-et-Vilaine et Morbihan)

Wikipedia? IMPORTHTML

IKEA? webscraper.io

Mais aussi avec des programmes payants, ou en codant soi-même etc.

Un autre scraper: webscraper.io

→ webscraper.io

- Gratuit et puissant
- un peu difficile à prendre en main au début
- ne fonctionne que sur Chrome/Chromium

SCHOOL OF **DATA**

ZOOM SUR

LES API

Récupérer des données via une API: genderize.io

→ **genderize.io/**

SCHOOL OF **DATA**

ZOOM SUR

L’EXTRACTION DE PDF

LES TABLEAUX DE DONNEES EN PDF

LE PDF EST NUMERIQUE? Tabula

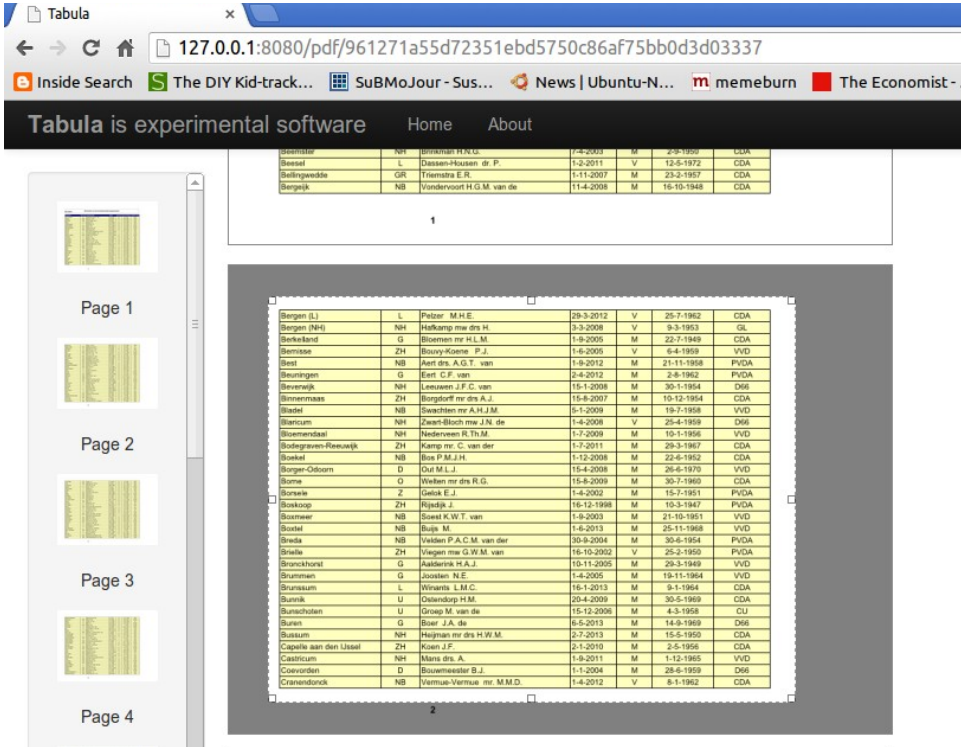

LES TABLEAUX DE DONNEES EN PDF

SI LE PDF EST SCANNE? Amazon Textract

https://aws.amazon.com/fr/textract/

Amazon Textract

Extrayez automatiquement le texte imprimé, l'écriture manuscrite, les éléments de mise en page et les données de n'importe quel document

RECHERCHER DES DONNÉES A TRAVERS PLUSIEURS PDF

GOOGLE PINPOINT https://journaliststudio.google.com/pinpoint

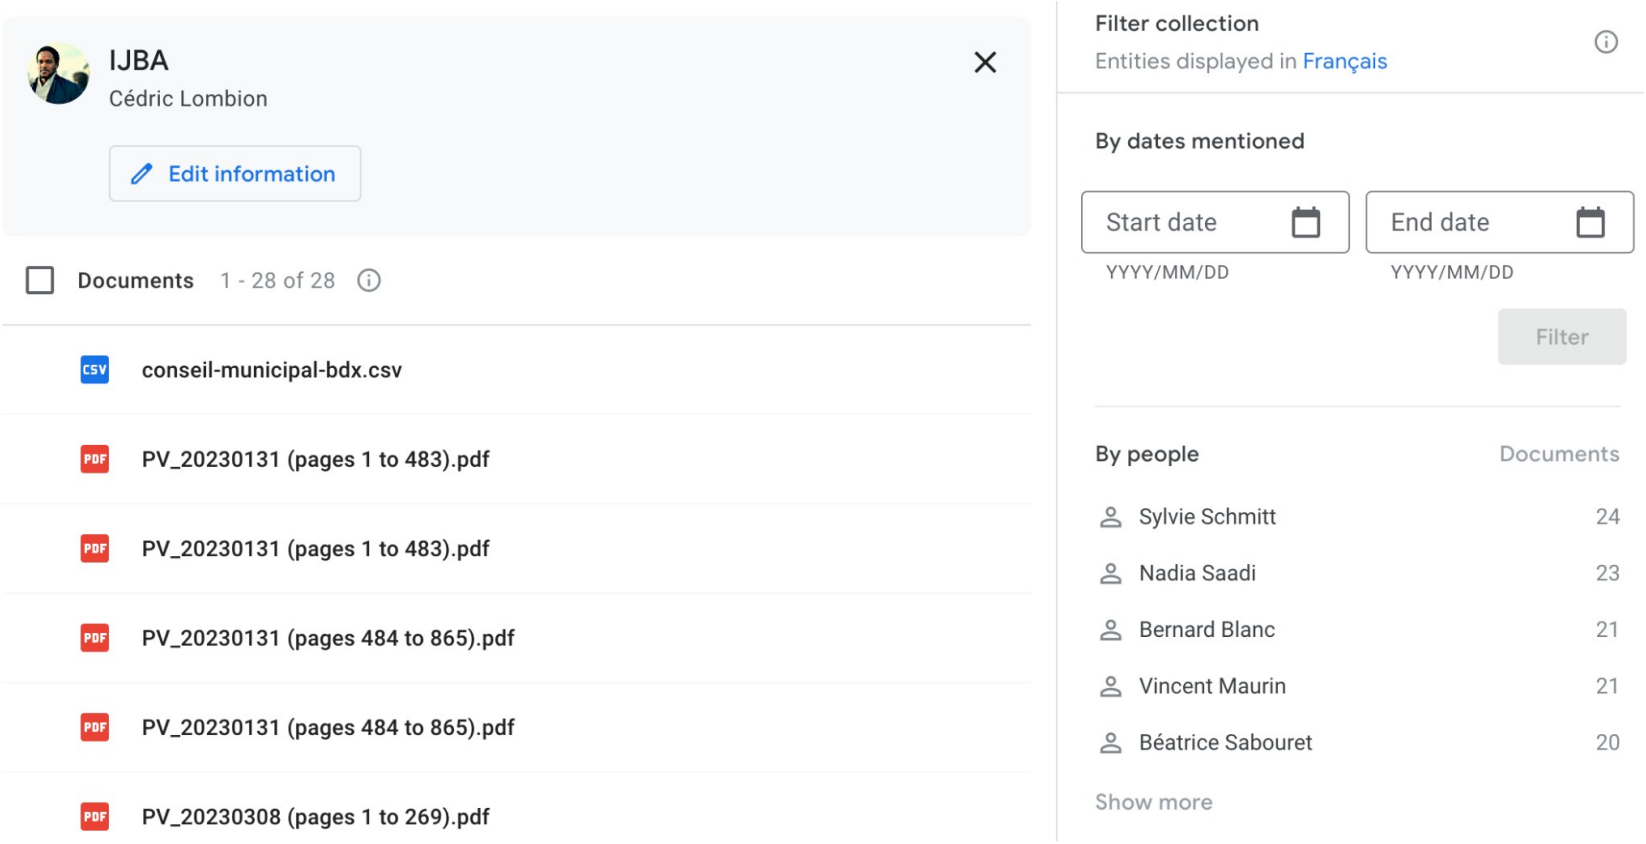

SCHOOL OF DATA

ZOOM SUR

LA COLLECTE MANUELLE

ET SI...

LES DONNÉES N’EXISTENT PAS?

ALORS IL FAUT LES CREER!

CROWDSOURCING

8000 personnes libèrent en une semaine les données manuscrites des déclarations d'intérêts des parlementaires !

vendredi 1 août 2014

Télécharger les données brutes des déclarations d'intérêts des parlementaires numérisées par les citoyens

COLLECTE DE DONNEES SUR LE TERRAIN

OpenDataKit

magnifying human resources through technology

Collect | Scan | Sensors | Survey | Tables || Aggregate

COLLECTER SES PROPRES DONNEES N'EST PAS SIMPLE

→ Quelle méthodologie ?
→ Quelle structuration de mes données (colonnes) ?
→ Quel degré de précision ?
→ Quel niveau d'exhaustivité ?

Il vaut mieux prendre contact avec des spécialistes qui pourront vous aider à penser votre collecte (spécialistes de la statistique, de l'urbanisme…)

SCHOOL OF **DATA**

MAIS QU'EN EST-IL DE

CHATGPT (ET AUTRES)?

UN ASSISTANT UTILE A LA COLLECTE DE DONNEES

Peut être utile pour:

- se rappeler des formules
  - “rappelle moi la formule de Google Sheets qui permet d’extraire du contenu HTML”
- trouver pourquoi la formule ne fonctionne pas
  - “voici ma formule, mais j’ai le mauvais tableau en retour.”
- faciliter l’écriture de petits scripts, si on a appris les bases
  - “voici les urls des délibérés de Bordeaux Métropole, aide moi à écrire un script curl pour télécharger les PDFs»
  - “voici la documentation de l’API de météo France, aide moi a construire une requête pour récupérer la température”

UN ASSISTANT UTILE A LA COLLECTE DE DONNEES

Mais attention:

ChatGPT se trompe souvent, donc il faut vérifier les résultats systématiquements
ne jamais compter sur Chatgpt pour extraire sans erreurs de données d'un PDF:

A SUIVRE...

(N’hésitez pas à poser des questions!)