SCHOOL OF **DATA**

# INTRODUCTION AU NETTOYAGE DE DONNÉES

Avant de commencer…

Téléchargez le logiciel Tabula https://tabula.technology/

On l’utilisera cet après-midi

I. RAPPEL : LA DATA PIPELINE

II. QU’EST-CE QU’UNE DONNEE

III. LA VERIFICATION

IV. LE NETTOYAGE

V. LES OUTILS

SCHOOL OF **DATA**

LA DATA PIPELINE

# QUELQUES RAPPELS

**7 GRANDES ETAPES**
valable pour tout type de projet, de la brève sur le vote du budget municipal à l'enquête internationale sur l'évasion fiscale

**TRAVAIL SOUVENT NON LINEAIRE**
aller-retour entre étapes, répétition des étapes pour plusieurs jeux de données…)

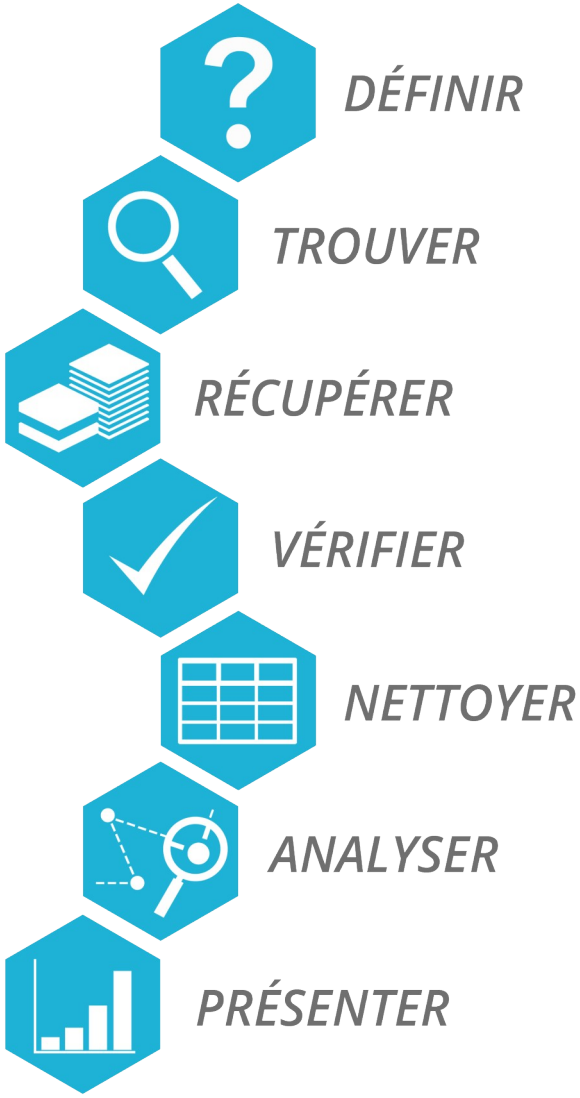

## CE QUE VOUS AVEZ DÉJÀ VU

Qu’est-ce que l’open data ?
Définir son projet d’enquête
Trouver les sources de données
Récupérer les données

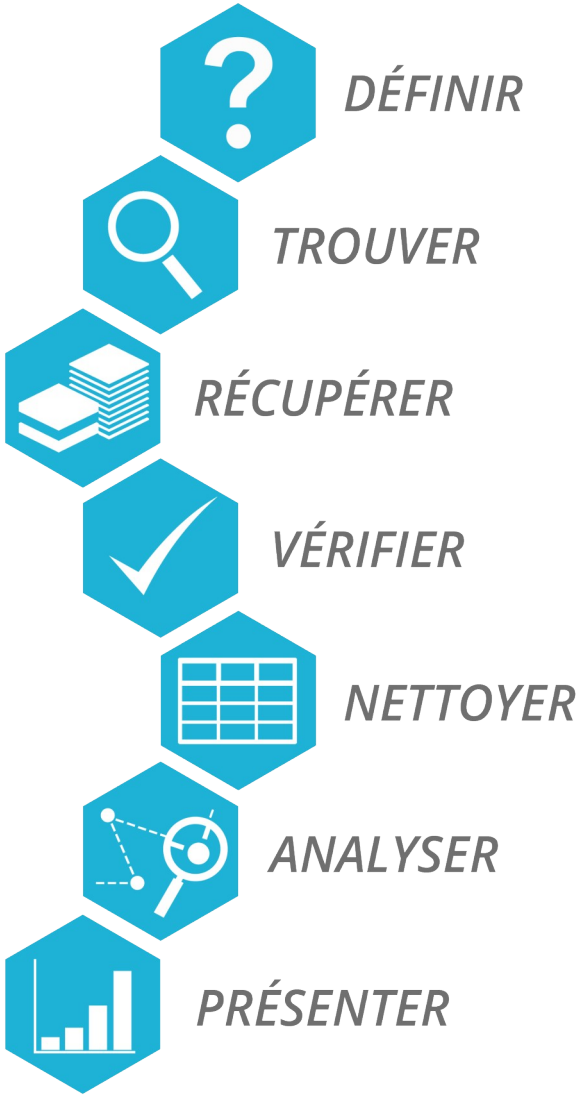

## EXEMPLE: DOSSIER MATERNITÉS DU MONDE

**Problématique**: Sur quel critère choisir une maternité lorsque l'on est enceinte ? Y a-t-il des profils type d'établissements ?

**Hypothèse supposée** : certains établissements se distinguent par un taux de médicalisation de l'acte plus fort (césarienne…)

**Recherche de données** : enquête nationale périnatale, base statistique annuelle des établissements de santé (SAE), l'Agence technique de l'information hospitalière (ATIH) et la Fédération française de recherche en santé périnatale (FFRSP)

**Problèmes avec les données** :
fiabilité: données aberrantes, encodage non standardisé
exhaustivité: actes non encodés

LES DÉCODEURS

Césarienne, épisiotomie… enquête sur la médicalisation de l'accouchement en France

Les statistiques des maternités en 2016 montrent que les interventions dites « techniques » sont loin d'être limitées.

## CE QUE L'ON VA VOIR AUJOURD'HUI

- ➔ Méthodes de vérification
- ➔ Nettoyage de données tabulaires

SCHOOL OF **DATA**

MAIS AU FAIT

# QU’EST-CE QU’UNE DONNÉE ?

# Qu’est-ce qu’une donnée ?

Qu’est-ce qu’une donnée ?

# Une représentation structurée du monde

# Une représentation structurée du monde

# Une représentation structurée du monde

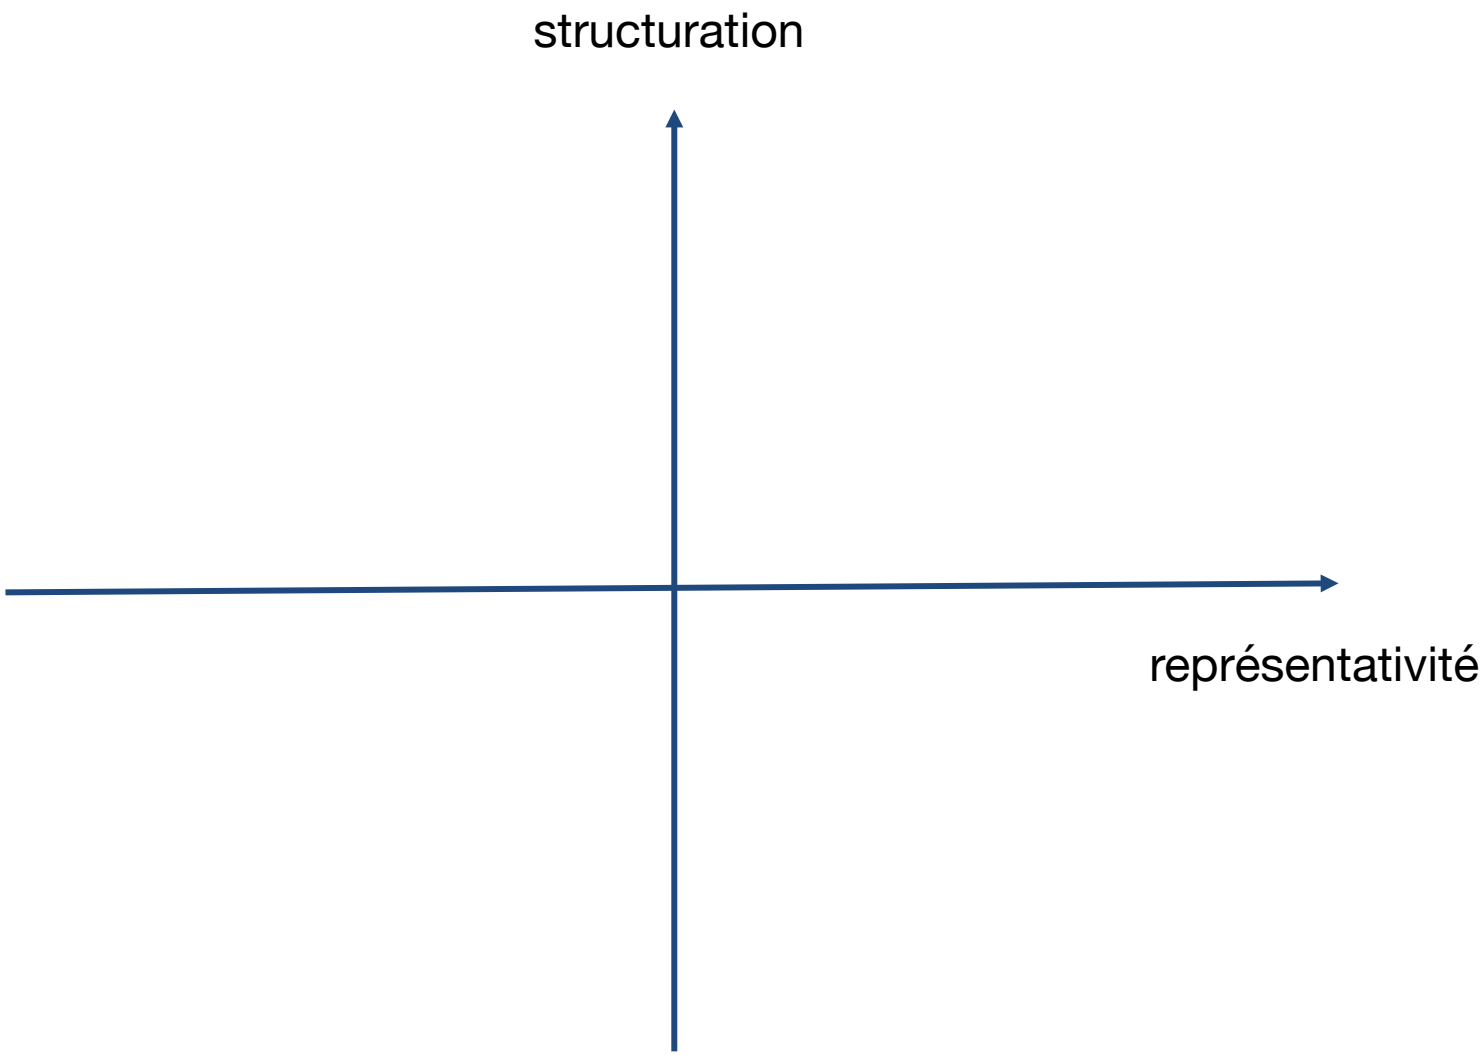
structuration
représentativité

représentativité

données mal encodées (qualité)

bonnes données

structuration

hallucinations

données falsifiées ou erronées (fiabilité / exhaustivité)

données mal encodées

Tableau 1 : Importations de véhicules en Côte d'Ivoire sur la période 2017-2018

| Mois | Type | Nombre | |
|---|---|---|---|
| | | 2017 | 2018 |
| Juillet | Neufs | 793 | 993 |
| | Usagés | 4482 | 4682 |
| Août | Neufs | 609 | 809 |
| | Usagés | 1477 | 1677 |
| Septembre | Neufs | 583 | 783 |
| | Usagés | 738 | 938 |
| Octobre | Neufs | 739 | 939 |
| | Usagés | 515 | 715 |
| Novembre | Neufs | 664 | 864 |
| | Usagés | 539 | 739 |

Source : Rapport 2018

bonnes données

| Mois | Type | Nombre | Année |
|---|---|---|---|
| Juillet | Neufs | 793 | 2017 |
| Juillet | Neufs | 993 | 2018 |
| Juillet | Usagés | 4482 | 2018 |
| Juillet | Usagés | 4682 | 2018 |
| Août | Neufs | 609 | 2017 |
| Août | Neufs | 809 | 2018 |
| Août | Usagés | 1477 | 2017 |
| Août | Usagés | 1677 | 2018 |
| Septembre | Neufs | 583 | 2017 |
| Septembre | Neufs | 783 | 2018 |
| Septembre | Usagés | 738 | 2017 |
| Septembre | Usagés | 938 | 2018 |
| Octobre | Neufs | 739 | 2017 |
| Octobre | Neufs | 939 | 2018 |
| Octobre | Usagés | 515 | 2017 |
| Octobre | Usagés | 715 | 2018 |

données falsifiées ou erronées

**Que signifie “Neufs” ?**

| Mois | Type | Nombre | Année |
|---|---|---|---|
| Juillet | Neufs | 793 | 2017 |
| Juillet | Neufs | 993 | 2018 |
| Juillet | Usagés | 4482 | 2018 |
| Juillet | Usagés | 4682 | 2018 |
| Août | Neufs | 609 | 2017 |
| Août | Neufs | 809 | 2018 |
| Août | Usagés | 1477 | 2017 |
| Août | Usagés | 1677 | 2018 |
| Septembre | Neufs | 583 | 2017 |
| Septembre | Neufs | 783 | 2018 |
| Septembre | Usagés | 738 | 2017 |
| Septembre | Usagés | 938 | 2018 |
| Octobre | Neufs | 739 | 2017 |
| Octobre | Neufs | 939 | 2018 |
| Octobre | Usagés | 515 | 2017 |
| Octobre | Usagés | 715 | 2018 |

hallucinations

Tableau 1 : Importations de véhicules en Côte d'Ivoire sur la période 2017-2018

| Mois | Type | Nombre | |
|---|---|---|---|
| | | 2017 | 2018 |
| Juillet | Neufs | 0 | 110,5 |
| | Usagés | 1 | 2 |
| Août | Neufs | -5 | 4 |
| | Usagés | 2 | 7 |
| Septembre | Neufs | 0 | 9 |
| | Usagés | 1 | 6 |
| Octobre | Neufs | -5 | 2 |
| | Usagés | 2 | 2 |
| Novembre | Neufs | 5 | 210,7 |
| | Usagés | 4 | -20 |

Source : Rapport 2018

SCHOOL OF **DATA**

ET MAINTENANT

# UN EXERCICE PRATIQUE

# UN LIEN UNIQUE

# POUR ACCÉDER AUX DOCUMENTS DE TRAVAIL

→ **https://bit.ly/IJBA2024ressources**

# ETAPES DEFINIR, TROUVER

Compléter ces étapes sur le thème: lutte contre la fracture numérique dans la métropole bordelaise

Pour trouver le tableau collaboratif:

→ **https://bit.ly/IJBA2024ressources**

SCHOOL OF **DATA**

ON REVIENT DONC VERS

# LA VERIFICATION

# VERIFICATION: 3 ENJEUX

Fiabilité

Exhaustivité

Qualité

Vérification: 3 enjeux

**FIABILITE:** les données représentent-elles la réalité ?

Exhaustivité

Qualité

« par exemple, un taux d'épisiotomie plus élevé chez les multipares que chez les primipares, des taux d'épisiotomie à moins de 1 % ou à plus de 60 % (source: Le Monde) »

Vérification: 3 enjeux

Fiabilité

**EXHAUSTIVITE:** les données sont-elles complètes ?

Qualité

« **tous les actes ne disposent pas d'un code spécifique**, et même parmi ceux qui en ont, certains, non « tarifés », **ne sont pas systématiquement saisis** par les soignants, à l'image de l'épisiotomie. (source: Le Monde) »

Vérification: 3 enjeux

Fiabilité

Exhaustivité

**QUALITE:** Les données sont-elles structurées et documentées correctement ?

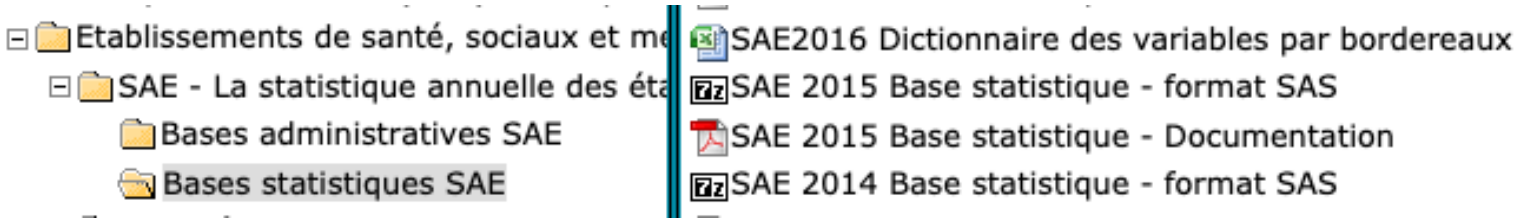


| BOR | AN | FI | FI_EJ | BIO_A1 | BIO_A2 | BIO_A3 | BIO_A4 | BIO_A5 | BIO_A6 | BIO_A7 | BIO_A8 | BIO_A9 | BIO_A10 | BIO_A11 | BIO_A12 | BIO_A13 | BIO_A14 | BIO_A15 | BIO_A16 | BIO_A17 | BIO_A18 | BIO_B1 | BIO_B2 | BIO_B3 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|---|
| BIO | 2017 | 010000024 | 010780054 | 1 | 1 | 0 | 1 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 842413 | 46807 |
| BIO | 2017 | 010005239 | 010008407 | 1 | 0 | 0 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 287872 | 33034 |
| BIO | 2017 | 020000162 | 020000063 | 1 | 1 | 0 | 1 | 1 | 0 | 0 | 1 | 0 | 0 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 1 | 941991 | 34002 |
| BIO | 2017 | 020000394 | 020000253 | 1 | 1 | 0 | 1 | 1 | 1 | 1 | 1 | 0 | 0 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 1 | 966398 | 139529 |
| BIO | 2017 | 020000519 | 020000261 | 1 | 1 | 0 | 1 | 1 | 1 | 1 | 1 | 0 | 0 | 1 | 1 | 1 | 1 | 0 | 0 | 1 | 1 | 1 | 738092 | 64676 |
| BIO | 2017 | 020000535 | 020000287 | 1 | 1 | 0 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 1 | 1 | 0 | 0 | 0 | 0 | 1 | 467262 | 2516 |
| BIO | 2017 | 020001061 | 020004404 | 1 | 1 | 0 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 1 | 1 | 1 | 0 | 0 | 0 | 0 | 0 | 0 | 613385 | 209591 |

**VERIFICATION: 4 méthodes**

Demander à la source: ce sont les meilleurs experts sur les données qu'ils produisent

Demander aux experts: de bons interlocuteurs quand la source ne coopère pas où quand il faut choisir entre plusieurs sources

Vérifications statistiques: moyenne, médiane, maximum, minimum, écart-type

Bon sens: est-ce que les hypothèses de bases sont vraies?

SCHOOL OF **DATA**

ON RETOURNE A NOTRE

# TABLEAU COLLABORATIF

1. Retrouver le jeu de données «Lieux d'inclusion numérique» sur le portail open data de Bordeaux métropole

2. Quelles questions de vérification poser à ce jeu de données ?

Ecrire les questions sur le jamboard

## Problèmes courants rencontrés lors de la vérification

- Valeurs manquantes
- Valeurs manquantes remplacées par des valeurs ambigues comme 0 ou des dates par défaut (1900,1904, 1969, 1970 sont des défauts courant)
- Lignes ou valeurs en double
- Formats de dates qui varient au sein du même jeu de données
- Unités de mesure non spécifiées
- Noms de colonnes ambigus
- Pas de documentation de la provenance ou méthodologie du jeu de donnée
- Des valeurs suspectes sont présentes
- Les données ne sont pas assez fines
- Les totaux diffèrent des agrégats inclus
- La feuille de calcul a exactement 65536 lignes (valeur max dans les anciennes versions d'Excel) ou 255 colonnes (valeur max dans les anciennes versions de Numbers)

SCHOOL OF **DATA**

NOUS VOILA ENFIN AU

# NETTOYAGE

# 3 TYPES DE NETTOYAGE

Toilettage

Edition

Rapprochement

3 types de nettoyage

**TOILETTAGE**

Edition

Rapprochement

Préparer les données à la vérification ou l'analyse, sans toucher au contenu : **nettoyage de la structure des données**.

3 types de nettoyage

Toilettage

**EDITION**

Rapprochement

Préparer les données à l'analyse, en corrigeant les problèmes et/ou en enlevant le superflu: **nettoyage du contenu des données**

3 types de nettoyage

Toilettage

Edition

**RAPPROCHEMENT**

Préparer les données à l'analyse, en les **fusionnant avec des données additionnelles** qui rajoutent du contexte ou de la précision

SCHOOL OF **DATA**

ALLEZ, UN PETIT

# EXERCICE

## ➔ https://bit.ly/IJBA2024ressources

Ce que l'on va faire ensemble:

1. Récupérer le fichier PDF marqué 'EXO'
2. Télécharger le logiciel Tabula https://tabula.technology/
3. Extraire les données
4. Vérifier & Nettoyer les données

## Astuces à retenir pour l'étape de Nettoyage

Lors du **toilettage** vous serez souvent amené à:

- Enlever les artefacts de mise en force (e.g. * NOM*)
  - en utilisant SUBSTITUTE()
- Séparer les données en deux colonnes, par exemple pour séparer une valeur et son unité (e.g. 5 milliards)
  - en utilisant SPLIT()
- Aligner les colonnes qui étaient décalées (par exemple après un export Tabula)
- Scindre les donnée sur plusieurs lignes quand elles sont dans une seule cellule
  - par exemple avec SPLIT() et char(10)
- Corriger les problèmes basiques d'orthographe qui affectent les filtres comme les formats de dates et les variations dans l'écriture des noms propres (New York, N.Y.)
  - en utilisant: IF() or IFS()

# Astuces à retenir pour l'étape de Nettoyage

Lors de **l'Édition** vous serez amené à faire:

- Valeurs manquantes ou incorrectes: corriger ou supprimer ?
  - La seule solution peut être d'abandonner le jeu de donnée et aller en chercher un autre
- Identifier et enlever les éléments en double
  - formule utile: UNIQUE()
  - fonctionnalité unique: Filters
- Ajouter de colonnes de clarification (e.g. unités de valeur)
- Ajouter des colonnes calculées (e.g. âge des individus quand vous n'avez que leurs date de naissance
  - formule utile: DATEDIF()
- Ajouter des colonnes de catégorisation (e.g. tranches d'âges)
  - formules utiles: IF() or IFS()
- Enlever des portions de données qui ne sont pas pertinentes pour votre analyse

# Astuces à retenir pour l'étape de Nettoyage

Lors de **l'Édition** vous serez amené à faire:

- Valeurs manquantes ou incorrectes: corriger ou supprimer ?
  - La seule solution peut être d'abandonner le jeu de donnée et aller en chercher un autre
- Identifier et enlever les éléments en double
  - formule utile: UNIQUE()
  - fonctionnalité unique: Filters
- Ajouter de colonnes de clarification (e.g. unités de valeur)
- Ajouter des colonnes calculées (e.g. âge des individus quand vous n'avez que leurs date de naissance
  - formule utile: DATEDIF()
- Ajouter des colonnes de catégorisation (e.g. tranches d'âges)
  - formules utiles: IF() or IFS()
- Enlever des portions de données qui ne sont pas pertinentes pour votre analyse

## Astuces à retenir pour l'étape de Nettoyage

Lors du **Rapprochement** vous serez amenés à faire:

- Fusion de deux jeux de données (ou plus) en utilisant une colonne commune
  - formule utile: FILTER() et INDEX(MATCH())

# A SUIVRE...