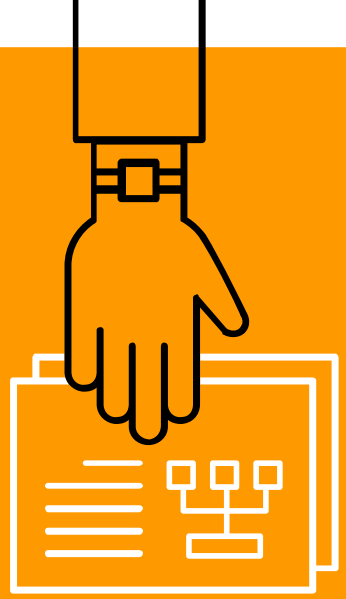

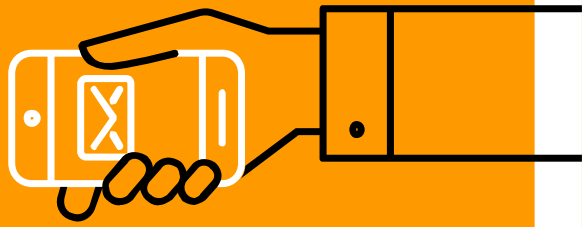

Initiation au datajournalisme

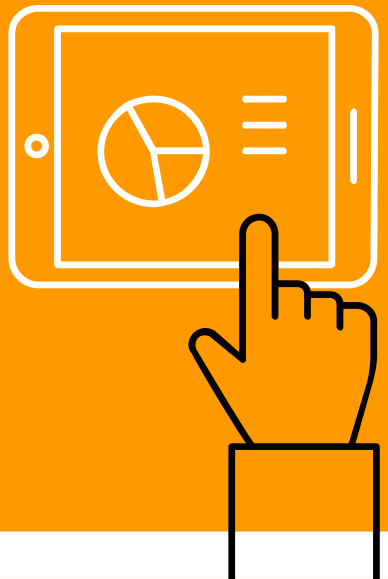

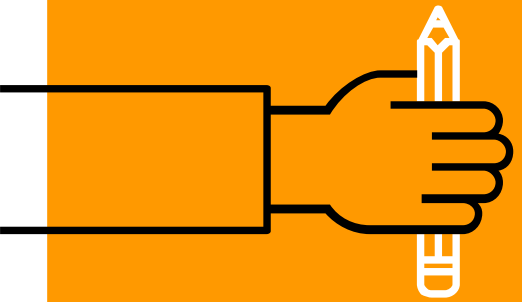

Rayya Roumanos I IJBA-2025

Rappel de la démarche

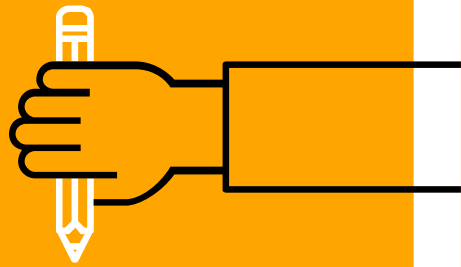

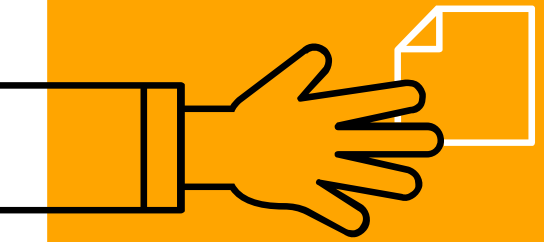

DATA PIPELINE*

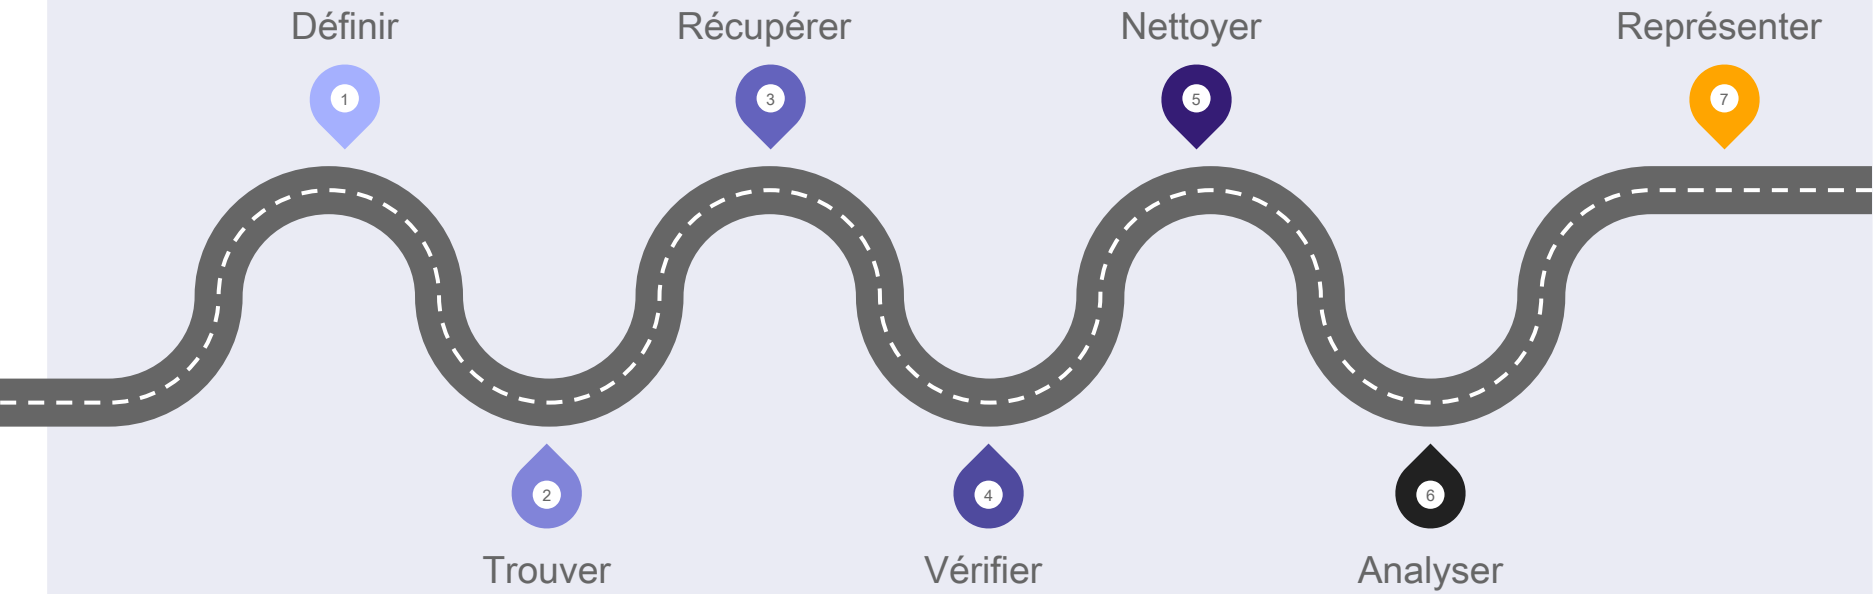

*** Matrice conçue par School of Data, la branche “formation” de l’ONG Open Knowledge Foundation**

Démarche

Point de départ

- Un jeu de données constitué
- Un questionnement

- Produire, grâce à un travail de documentation, des réponses provisoires à une question
- S'assurer que les réponses provisoire comportent des variables mesurables
- Créer un tableau d'horizon

Exemple : diversité dans les écoles de journalisme

Exercice avec un jeu de données constitué

Aides à la presse

(Ministère de la Culture)

1. Retrouvez les données
2. Récupérez les données
3. Familiarisez vous avec le tableau de données

A	B	C
Groupe ou société de presse	Aides directes (1) (en €)	Dont aides au pluralisme (en €)
BAYARD PRESSE	4541564	3338597
LA MONTAGNE	1785383	129391
PLAY BAC PRESSE	104582	104582
ROSSEL FRANCE INVESTISSEMENT	1978865	217170
SNC L'EQUIPE	1134433	
SOCIETE EDITRICE DU MONDE	2707411	921551
GROUPE LA DEPECHE DU MIDI	3333740	254639
LAGARDERE ACTIVE	620169	
LE TELEGRAMME	1359444	5193
SFA PAR (L'OBS)	318225	
SOCIETE EDITRICE DU MONDE	2885235	865754
UFIPAR (LES ECHOS-LE PARISIEN)	4822328	
GHOSN CAPITAL (VSD)	284801	
GROUPE EBRA	7308519	
GROUPE FIGARO	1563393	

Exercice avec un jeu de données constitué

Aides à la presse

(Ministère de la Culture)

Répondez aux questions suivantes :

- Quelles sont les entreprises qui n'ont reçu de l'aide qu'une seule fois ?
- Quelles sont les entreprises qui n'ont reçu de l'aide qu'en 2018 ?
- Quelles sont les 10 entreprises qui ont reçu le plus d'aide en 2016 ?

A	B	C
Groupe ou société de presse	Aides directes (1) (en €)	Dont aides au pluralisme (en €)
BAYARD PRESSE	4541564	3338597
LA MONTAGNE	1785383	129391
PLAY BAC PRESSE	104582	104582
ROSSEL FRANCE INVESTISSEMENT	1978865	217170
SNC L'EQUIPE	1134433	
SOCIETE EDITRICE DU MONDE	2707411	921551
GROUPE LA DEPECHE DU MIDI	3333740	254639
LAGARDERE ACTIVE	620169	
LE TELEGRAMME	1359444	5193
SFA PAR (L'OBS)	318225	
SOCIETE EDITRICE DU MONDE	2885235	865754
UFIPAR (LES ECHOS-LE PARISIEN)	4822328	
GHOSN CAPITAL (VSD)	284801	
GROUPE EBRA	7308519	
GROUPE FIGARO	1563393	

Revenons aux données

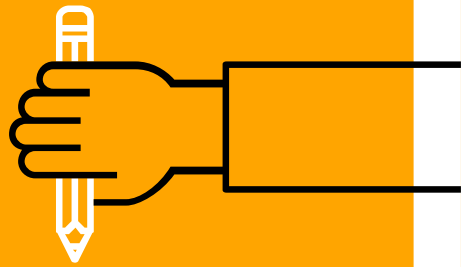

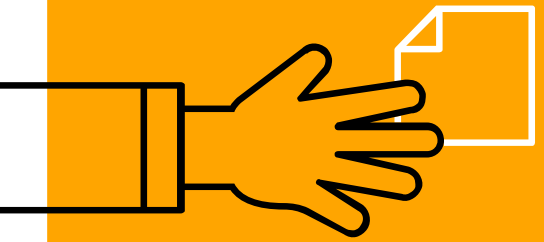

Ce qu’elles ne sont pas

Des informations

Les données sont une des briques utiles à la création d’information, ainsi que des connaissances

Des chiffres et rien que des chiffres

Les données peuvent prendre différentes formes.
Elles sont souvent transformées en chiffres pour être traitées de manière statistique

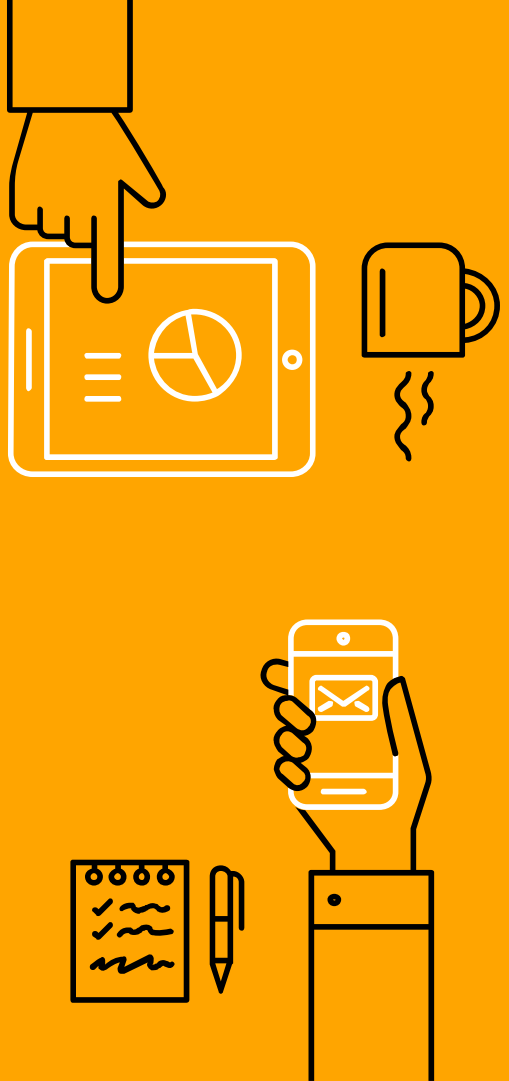

Ce qu’elles sont :

des **représentations structurées** du monde

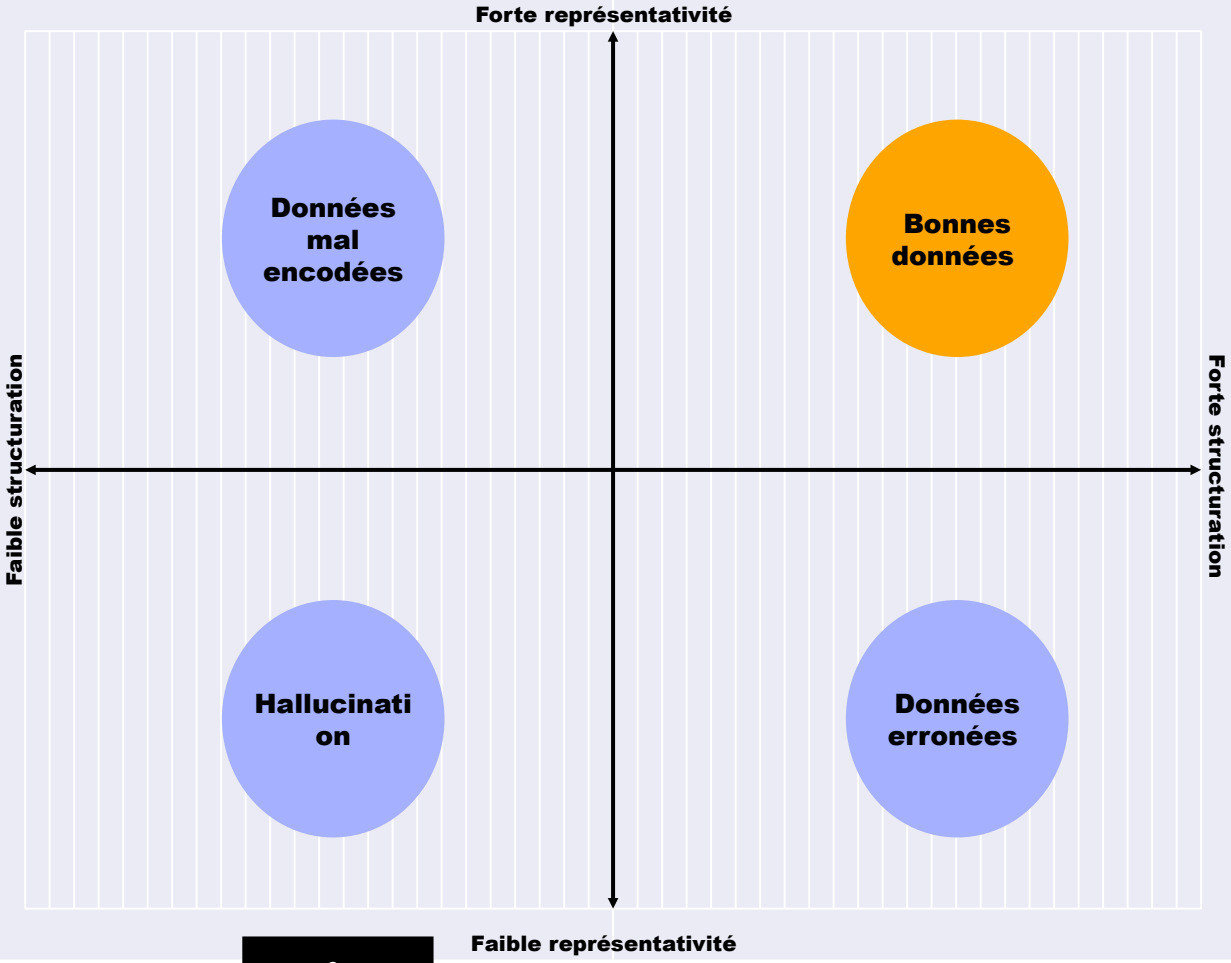

Schéma conçu par Cédric Lombion (Open Knowledge Foundation)

Exemple de données mal encodées

Dans cet exemple, la lecture humaine est possible, voire simple. En revanche, la lecture par un logiciel est mal engagée

Exercice : ici
Réponse : là

Tableau : Importations de véhicules en Côte d'Ivoire sur une période de 3 mois en 2017 et 2018

Mois	Type	Nombre	
		2017	2018
Juillet	Neufs	793	993
	Usagés	4482	4682
Août	Neufs	609	809
	Usagés	1477	1677
Septembre	Neufs	583	783
	Usagés	738	938

Attention : les angles morts de l'analyse

1. **Fétichisation**
   Accorder une importance capitale à la donnée au détriment des idées, des opinions, des vécus, des sens, etc
2. **(Sur)interprétation**
   Essentialiser un phénomène en partant de faits non représentatifs
3. **(Non)interprétation**
   Passer le relais interprétatif aux récepteurs

Trouver des données

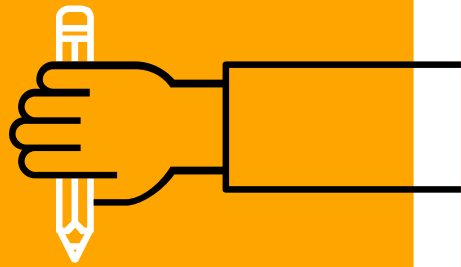

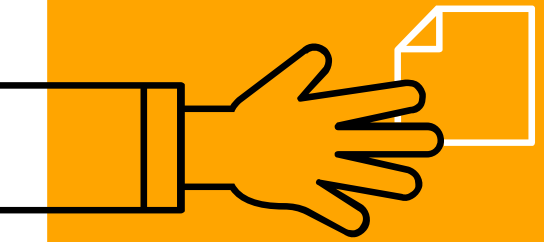

Où se trouvent les données ?

LOCALISATION
Portail open data
Dans le système informatique d’une administration ou d’une entitée privée (non publiées en ligne)
Dans les archives physiques d’une administration ou d’une entitée privée
Derrière une interface de programmation applicative (API)
En libre accès sur le web
Nulle part

Sous quel format sont-elles conservées ?

LOCALISATION	RECUPERATION	FORMATS
Portail open data	Téléchargement	xls, csv, shp, pdf, ods, json, xml, sqlite
Dans le système informatique d'une administration ou d'une entitée privée (non publiées en ligne)	Demande d'accès	xls, csv, shp, pdf, ods, json, xml, sqlite (et bien pire…)
Dans les archives physiques d'une administration ou d'une entitée privée	Demande d'accès	papier, photos (!), microfilm (!?!),
Derrière une interface de programmation applicative (API)	En bidouillant un peu de code informatique	csv, json, xml
En libre accès sur le web	en fonction du format	html, pdf (ou tout autre format en existence)
Nulle part	collecte de données	lié au mode de collecte

Dois-je transformer les données ?

FORMAT	RECUPERATION
XLS, CSV, SHP, ODS, JSON, XML, SQLITE	Pas d’étapes supplémentaires
PDF créé numériquement	Extraction des données (via Tabula par exemple, ou manuellement)
PDF scanné	Reconnaissance optique de caractère (OCR) ou manuellement
Papier, Photographie, Microfilm	Scanner + OCR ou manuellemenet
HTML	Collecte automatisée (scraping) ou manuellement

Zoom sur le scraping

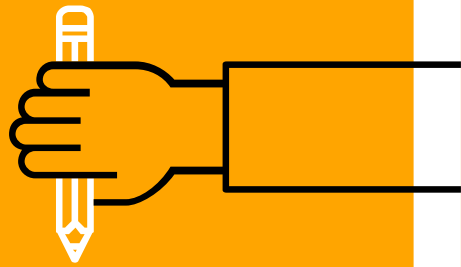

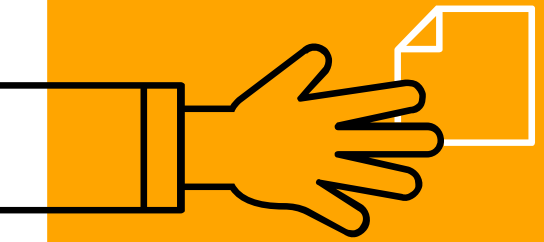

STRUCTURE D’UNE PAGE WEB

Avec “X-Ray Goggles”

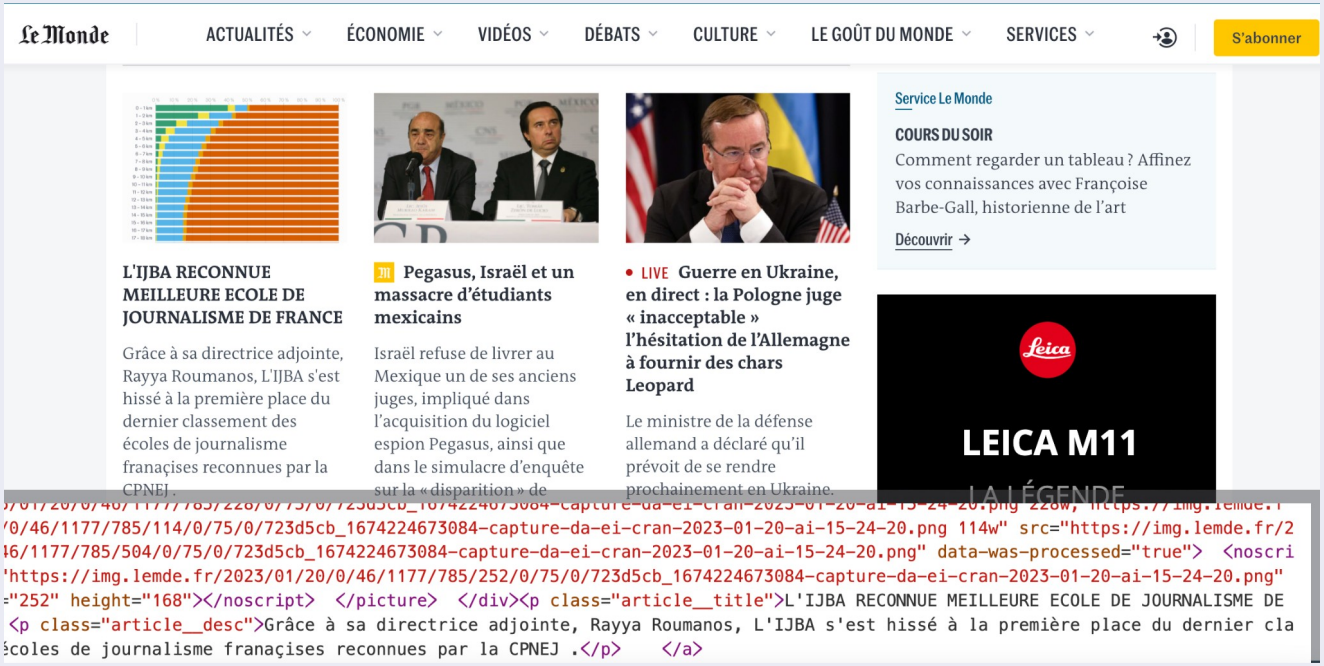

Scraping (facile)

Importer des données dans un tableau depuis un site web

- **OPTION 1 : Copier/coller**
- **OPTION 2 : ImportHtml**

n° Région	Région	n° Dpt	Département	Nombre de communes
84	Auvergne-Rhône-Alpes[1]	01	Ain	393
		03	Allier	317
		07	Ardèche	335
		15	Cantal	246
		26	Drôme	363
		43	Haute-Loire	257
		74	Haute-Savoie	279
		38	Isère	512
		42	Loire	323
		63	Puy-de-Dôme	464
		69D	Rhône	208
		69M	Métropole de Lyon	59
		73	Savoie	273
		Total		**4029**

Wikipedia

A1 =IMPORTHTML("https://fr.wikipedia.org/wiki/Listes_des_communes_

	A	B	C	D	E
1	no Région	Région	no Dpt	Département	Nombre de communes
2	84	*Auvergne-Rhôn	1	Ain	393
3			3	Allier	317
4			7	Ardèche	335
5			15	Cantal	246
6			26	Drôme	363
7			43	Haute-Loire	257
8			74	Haute-Savoie	279
9			38	Isère	512
10			42	Loire	323
11			63	Puy-de-Dôme	464
12			69D	Rhône	208
13			69M	Métropole de Lyc	59
14			73	Savoie	273
15			*Total*		*4029*

Google Spreadsheet

Scraping (plus complexe)

Via des outils comme :

- import.io
- octoparse
- crawly
- Scaper (Google)