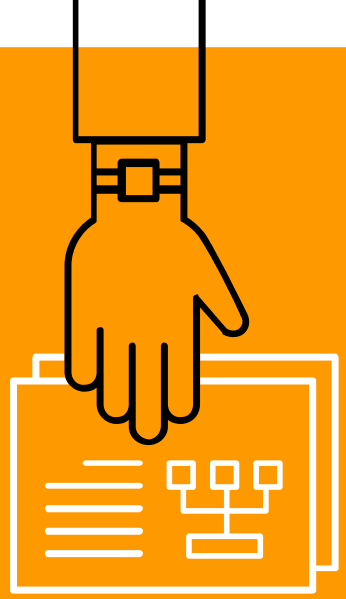

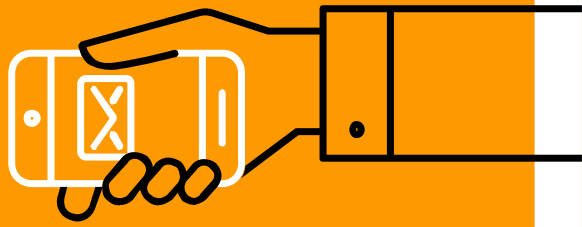

Initiation au datajournalisme

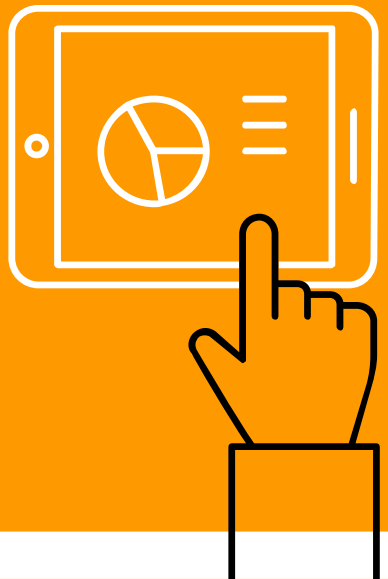

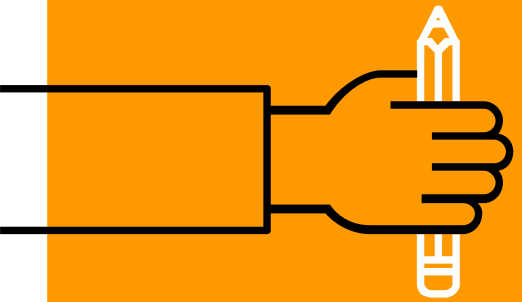

Rayya Roumanos I IJBA-2025

Avant de commencer

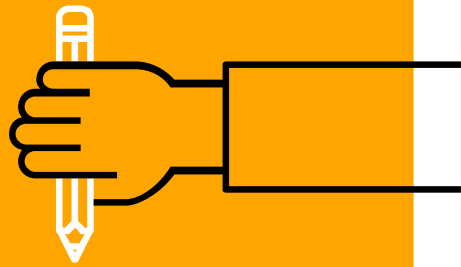

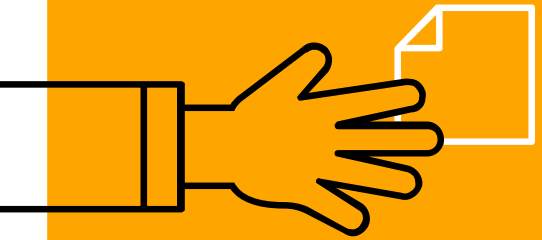

Tabula

Téléchargez le logiciel Tabula: https://tabula.technology

On en aura besoin plus tard.

Rappel de la démarche

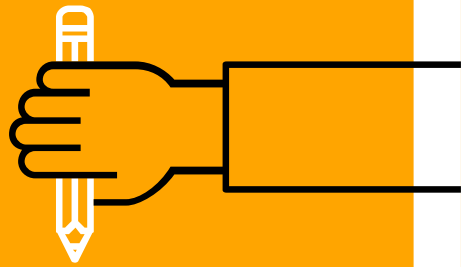

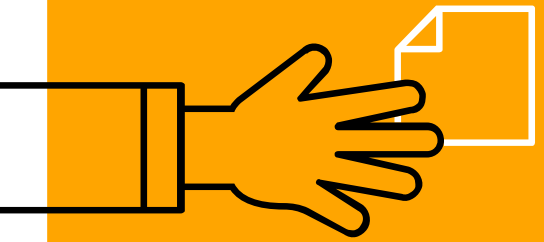

DATA PIPELINE*

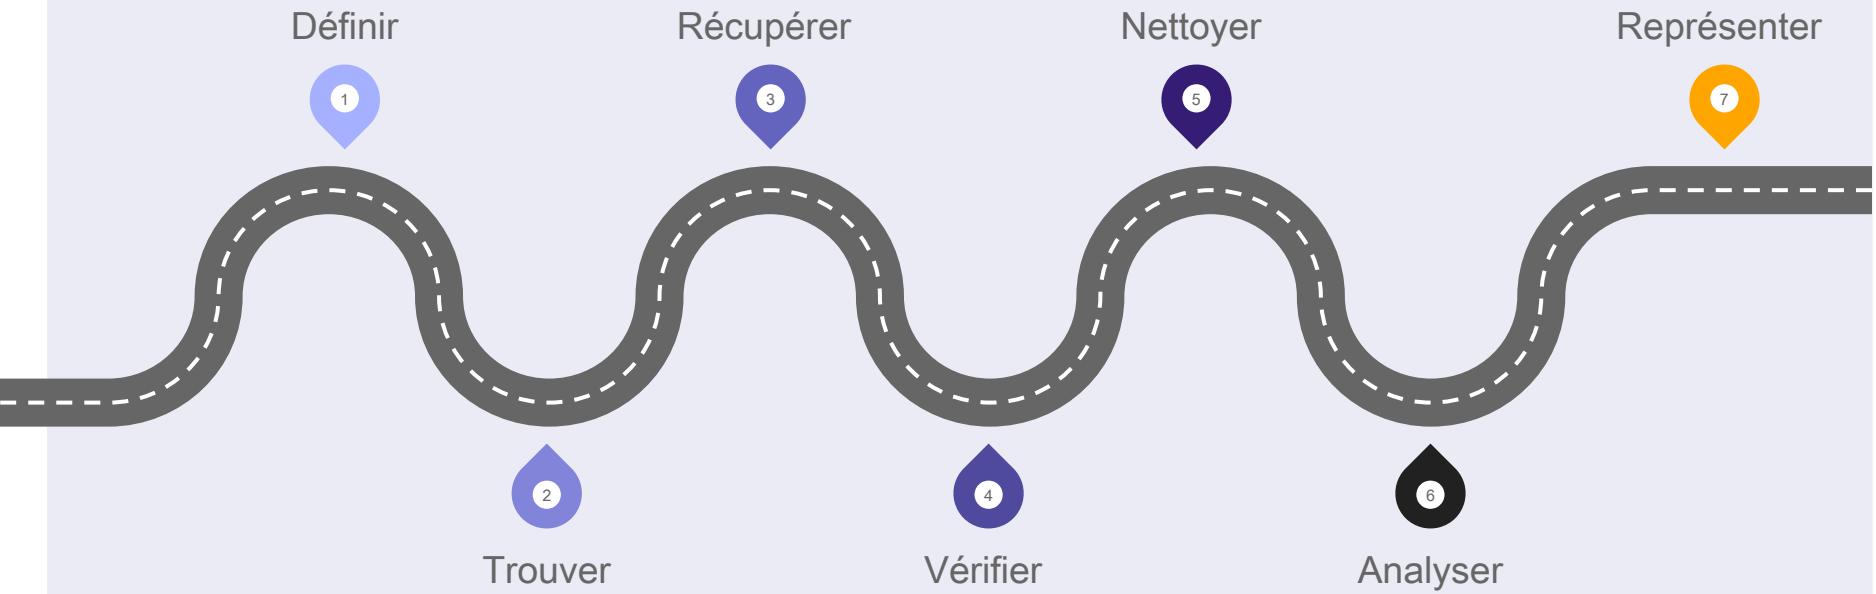

*** Matrice conçue par School of Data, la branche “formation” de l’ONG Open Knowledge Foundation**

Démarche

Point de départ

- Un jeu de données constitué
- Un questionnement

- Produire, grâce à un travail de documentation, des réponses provisoires à une question
- S'assurer que les réponses provisoire comportent des variables mesurables
- Créer un tableau d'horizon

Exemple : diversité dans les écoles de journalisme

Démarche

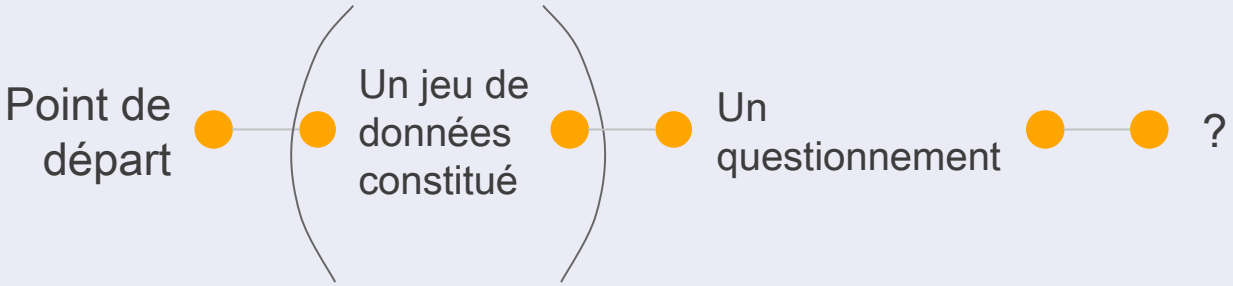

Exemple : diversité dans les écoles de journalisme

Démarche

Point de départ

Un jeu de données constitué

Un questionnement

Des vérifications

Du nettoyage

Exemple: dossier des maternités du Monde

LES DÉCODEURS

Césarienne, épisiotomie... enquête sur la médicalisation de l'accouchement en France

Les statistiques des maternités en 2016 montrent que les interventions dites « techniques » sont loin d'être limitées.

Exemple: dossier des maternités du Monde

Problématique: Sur quel critère choisir une maternité lorsque l'on est enceinte ? Y a-t-il des profils type d'établissements ?

Hypothèse: certains établissements se distinguent par un taux de médicalisation de l'acte plus fort (césarienne…)

Recherche de données : enquête nationale périnatale, base statistique annuelle des établissements de santé (SAE), l'Agence technique de l'information hospitalière (ATIH) et la Fédération française de recherche en santé périnatale (FFRSP)

Problèmes avec les données :
fiabilité: données aberrantes, encodage non standardisé
exhaustivité: actes non encodés

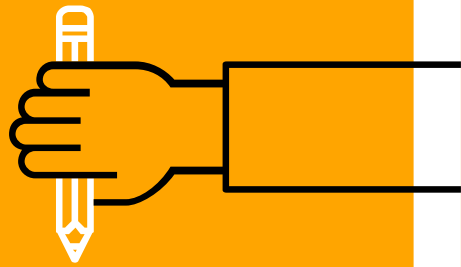

Vérifier les données

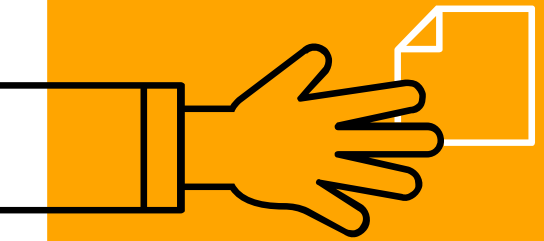

On a vu: Ce qu’elles ne sont pas

Des informations

Les données sont une des briques utiles à la création d’information, ainsi que des connaissances

Des chiffres et rien que des chiffres

Les données peuvent prendre différentes formes.
Elles sont souvent transformées en chiffres pour être traitées de manière statistique

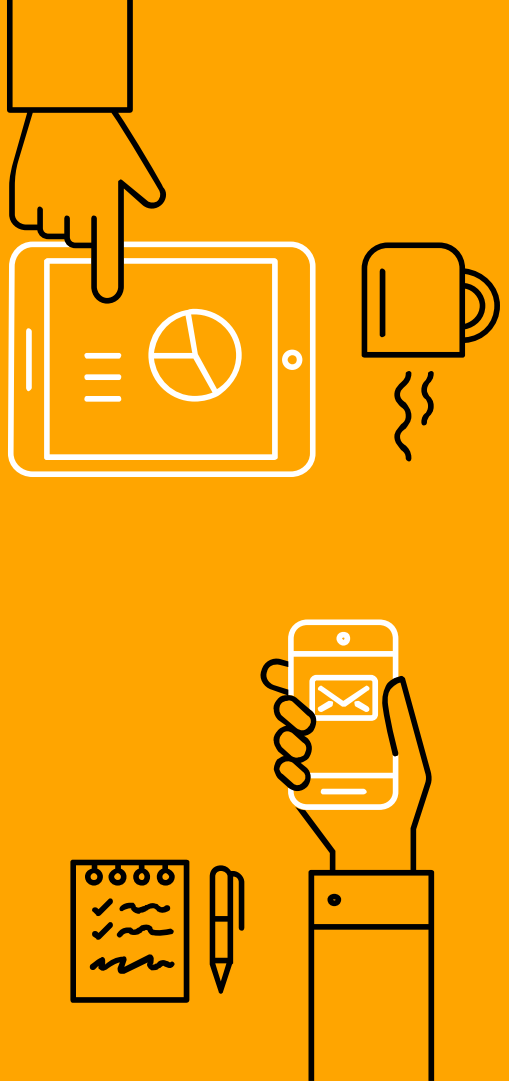

On a vu: ce qu’elles sont

Une représentation structurée du monde

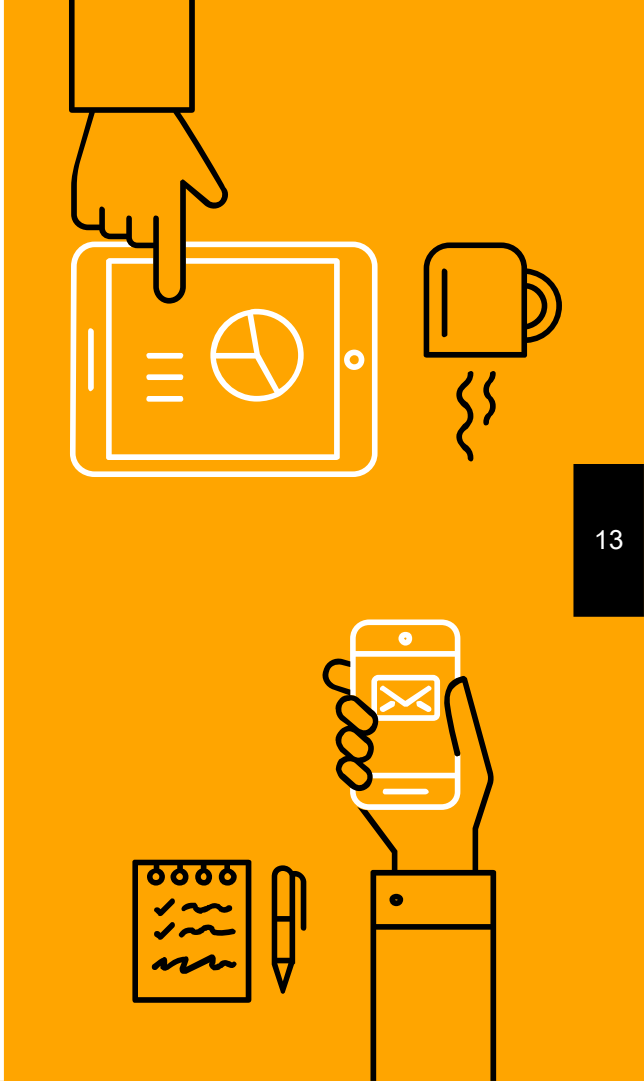

On a vu: ce qu’elles sont

Une représentation structurée du monde

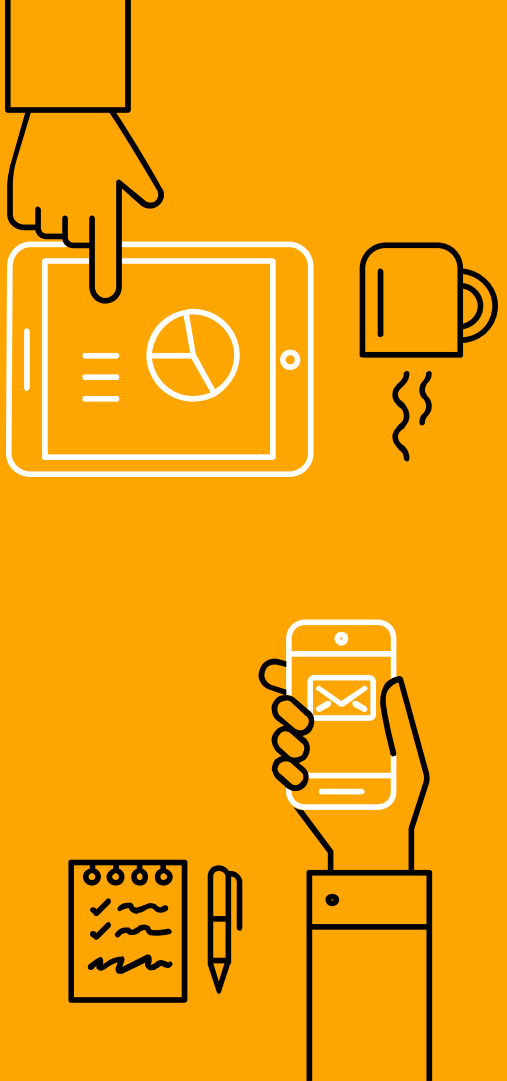

On a vu: ce qu’elles sont

Une représentation structurée du monde

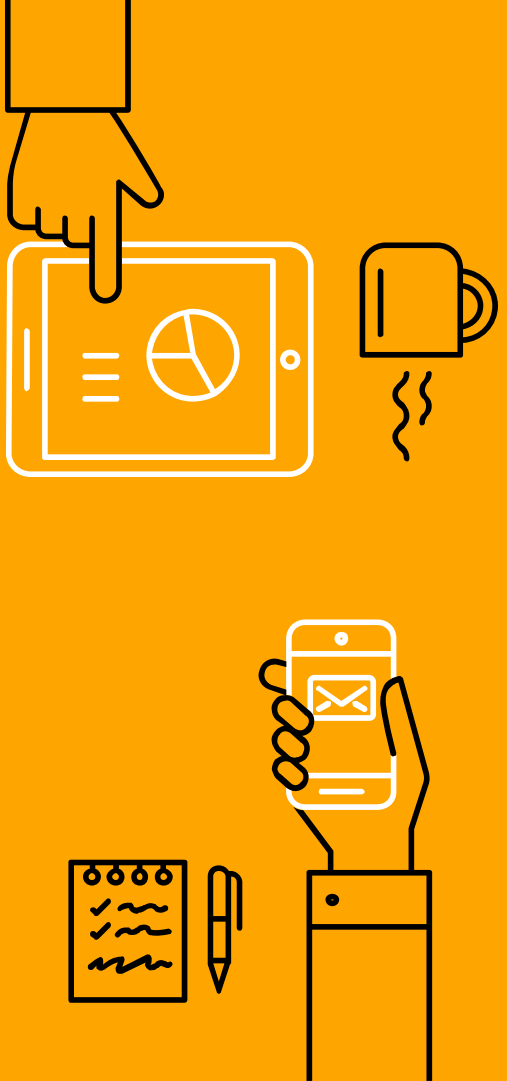

Revenons sur:

des **représentations structurées** du monde

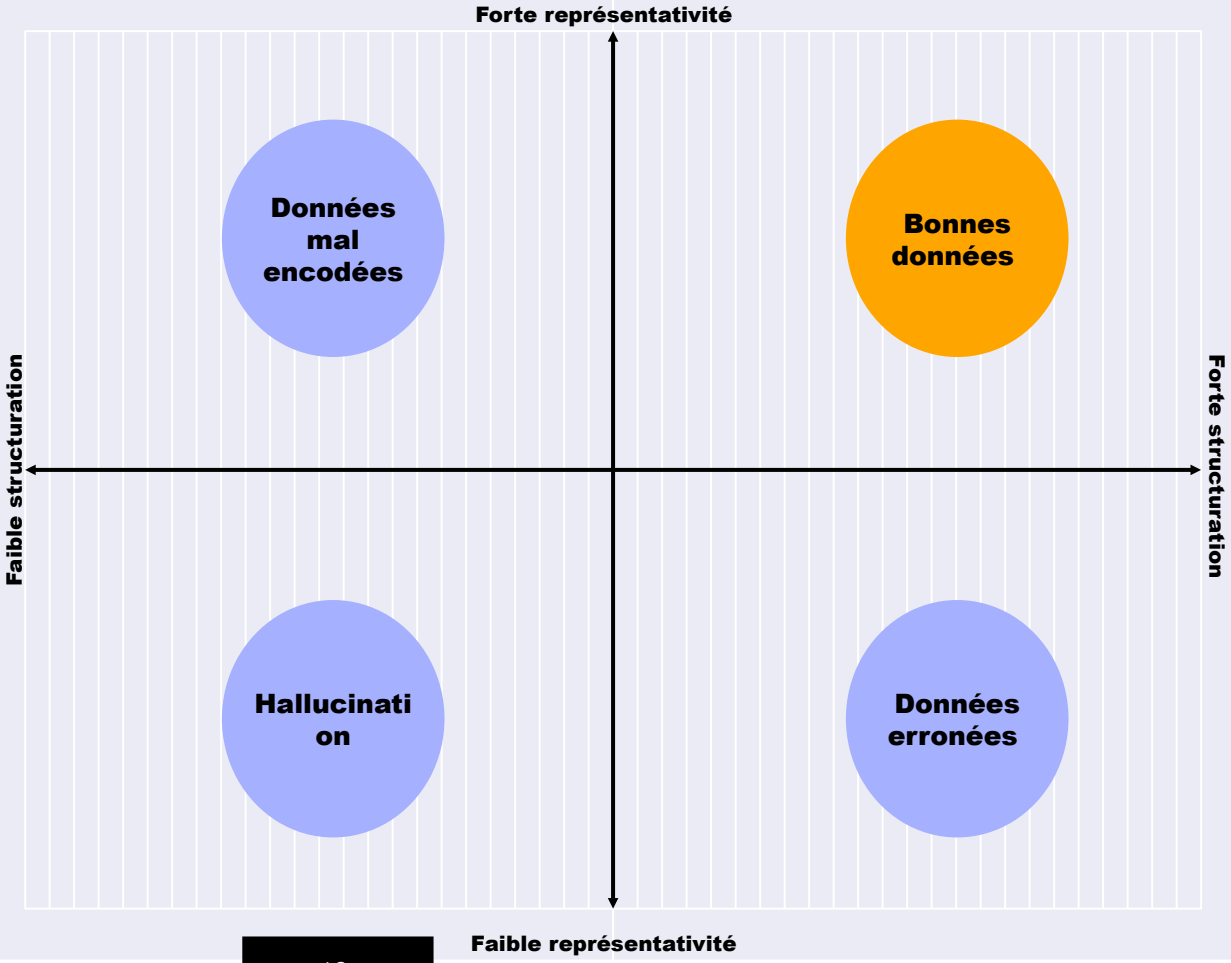

Schéma conçu par Cédric Lombion (Civic Literacy Initiative)

Un réflexe essentiel

Vérifier est nécessaire même avec des données officielles

Exercice : https://bit.ly/IJBA2425-3

Vérification: 3 enjeux

1. **Fiabilité** — Les données représentent-elles la réalité ?
2. **Exhaustivité** — les données sont-elles complètes ?
3. **Qualité** — Les données sont-elles structurées et documentées correctement ?

Vérification: 3 enjeux

1 Fiabilité

Les données représentent-elles la réalité ?

« par exemple, un taux d'épisiotomie plus élevé chez les multipares que chez les primipares, des taux d'épisiotomie à moins de 1 % ou à plus de 60 % (source: Le Monde) »

Vérification: 3 enjeux

2 Exhaustivité

les données sont-elles complètes ?

« **tous les actes ne disposent pas d'un code spécifique**, et même parmi ceux qui en ont, certains, non « tarifés », **ne sont pas systématiquement saisis** par les soignants, à l'image de l'épisiotomie. (source: Le Monde) »

Vérification: 3 enjeux

3 Qualité

Les données sont-elles structurées et documentées correctement ?

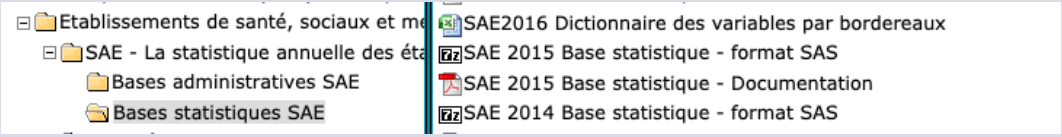

BOR	AN	FI	FI_EJ	BIO_A1	BIO_A2	BIO_A3	BIO_A4	BIO_A5	BIO_A6	BIO_A7	BIO_A8	BIO_A9	BIO_A10	BIO_A11	BIO_A12	BIO_A13	BIO_A14	BIO_A15	BIO_A16	BIO_A17	BIO_A18	BIO_B1	BIO_B2	BIO_B3
BIO	2017	010000024	010780054	1	1	0	1	1	0	0	1	0	0	1	1	1	1	0	0	0	0	0	842413	46807
BIO	2017	010005239	010008407	1	0	0	1	1	1	0	0	0	0	1	1	0	0	0	0	0	0	1	287872	33034
BIO	2017	020000162	020000063	1	1	0	1	1	0	0	1	0	0	1	1	1	0	0	0	0	0	1	941991	34002
BIO	2017	020000394	020000253	1	1	0	1	1	1	1	1	0	0	1	1	1	0	0	0	0	0	1	966398	139529
BIO	2017	020000519	020000261	1	1	0	1	1	1	1	1	0	0	1	1	1	1	0	0	1	1	1	738092	64676
BIO	2017	020000535	020000287	1	1	0	1	1	1	0	0	0	0	0	0	1	1	0	0	0	0	1	467262	2516
BIO	2017	020001061	020004404	1	1	0	1	1	1	0	0	0	0	1	1	1	0	0	0	0	0	0	613385	209591

4 méthodes

A employer en fonction des données

- **Demander à la source**
- **Demander aux experts**
- **Vérifications statistiques** (moyenne, médiane, maximum, minimum, écart-type)
- **Bon sens** (est-ce que les hypothèses de bases sont réalistes?)

Problèmes courants

- Valeurs manquantes
- Valeurs manquantes remplacées par des valeurs ambigues comme 0 ou des dates par défaut (1900,1904, 1969, 1970 sont des défauts courant)
- Lignes ou valeurs en double
- Formats de dates qui varient au sein du même jeu de données
- Unités de mesure non spécifiées
- Noms de colonnes ambigus
- Pas de documentation de la provenance ou méthodologie du jeu de donnée
- Des valeurs suspectes sont présentes
- Les données ne sont pas assez fines
- Les totaux diffèrent des agrégats inclus
- La feuille de calcul a exactement 65536 lignes (valeur max dans les anciennes versions d'Excel) ou 255 colonnes (valeur max dans les anciennes versions de Numbers)

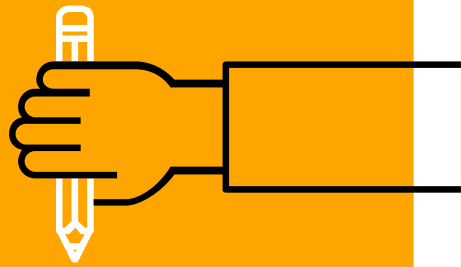

Le nettoyage

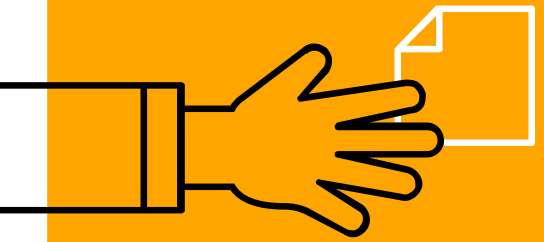

Le plan

Ce que l'on va faire ensemble:

1. Télécharger le logiciel Tabula https://tabula.technology/
2. Récupérer le fichier PDF marqué 'EXO'
3. Identifier notre stratégie de vérification
4. Extraire les données
5. Vérifier & Nettoyer les données

Récapitulatif: nettoyage

Lors du **toilettage**, vous serez souvent amenés à:

- Enlever les artefacts de mise en forme (e.g. * NOM*)
  - en utilisant SUBSTITUTE()
- Séparer les données en deux colonnes, par exemple pour séparer une valeur et son unité (e.g. 5 milliards)
  - en utilisant SPLIT()
- Aligner les colonnes qui étaient décalées (par exemple après un export Tabula)
- Scindre les donnée sur plusieurs lignes quand elles sont dans une seule cellule
  - par exemple avec SPLIT() et char(10)
- Corriger les problèmes basiques d'orthographe qui affectent les filtres comme les formats de dates et les variations dans l'écriture des noms propres (New York, N.Y.)
  - en utilisant: IF() or IFS()

Récapitulatif: nettoyage

Lors de l'**édition**, vous serez souvent amenés à:

- Valeurs manquantes ou incorrectes: corriger ou supprimer ?
- La seule solution peut être d'abandonner le jeu de donnée et aller en chercher un autre
- Identifier et enlever les éléments en double
  - formule utile: UNIQUE()
- fonctionnalité unique: Filters
- Ajouter de colonnes de clarification (e.g. unités de valeur)
- Ajouter des colonnes calculées (e.g. âge des individus quand vous n'avez que leurs date de naissance
  - formule utile: DATEDIF()
- Ajouter des colonnes de catégorisation (e.g. tranches d'âges)
  - formules utiles: IF() or IFS()
- Enlever des portions de données qui ne sont pas pertinentes pour votre analyse

Récapitulatif: nettoyage

Lors du **rapprochement**, vous serez souvent amenés à:

- Fusion de deux jeux de données (ou plus) en utilisant une colonne commune
  - formule utile: FILTER() et INDEX(MATCH())

A demain pour…

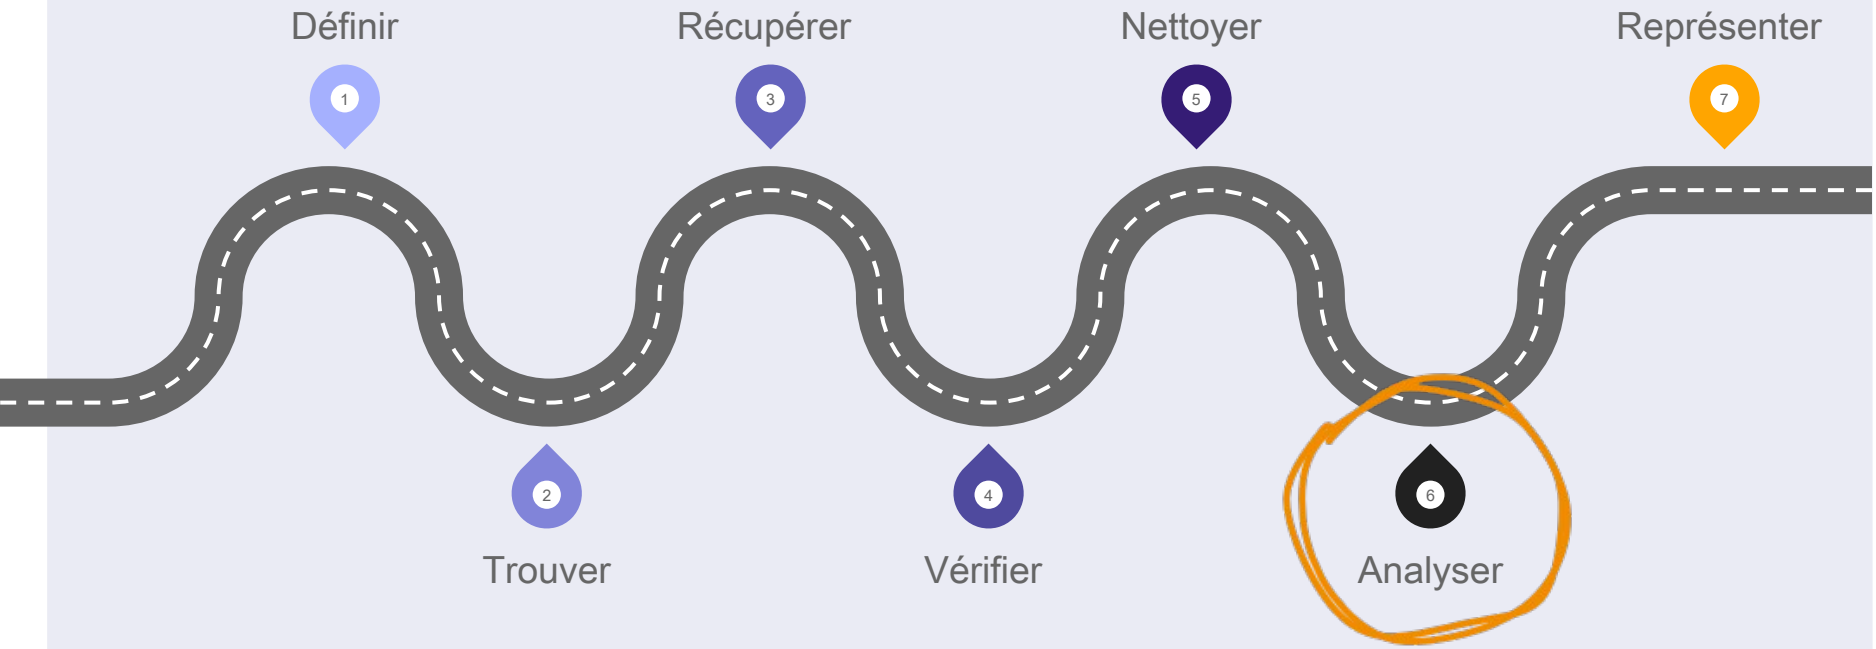

*** Matrice conçue par School of Data, la branche “formation” de l’ONG Open Knowledge Foundation**